

Trabajo Fin de Grado
Grado en Ingeniería Electrónica, Robótica y Meca-
trónica

Estrategias de gestión energética para una estación de
repostaje multi-energía: cuantificación de la mejora
aportada por la predicción con redes LSTM

Autor: Fernando Román Hidalgo

Tutor: Miguel Ángel Ridao Carlini

Dpto. de Ingeniería de Sistemas y Automática
Escuela Técnica Superior de Ingeniería
Universidad de Sevilla

Sevilla, 2026



Trabajo Fin de Grado
Grado en Ingeniería Electrónica, Robótica y Mecatrónica

Estrategias de gestión energética para una estación de repostaje multi-energía: cuantificación de la mejora aportada por la predicción con redes LSTM

Autor:

Fernando Román Hidalgo

Tutor:

Miguel Ángel Ridao Carlini

CATEDRÁTICO DE UNIVERSIDAD

Dpto. de Ingeniería de Sistemas y Automática
Escuela Técnica Superior de Ingeniería
Universidad de Sevilla

Sevilla, 2026

Trabajo Fin de Grado: Estrategias de gestión energética para una estación de repostaje multi-energía:
cuantificación de la mejora aportada por la predicción con redes LSTM

Autor: Fernando Román Hidalgo

Tutor: Miguel Ángel Ridaó Carlini

El tribunal nombrado para juzgar el trabajo arriba indicado, compuesto por los siguientes profesores:

Presidente:

Vocal/es:

Secretario:

Acuerdan otorgarle la calificación de:

El Secretario del Tribunal:

Fecha:

Agradecimientos

Decía el tío Ben que «un gran poder conlleva una gran responsabilidad». Durante este último tiempo, al estar ya inmerso en el mundo laboral, reconozco que la tentación de dejar este trabajo de lado y pasar página ha estado muy presente. Sin embargo, he sentido la responsabilidad de terminar lo que empecé y cerrar esta etapa académica como se merece. No solo por mí, sino por el deber de honrar a todas las personas que han estado a mi lado. Por eso, este trabajo no es solo mío, sino de todos los que me han acompañado en el proceso.

En primer lugar, quiero expresar mi más sincero agradecimiento a mi tutor, Miguel Ángel, por su paciencia, su plena disponibilidad y su intachable profesionalidad a la hora de guiarme.

A mis padres, por su apoyo incondicional desde el primer día. Gracias por confiar siempre en mí y por haberme inculcado el valor de no conformarme nunca. Si he llegado hasta aquí, es gracias a lo que me habéis enseñado.

A mis amigos de la universidad, por compartir el gusto de aprender riendo. Gracias a vosotros, cada paso dado en esta carrera no se ha sentido como una obligación, sino como una experiencia que ha merecido la pena.

A mis amigos de siempre, por obligarme a levantar la vista de la pantalla y ser ese soplo de aire fresco y necesario cuando uno solo necesita despejarse y desconectar.

Y a mi pareja, mi mayor punto de apoyo durante toda esta etapa universitaria. Has sido mi refugio y mi motivación en esos momentos en los que las fuerzas escaseaban; sé de sobra que, sin tu aliento, este trabajo todavía seguiría en el tintero.

A todos, gracias por acompañarme hasta la meta.

Resumen

La descarbonización del transporte por carretera exige infraestructuras de repostaje capaces de dar servicio simultáneamente a vehículos eléctricos de batería y a vehículos de pila de combustible, integrando además la generación renovable local. Este trabajo aborda el modelado y la simulación en MATLAB/Simulink de OASIS, una microrred multi-energía que combina generación fotovoltaica, almacenamiento eléctrico (BESS), un electrolizador PEM con almacenamiento de hidrógeno en dos etapas de presión (tanque de baja y de alta, con compresor intermedio), una pila de combustible y dos cargadores rápidos de vehículo eléctrico, todo ello coordinado por un Sistema de Gestión de Energía (EMS).

Partiendo de un EMS heurístico de referencia adaptado de un trabajo previo del grupo de investigación, se entrenan y validan dos modelos de red neuronal LSTM —irradiancia solar y precio spot de la electricidad a 24 horas— y se estudia cómo incorporarlos a la gestión. Inyectadas en las reglas de la heurística, las previsiones no reducen el coste ni siquiera con información perfecta, aunque sí mejoran de forma sistemática la seguridad del suministro de hidrógeno. La cadena de medida construida para demostrarlo (comparación pareada por semilla, oráculo, descomposición de la importación por destinos y ablación por componentes) localiza en cambio el margen real: la heurística compraba a la red la mayor parte de la energía del electrolizador con la batería casi llena. La versión final del EMS hace que la batería alimente al electrolizador antes que la red y programa la producción de hidrógeno sobre el precio publicado del mercado diario, y reduce el coste semanal un 14 % en los veinte casos evaluados. Añadirle la previsión LSTM de precio no cambia ningún resultado, porque la información que la decisión necesita ya está publicada; la previsión aporta donde hay incertidumbre real, que es el suministro de hidrógeno en los días de poca irradiancia.

El trabajo entrega, por tanto, la herramienta de simulación y comparación de estrategias, los dos modelos de predicción validados frente a líneas base no triviales, y la evidencia cuantitativa de qué parte de la mejora de un EMS predictivo es atribuible a la predicción y qué parte al diseño de las reglas que la consumen.

Palabras clave: microrred multi-energía, sistema de gestión de energía (EMS), hidrógeno verde, electrolizador PEM, pila de combustible, LSTM, vehículo eléctrico, MATLAB/Simulink.

Abstract

Decarbonizing road transport requires refueling infrastructure able to serve battery electric vehicles and fuel-cell electric vehicles simultaneously, while integrating local renewable generation. This thesis addresses the modeling and simulation, in MATLAB/Simulink, of OASIS, a multi-energy microgrid that combines photovoltaic generation, electrical storage (BESS), a PEM electrolyzer with two-stage hydrogen storage (low- and high-pressure tanks linked by a compressor), a fuel cell, and two fast electric-vehicle chargers, all coordinated by an Energy Management System (EMS).

Starting from a heuristic reference EMS adapted from prior work by the research group, two LSTM neural network models are trained and validated —solar irradiance and day-ahead electricity price over a 24-hour horizon— and their integration into the management logic is studied. Injected into the heuristic’s rules, the forecasts do not reduce cost even with perfect information, although they consistently improve the security of hydrogen supply. The measurement chain built to demonstrate this (seed-paired comparison, oracle runs, decomposition of grid imports by destination and component-wise ablation) instead locates the real margin: the heuristic bought most of the electrolyzer’s energy from the grid while the battery was nearly full. The final EMS lets the battery feed the electrolyzer before the grid does, and schedules hydrogen production on the published day-ahead price, reducing the weekly cost by 14 % in all twenty evaluated cases. Adding the LSTM price forecast changes no result, because the information the decision needs is already published; forecasting adds value where genuine uncertainty remains, namely hydrogen supply on low-irradiance days.

The thesis therefore delivers the simulation and comparison framework, the two forecasting models validated against non-trivial baselines, and quantitative evidence of how much of a predictive EMS’s improvement is attributable to the forecast and how much to the design of the rules that consume it.

Keywords: multi-energy microgrid, energy management system (EMS), green hydrogen, PEM electrolyzer, fuel cell, LSTM, electric vehicle, MATLAB/Simulink.

Índice General

<i>Agradecimientos</i>	I
<i>Resumen</i>	III
<i>Abstract</i>	V
<i>Índice General</i>	VII
<i>Nota sobre el uso de herramientas de Inteligencia Artificial</i>	XI
1. Introducción	2
1.1. Contexto y motivación	2
1.2. Objetivos	3
1.2.1. Objetivo general	3
1.2.2. Objetivos específicos	3
1.3. Alcance del trabajo	3
1.4. Estructura del documento	4
2. Estado del arte	6
2.1. Contexto: transición energética y movilidad limpia	6
2.2. Estaciones de repostaje multi-energía	6
2.2.1. Concepto y ventajas	6
2.2.2. Proyectos de referencia	7
2.3. Generación fotovoltaica	7
2.3.1. Dimensionamiento real del generador PV de OASIS	8
2.4. Electrólisis PEM para producción de hidrógeno verde	8
2.4.1. Principio de funcionamiento	8
2.4.2. Ventajas del PEM frente al alcalino	8
2.4.3. Curva de polarización	9
2.5. Almacenamiento de hidrógeno	9
2.5.1. Almacenamiento a baja presión (buffer)	10
2.5.2. Compresión hacia alta presión	10
2.5.3. Almacenamiento a alta presión	10
2.6. Pila de combustible (PEMFC)	11
2.7. Almacenamiento electroquímico (BESS)	11
2.8. Infraestructura de carga eléctrica (EV)	12
2.9. Microrredes y sistemas de gestión de energía	13
2.9.1. Concepto de microrred	13
2.9.2. Estrategias de gestión energética (EMS)	13
2.9.3. EMS en instalaciones multi-energía: revisión bibliográfica	14
2.10. Predicción de irradiancia solar con redes neuronales	14
2.11. Predicción del precio spot de electricidad	15
2.12. Simulación de microrredes con Simulink/Simscape	15
2.13. Posicionamiento del presente trabajo	15

3.	Datos de carga EV y dimensionamiento de la estación	18
3.1.	Dataset de referencia: DESL-EPFL	18
3.1.1.	Descripción del dataset	18
3.1.2.	Distribución de llegadas	18
3.1.3.	Energía por sesión	19
3.1.4.	Estado de carga (SOC)	19
3.2.	Comparación Level 2 vs Level 3	20
3.2.1.	Definición de niveles	20
3.2.2.	Comparación con datos reales	20
3.3.	Justificación de la potencia del cargador (50 kW)	22
3.3.1.	Criterio de selección de 50 kW	22
3.3.2.	Comparación con alternativas	23
3.3.3.	Validación con el dataset	24
3.4.	Dimensionamiento de la estación	24
3.4.1.	Número de cargadores EV	24
3.4.2.	Número de surtidores de hidrógeno	26
3.5.	Generación de perfiles de demanda	28
3.5.1.	Metodología	28
3.5.2.	Escalado	28
3.5.3.	Resultados	28
3.5.4.	Descripción del proceso de generación	29
3.6.	Limitaciones del dataset	30
3.7.	Referencias de datos	30
4.	Modelos de predicción basados en redes LSTM	32
4.1.	Fundamentos de las redes LSTM	32
4.2.	Modelo LSTM solar: predicción de irradiancia	33
4.2.1.	Datos de entrada y fuente	33
4.2.2.	Arquitectura y entrenamiento	33
4.2.3.	Resultados de validación	35
4.2.4.	Evaluación frente a líneas base	37
4.2.5.	Proyección sobre la envolvente y elección del horizonte operativo	40
4.2.6.	Combinación con la línea base	42
4.2.7.	Integración en Simulink: S-Function <code>lstm_sol.m</code>	43
4.3.	Modelo LSTM de precio: predicción del mercado spot	43
4.3.1.	Motivación y fuente de datos	43
4.3.2.	Features del modelo (14 variables)	44
4.3.3.	Arquitectura y entrenamiento	45
4.3.4.	Resultados de validación	46
4.3.5.	Combinación con la línea base	50
4.3.6.	Evaluación en lazo cerrado	51
4.3.7.	Clamp de predicciones negativas	51
4.3.8.	Integración en Simulink: S-Function <code>lstm_precios.m</code>	52
4.4.	Comparación de los dos modelos	53
4.5.	Limitaciones de los modelos	54
5.	Metodología	56
5.1.	Enfoque general	56
5.2.	Entorno de simulación: la microrred OASIS	56
5.3.	El EMS de referencia — Versión A	60
5.4.	Del EMS heurístico al EMS de programación: lo que enseñó la iteración	64
5.5.	Qué se corrige del EMS heredado y qué queda anotado	65

5.6.	El EMS final – Versión C	66
5.6.1.	La batería alimenta al electrolizador	66
5.6.2.	Programación: el electrolizador produce en las horas más baratas que hacen falta	66
5.6.3.	Qué hace cada previsión, y por qué	67
5.6.4.	Parámetros y lo que no lleva	68
5.6.5.	Diseño de la ablación	68
5.7.	Métricas de comparación	69
5.8.	Escenarios de simulación	70
6.	Resultados	74
6.1.	Cadena de ejecución	74
6.2.	Diseño de repeticiones y comparación pareada	75
6.3.	Alcance de lo ejecutado	75
6.4.	Verificación previa de los resultados	76
6.5.	El resultado de la variante predictiva	77
6.6.	El diagnóstico: a dónde va la importación	78
6.7.	La Versión C	79
6.7.1.	Frente a la heurística de referencia	79
6.7.2.	Ablación: cuánto vale cada componente	82
6.7.3.	Sensibilidad a los precios del hidrógeno	82
7.	Conclusiones	84
7.1.	Respuesta a la pregunta del trabajo	84
7.2.	Aportaciones	85
7.3.	Limitaciones	85
7.4.	Líneas futuras	86
8.	Anexo: código y datos del trabajo	88
	<i>Índice de Figuras</i>	90
	<i>Índice de Tablas</i>	94
	<i>Bibliografía</i>	98

Nota sobre el uso de herramientas de Inteligencia Artificial

Durante el desarrollo de este trabajo se han empleado de manera complementaria herramientas de Inteligencia Artificial generativa como apoyo en tareas de optimización de redacción, organización y estructura de contenidos, así como en la consulta bibliográfica preliminar y en el soporte puntual para la depuración de scripts de MATLAB orientados a la generación de figuras y tablas. En todo caso, la formulación de los objetivos, la toma de decisiones metodológicas, el diseño de los sistemas de gestión energética (EMS), la validación de los modelos y la interpretación de los resultados han sido llevados a cabo de forma autónoma por el autor, quien asume la plena responsabilidad de la autoría intelectual del contenido de esta memoria.

1 Introducción

1.1 Contexto y motivación

La descarbonización del transporte por carretera es una prioridad de la política energética europea: el sector es responsable de una parte sustancial de las emisiones de gases de efecto invernadero de la Unión y su reducción es una de las líneas de acción del Pacto Verde Europeo [1], [2]. Dos vectores de propulsión alternativa concentran la mayor parte de la inversión y el despliegue actual: el vehículo eléctrico de batería (EV) y el vehículo de célula de combustible de hidrógeno (FCEV). Ambos comparten una misma limitación estructural: dependen de una infraestructura de repostaje/recarga que hoy está mayoritariamente separada por vector energético. Esta separación fragmenta la inversión y ralentiza el despliegue conjunto [3], [4].

La estación de repostaje multi-energía (MERS, *Multi-Energy Refueling Station*) responde a esta limitación: integra en una única instalación la generación renovable local, el almacenamiento (eléctrico y de hidrógeno) y los puntos de suministro para ambos tipos de vehículo [5]. En España, la Hoja de Ruta del Hidrógeno sitúa explícitamente los corredores de repostaje verde como una de las líneas prioritarias de despliegue de hidrógeno renovable [6], y el elevado recurso solar de regiones como Andalucía favorece el uso de generación fotovoltaica local como fuente primaria de una instalación de este tipo.

El reto técnico de una MERS es de operación, además de dimensionamiento: coordinar en tiempo real el reparto de la energía disponible entre la carga de baterías, la producción de hidrógeno vía electrólisis, el uso de la pila de combustible y la atención a la demanda simultánea de EV y FCEV, todo ello bajo un precio eléctrico horario variable. Esta coordinación es responsabilidad del sistema de gestión energética (EMS, *Energy Management System*) de la instalación. El Capítulo 2 distingue tres familias de EMS: heurísticas basadas en reglas, control predictivo (MPC) y aprendizaje automático. Las estrategias basadas en reglas siguen siendo las más utilizadas en instalaciones reales por su robustez y su sencillez de implementación, pero su principal debilidad es no incorporar información predictiva sobre generación, demanda o precio, lo que les impide anticiparse a eventos futuros.

Este trabajo parte de un antecedente directo: el EMS heurístico más avanzado desarrollado en el TFM de Molero Almazán [7] para una microrred híbrida con almacenamiento de hidrógeno, que ya incorpora coordinación dinámica batería-electrolizador según el estado de carga y tiempos mínimos de funcionamiento con histéresis. Ese EMS no llega a incorporar predicción real de ninguna variable, a pesar de dejar puertos preparados para ello, como el propio autor reconoce en sus conclusiones y líneas futuras. Este trabajo fin de grado recoge explícitamente esa línea de continuación: adaptar dicho EMS a la arquitectura de una MERS con carga EV e integrar en él predicciones basadas en redes LSTM de dos de sus variables de entrada más relevantes, la irradiancia solar y el precio spot de la electricidad. Con ello se cuantifica la mejora que aporta la predicción frente a la heurística de partida sin ella.

1.2 Objetivos

1.2.1 Objetivo general

Diseñar, simular y comparar estrategias de gestión energética (EMS) para una estación de repostaje multi-energía con generación fotovoltaica, almacenamiento electroquímico y de hidrógeno, y carga de vehículos eléctricos y de hidrógeno, partiendo de una estrategia heurística avanzada de referencia sin predicción y llegando a una versión final cuyos componentes se evalúan por separado, para cuantificar qué parte de la mejora es atribuible a las predicciones basadas en redes LSTM de irradiancia solar y precio eléctrico.

1.2.2 Objetivos específicos

1. Caracterizar la demanda de carga de vehículos eléctricos, a partir de un dataset real de sesiones de carga rápida (DESL-EPFL), y generar a partir de ella perfiles de demanda sintéticos, tanto de carga EV como de repostaje de hidrógeno, coherentes con el dimensionamiento de la estación (Capítulo 3).
2. Desarrollar y validar dos modelos de predicción basados en redes LSTM: uno para la irradiancia solar y otro para el precio spot de la electricidad, ambos a un horizonte de 24 horas, e integrarlos en el bucle de simulación de Simulink mediante S-Functions (Capítulo 4).
3. Adaptar el EMS heurístico avanzado de referencia [7] (coordinación dinámica batería/electrolizador según SOC, tiempo mínimo de funcionamiento con histéresis, compresor, doble almacenamiento de hidrógeno y decisión económica de producción propia frente a compra externa) a la arquitectura y a la escala de la estación de este trabajo, manteniendo la máquina de estados de arranque/parada de los equipos electroquímicos ya existente.
4. Diseñar un EMS que incorpore las predicciones LSTM de irradiancia solar y de precio en la toma de decisiones, iterando sobre la versión de referencia hasta una versión final cuyos componentes puedan evaluarse por separado.
5. Simular las versiones bajo condiciones equivalentes y comparar cuantitativamente su desempeño en coste operativo, aprovechamiento de la generación renovable, seguridad del suministro de hidrógeno y régimen de operación de los equipos, para determinar qué parte de la mejora es atribuible específicamente a la predicción.

1.3 Alcance del trabajo

Este trabajo se limita a la fase de diseño, simulación y comparación en MATLAB/Simulink; no incluye la implementación física de la instalación ni un análisis económico de inversión (CAPEX/OPEX) a largo plazo. El horizonte de simulación considerado es de días/semanas representativos (laborable y fin de semana), no de un año completo, en línea con el enfoque adoptado también en el antecedente de este trabajo [7]. La ubicación de referencia es Sevilla, lo que condiciona tanto los datos meteorológicos empleados para entrenar el modelo solar como el mercado eléctrico de referencia (OMIE) para el modelo de precio.

Las tres versiones del EMS que se comparan —la heurística de referencia, la variante que inyecta las previsiones en sus reglas y la versión final, esta última evaluada además en dos configuraciones de ablación— son todas de tipo heurístico (reglas); no se aborda en este trabajo el diseño de un controlador predictivo basado en modelos (MPC), que el trabajo antecedente señala como siguiente paso para instalaciones de este tipo, y que queda propuesto como línea de trabajo futuro. Del mismo modo, se mantienen las limitaciones ya identificadas en los datos de partida: el perfil de demanda de hidrógeno se aproxima por analogía con el de EV, y la predicción solar se valida con datos

meteorológicos observados en lugar de una previsión meteorológica operativa real. Ambas se tienen en cuenta al interpretar los resultados de la comparación (véanse Capítulo 3 y Capítulo 4).

1.4 Estructura del documento

El resto del documento se organiza como sigue. La Capítulo 2 revisa el contexto tecnológico de las estaciones de repostaje multi-energía, sus componentes principales (generación fotovoltaica, electrólisis PEM, almacenamiento de hidrógeno, pila de combustible, BESS e infraestructura de carga EV) y las estrategias de gestión energética existentes, y sitúa la contribución de este trabajo respecto a ese estado del arte. La Capítulo 3 describe el dataset de referencia utilizado para caracterizar la demanda de carga EV, la justificación de la potencia del cargador seleccionada y el proceso de generación de los perfiles de demanda sintéticos empleados en la simulación. La Capítulo 4 presenta el desarrollo, entrenamiento y validación de los dos modelos LSTM (irradiancia solar y precio eléctrico) y su integración en el modelo de Simulink.

A continuación, el capítulo de Metodología describe el EMS heurístico de referencia, resume lo que enseñó el intento de mejorarlo inyectando las predicciones LSTM en sus reglas, y presenta el diseño del EMS final de este trabajo, la Versión C, junto con la configuración de las simulaciones y el diseño de su ablación. El capítulo de Resultados presenta y discute la comparación cuantitativa. Finalmente, el capítulo de Conclusiones recoge las principales aportaciones del trabajo y propone líneas de continuación futuras.

2 Estado del arte

Este capítulo revisa el contexto tecnológico y científico en el que se enmarca el presente trabajo. Se analiza el estado actual de las estaciones de repostaje multi-energía, los componentes que las integran (generación fotovoltaica, electrólisis PEM, almacenamiento de hidrógeno, pilas de combustible, almacenamiento en baterías y carga de vehículos eléctricos), las estrategias de gestión energética aplicadas a microrredes, y el uso de redes neuronales recurrentes de tipo LSTM para la predicción de irradiancia solar y precio de la electricidad.

2.1 Contexto: transición energética y movilidad limpia

La descarbonización del sector transporte es un objetivo central de la transición energética. En Europa, el transporte representa aproximadamente una cuarta parte ($\approx 25\%$) de las emisiones totales de gases de efecto invernadero. El transporte por carretera concentra en torno al 72% de dicha fracción [2]. Para alcanzar la neutralidad climática en 2050 fijada por el Pacto Verde Europeo [1], es necesario electrificar la movilidad y desarrollar las infraestructuras de recarga y repostaje que la soporten.

Dos tecnologías vehiculares limpias coexisten en este escenario: los vehículos eléctricos de batería (BEV, *Battery Electric Vehicles*) y los vehículos de pila de combustible de hidrógeno (FCEV, *Fuel Cell Electric Vehicles*). Ambos complementan sus fortalezas en segmentos de mercado distintos: los BEV son más eficientes y económicos en trayectos urbanos cortos y medios; los FCEV ofrecen mayor autonomía y repostaje más rápido en trayectos de larga distancia y para vehículos pesados [8].

En España, la Hoja de Ruta del Hidrógeno [6] fija para 2030 el objetivo de instalar entre 100 y 150 hidrogeneras de acceso público y de alcanzar 4 GW de potencia instalada de electrólisis, con un hito intermedio de 300–600 MW en 2024. En el vector eléctrico, el Plan Nacional Integrado de Energía y Clima (PNIEC 2023–2030) fija 5,5 millones de vehículos eléctricos en circulación en 2030 [9], y el reglamento europeo AFIR [10] establece los objetivos vinculantes de despliegue de infraestructura de recarga que España debe cumplir. Este contexto crea una demanda creciente de instalaciones que combinen ambos vectores energéticos bajo un mismo techo.

2.2 Estaciones de repostaje multi-energía

2.2.1 Concepto y ventajas

Una estación de repostaje multi-energía (MERS, *Multi-Energy Refueling Station*) es una instalación que combina, bajo un único sistema de gestión, dos o más vectores energéticos para la movilidad. En su configuración más avanzada integra: generación fotovoltaica, almacenamiento en baterías, electrólisis para producción local de hidrógeno, almacenamiento de hidrógeno a baja y alta presión, pila de combustible y cargadores de vehículos eléctricos [5].

Las ventajas de integrar ambos vectores en una misma instalación son múltiples:

- **Aprovechamiento compartido de la generación renovable:** la instalación fotovoltaica puede destinar el excedente solar tanto a cargar baterías como a producir hidrógeno, con lo que aprovecha al máximo la energía local.
- **Reducción del coste de la infraestructura de conexión a la red:** al compartir el punto de conexión entre cargadores EV y electrolizador, se reduce la demanda pico sobre la red y el coste del transformador.
- **Flexibilidad ante la volatilidad del precio spot:** la pila de combustible puede actuar como respaldo generando electricidad en horas de precio alto, mientras que el electrolizador consume en horas de precio bajo.
- **Servicio integral al usuario:** un único emplazamiento puede atender tanto a conductores de BEV como de FCEV, y reduce el tiempo de desplazamiento hacia infraestructura especializada.

2.2.2 Proyectos de referencia

A nivel europeo, el proyecto H2ME (*Hydrogen Mobility Europe*), financiado por la *Fuel Cells and Hydrogen Joint Undertaking* bajo los acuerdos 671438 y 700350, es la mayor demostración europea de vehículos ligeros e infraestructura de hidrógeno: se planteó desplegar 1 500 vehículos y 49 estaciones de repostaje en Alemania, Francia, Dinamarca, Suecia y Reino Unido entre 2015 y 2022 [3]. Los resultados intermedios publicados del proyecto son especialmente relevantes para este trabajo porque documentan operación real y no simulada: 102 vehículos de pila de combustible acumulaban 625 300 km recorridos y 7 900 kg de hidrógeno dispensados sin ningún incidente de seguridad, con tiempos de repostaje de 2 a 3 minutos, y la estación de 700 bar de Kolding (Dinamarca) alcanzó una disponibilidad del 98,2% despachando 900 kg en su primer año [3]. La hoja de ruta europea del hidrógeno sitúa el transporte por carretera como uno de los segmentos de despliegue prioritario de esta infraestructura [4].

A nivel nacional, Repsol inauguró en enero de 2025 la estación H2GO Repsol Morro Jable (Fuerteventura), la primera estación multi-energía y autosuficiente de Canarias: combina diésel renovable, un punto de recarga eléctrica de 50 kW, hidrógeno verde y combustibles tradicionales, con generación fotovoltaica (75 kW), baterías de litio (250 kW) y una pila de hidrógeno de 88 kW que garantizan la autosuficiencia energética de la propia instalación [11]. El conjunto es una combinación de componentes muy similar a la de OASIS, aunque a menor escala y sin electrolizador propio (el H₂ se suministra ya producido, no se genera in situ). La Hoja de Ruta del Hidrógeno del Gobierno de España contempla además una red de en torno a un centenar de hidrogeneras en el país para 2030 [6].

En el ámbito académico, [12] evalúan en HOMER Pro una estación de recarga de vehículo eléctrico alimentada por fotovoltaica y eólica con baterías de ion-litio, tanque de hidrógeno, electrolizador y pila de combustible, en tres emplazamientos de Malasia, y obtienen un coste neto actualizado (NPC) de entre 1,4 y 3,4 millones de dólares y un coste de la energía (COE) de entre 0,03 y 0,16 \$/kWh según la ubicación. En el plano del control, [13] modelan una microrred de corriente continua PV–hidrógeno a nivel de convertidor, con controladores locales para el campo fotovoltaico, el electrolizador y la pila de combustible coordinados mediante control predictivo económico distribuido, y muestran que este alcanza un comportamiento económico comparable al del control centralizado equivalente con una carga computacional y una oscilación de potencia sensiblemente menores.

2.3 Generación fotovoltaica

La energía solar fotovoltaica es la fuente de generación renovable más adecuada para alimentar una estación de repostaje de carretera por varias razones: su modularidad (se puede dimensionar a la escala exacta de la carga), su bajo mantenimiento y, en el caso de España, el elevado recurso solar disponible [14].

La potencia generada por un sistema FV depende de la irradiancia incidente sobre el panel (G en W/m^2), la temperatura de la célula (T_c), la eficiencia del módulo (η) y el área activa (A):

$$P_{PV} = \eta \cdot A \cdot G \cdot (1 - \beta_T(T_c - T_{\text{ref}}))$$

donde $\beta_T \approx 0.004 \text{ } ^\circ\text{C}^{-1}$ es el coeficiente de temperatura de potencia y $T_{\text{ref}} = 25 \text{ } ^\circ\text{C}$. La irradiancia en el plano del generador (POA) se obtiene a partir de la irradiancia horizontal global (GHI, registrada por NASA POWER en este trabajo) aplicando modelos de transposición como el de Perez [15].

La predicción de irradiancia permite al EMS anticipar la operación del electrolizador: si se predice alta irradiancia para las próximas horas, el EMS puede planificar la producción de hidrógeno con anticipación y evitar curtailment solar.

2.3.1 Dimensionamiento real del generador PV de OASIS

Los apartados que siguen van fijando, junto a cada tecnología, los parámetros con los que está construida la estación OASIS de este trabajo; la Tabla 5.1 los reúne todos y la Figura 5.1 muestra su disposición física. El bloque PV de OASIS.s1x está parametrizado con un array de $N_s = 24$ módulos en serie y $N_p = 35$ ramas en paralelo, cada módulo caracterizado por una tensión en el punto de máxima potencia $V_{\text{mp}} = 34.6 \text{ V}$, corriente de cortocircuito $I_{\text{sc}} = 18.57 \text{ A}$, tensión de circuito abierto $V_{\text{oc}} = 41.7 \text{ V}$, a una temperatura de referencia de 300 K ($27 \text{ } ^\circ\text{C}$). Tomando una relación típica $\frac{I_{\text{mp}}}{I_{\text{sc}}} \approx 0.94$ para módulos de silicio cristalino (dato no incluido en la parametrización del bloque), la potencia nominal por módulo es $P_{\text{mod}} \approx V_{\text{mp}} \cdot I_{\text{mp}} \approx 34.6 \cdot 17.5 \approx 605 \text{ W}$, y la potencia pico del array:



$$P_{PV,\text{pico}} = N_s \cdot N_p \cdot P_{\text{mod}} \approx 24 \cdot 35 \cdot 605 \approx 508 \text{ kWp}$$

Esta estimación es coherente con el pico de generación real observado en el propio modelo ($\approx 500 \text{ kW}$ el 15 de agosto de 2025), por lo que se toma $\approx 500 \text{ kWp}$ como capacidad instalada de OASIS en el resto de este trabajo.


2.4 Electrólisis PEM para producción de hidrógeno verde

2.4.1 Principio de funcionamiento

El hidrógeno verde se produce mediante electrólisis del agua utilizando energía eléctrica renovable. En la electrólisis PEM (*Proton Exchange Membrane*), una membrana de intercambio protónico separa los electrodos (ánodo y cátodo) y actúa simultáneamente como electrolito y barrera de gas [16]. Las semirreacciones son:



La reacción global es:



La energía eléctrica mínima teórica para esta reacción es de 39.4 kWh/kg H_2 (límite termodinámico). Los electrolizadores PEM comerciales actuales operan en el rango de $47\text{--}55 \text{ kWh/kg H}_2$ [17], lo que corresponde a una eficiencia eléctrica del $70\text{--}84\%$.

2.4.2 Ventajas del PEM frente al alcalino

Los electrolizadores PEM son preferibles frente a los alcalinos en aplicaciones acopladas a generación renovable por varias razones [18], [19]:

- **Respuesta dinámica rápida:** el *stack* PEM responde en milisegundos y admite un rango de carga de aproximadamente el 5 al 100 % de su potencia nominal, frente a los segundos y el 20–100 % del alcalino. La carga mínima del alcalino está limitada por la seguridad y no por la electrónica de potencia: su diafragma es permeable a los gases disueltos, de modo que a carga baja el *cruce de gases* (crossover) de hidrógeno hacia el compartimento de oxígeno se aproxima al límite inferior de inflamabilidad, lo que obliga a mantener ese suelo de operación. Esta es la propiedad decisiva para acoplar el electrolizador a un campo fotovoltaico, cuya potencia varía con la nubosidad en cuestión de segundos.
- **Alta densidad de corriente:** los *stacks* PEM operan en torno a 1–2 A/cm² frente a 0,2–0,4 A/cm² del alcalino. El efecto práctico se aprecia mejor en el área de celda necesaria para una misma producción: del orden de cientos de cm² en PEM frente a varios m² en alcalino, de donde resultan equipos mucho más compactos y aptos para instalación contenedorizada.
- **Alta pureza del hidrógeno producido:** entre el 99,9 % y el 99,9999 % según la configuración. El alcalino alcanza valores comparables: la ventaja del PEM no está en el valor final sino en partir de un cruce de gases mucho menor, lo que permite llegar a calidad de pila de combustible (norma ISO 14687) con un tren de acondicionamiento (separador, desoxidante catalítico y secador) integrado en el propio equipo, sin una unidad de purificación externa.
- **Presión diferencial:** los equipos PEM comerciales entregan hidrógeno típicamente a 30 bar, con un rango habitual de 20 a 40 bar, y evitan así una primera etapa de compresión mecánica. Como límite de diseño, la literatura sitúa la presión de celda del PEM por debajo de 70 bar frente a los 30 bar del alcalino [17]. En OASIS el electrolizador entrega a 40 bar, que es exactamente la presión máxima del tanque tampón (Capítulo 2.5.1), de modo que la compresión solo interviene en la etapa siguiente.

2.4.3 Curva de polarización

El comportamiento eléctrico del electrolizador PEM se caracteriza por su curva de polarización $U(i)$ (tensión de celda frente a densidad de corriente), que incluye las pérdidas de activación, óhmicas y de concentración [20]:

$$U = E_{\text{rev}} + \eta_{\text{act}} + \eta_{\text{ohm}} + \eta_{\text{conc}}$$

donde $E_{\text{rev}} \approx 1.23$ V es la tensión reversible a condiciones estándar. En el rango de operación nominal, la potencia consumida es aproximadamente proporcional a la corriente, lo que permite modular la producción de hidrógeno regulando la potencia eléctrica de entrada entre el 10% y el 100% de la potencia nominal.

2.5 Almacenamiento de hidrógeno

El hidrógeno recorre la instalación en dos etapas de presión encadenadas, con un compresor entre ellas. La Figura 2.1 resume esa cadena, los equipos que la componen y los umbrales de nivel con los que el EMS decide sobre cada tanque; los tres apartados siguientes desarrollan cada etapa.




Figura 2.1: Cadena de producción, almacenamiento y dispensación de hidrógeno de OASIS. El electrolizador entrega a la presión máxima del tanque tampón, de modo que la compresión solo interviene en la etapa siguiente. Los umbrales que acompañan a cada tanque son los que gobiernan la decisión del EMS y se justifican en el Capítulo 5; LOH y LOH_High son fracciones de la presión máxima de su propio tanque, no de la masa almacenada.

2.5.1 Almacenamiento a baja presión (buffer)

El hidrógeno producido por el electrolizador PEM se almacena inicialmente en un depósito tampón a presión relativamente baja. El de OASIS tiene un volumen de 3,1 m³ y una presión máxima de 40 bar, con una presión inicial de simulación de 26 bar (parámetros leídos del bloque Low Press Tank del modelo). Este depósito actúa como acumulador entre la producción discontinua (dependiente de la generación solar) y la demanda de compresión hacia el tanque de alta presión. Su función es desacoplar ambas operaciones y evitar arranques y paradas frecuentes del compresor.

2.5.2 Compresión hacia alta presión

Para el repostaje de vehículos de célula de combustible a 700 bar (estándar SAE J2601 para turismos) o 350 bar (vehículos pesados), es necesario comprimir el hidrógeno desde la presión de almacenamiento intermedia hasta la presión de dispensación. Se utilizan compresores de diafragma o compresores iónicos, con consumos típicos de 2–5 kWh/kg H₂ [21].

2.5.3 Almacenamiento a alta presión

El depósito de alta presión alimenta directamente el surtidor. Los depósitos comerciales para estaciones de servicio son cilindros de acero o fibra de carbono con volúmenes de 100–500 L. La masa almacenada es:

$$m_{\text{H}_2} = \rho(P, T) \cdot V$$


donde la densidad ρ del hidrógeno a alta presión se obtiene de la ecuación de van der Waals o tablas NIST; a presión atmosférica es de solo 0.09 kg/m³. El tanque de alta de OASIS tiene un volumen de 0,41 m³ y el bloque empleado en las simulaciones lo parametriza a 600 bar de presión máxima y 480 bar de presión inicial. Conviene precisar qué son los 700 bar que se asocian habitualmente a este tipo de instalación: son la presión nominal de servicio del depósito del **vehículo**, la que fija el estándar de repostaje SAE J2601 para turismos, y no la presión que basta con tener almacenada. Llenar un depósito hasta esa presión exige un diferencial a favor, y por eso las estaciones reales de 70 MPa almacenan en cascada por encima de 850 bar o interponen un compresor de refuerzo (*booster*) entre el almacenamiento y el surtidor; el tanque de alta del que este trabajo hereda los umbrales tiene, de hecho, un techo de seguridad de 900 bar [7]. Con los 600 bar del bloque, un repostaje completo no llegaría a la presión nominal del vehículo. El modelo no representa esa restricción: el surtidor se resuelve como un caudal másico que sale del tanque de alta, sin comprobación de la presión disponible. El efecto del reescalado de los umbrales sobre esos 600 bar se discute en Capítulo 5.

Tomando como referencia los valores habituales de densidad para H₂ gaseoso a 15 °C (23,3 kg/m³ a 350 bar y ≈39,3 kg/m³ a 700 bar [21]) y estimando por extrapolación lineal entre ambos puntos ≈29,2 kg/m³ a 480 bar y ≈34,7 kg/m³ a 600 bar, el tanque almacenaría del orden de 14,2 kg a los 600 bar de su presión máxima y 12,0 kg en su condición inicial de 480 bar. Nótese que se trata de una extrapolación fuera del intervalo definido por los dos puntos de referencia, y no de una interpolación: para un dimensionamiento definitivo procede tomar la densidad directamente de tablas NIST.

Una limitación del modelo condiciona la lectura de los resultados: los bloques de tanque de OASIS calculan la presión a partir de la cantidad de hidrógeno almacenado mediante la ecuación de los gases ideales, sin factor de compresibilidad. A 600 bar y 15 °C el hidrógeno real tiene una densidad de ≈34,7 kg/m³ frente a los ≈50,5 kg/m³ que predice el gas ideal, es decir, el modelo sobrestima en torno a un 45% la masa que cabe en el tanque lleno. La autonomía de hidrógeno que se observe en simulación es, por tanto, optimista respecto a la de una instalación real; corregirla exigiría sustituir la ecuación de estado del bloque por una de gas real (van der Waals, Noble-Abel o tabla NIST), lo que se propone como línea de trabajo futuro.

2.6 Pila de combustible (PEMFC)

La pila de combustible de membrana de intercambio protónico (PEMFC) realiza el proceso inverso al electrolizador: combina hidrógeno y oxígeno atmosférico para generar electricidad, con agua y calor como únicos subproductos [22]:



La tensión teórica de celda es de 1.23 V (a condiciones estándar), pero en operación real se reduce a 0.6–0.8 V por las mismas pérdidas de activación, óhmicas y de concentración que en el electrolizador. La eficiencia eléctrica de las PEMFC comerciales es del 50–60%, con posibilidad de cogeneración (calor + electricidad) hasta el 85%.

En el contexto de una estación de repostaje multi-energía, la pila de combustible tiene dos roles complementarios: actuar como generador de respaldo cuando la generación solar es insuficiente y el precio de la red es elevado, y proporcionar energía de arranque cuando la batería está descargada. El pico eléctrico a cubrir en modo isla no es solo el de los cargadores EV ($2 \times 50 \text{ kW} = 100 \text{ kW}$): hay que sumar el consumo propio del compresor (15 kW) si estuviera operando en ese instante, más un margen de seguridad que cubra la degradación del equipo y la incertidumbre de dimensionamiento. Por ello, la FC de OASIS se ha dimensionado a 130 kW (100 kW de pico EV + 15 kW de compresor + ≈10 % de margen, redondeado a un tamaño de módulo comercial), en vez de a los 100 kW que cubrirían el pico de EV con margen cero. Este valor es el criterio de diseño que emplean los tres EMS de este trabajo como P_{maxFC} . El bloque electroquímico del modelo, en cambio, está parametrizado con 120 celdas de 600 cm² y una corriente máxima de 600 A, lo que corresponde a una potencia de salida sensiblemente menor; escalar el bloque hasta los 130 kW de diseño queda pendiente sobre el modelo físico, y mientras no se haga la consigna Ref_{FC} puede quedar saturada por el propio bloque antes de alcanzar el valor que solicita el EMS.

2.7 Almacenamiento electroquímico (BESS)

Los sistemas de almacenamiento en batería (BESS, *Battery Energy Storage Systems*) proporcionan la respuesta rápida que la pila de combustible y el electrolizador no pueden ofrecer por sus tiempos de arranque. En microrredes de transporte, las baterías de ion-litio son la tecnología dominante por su alta densidad de energía (150–250 Wh/kg), alta eficiencia de ciclo (95–98%) y vida útil de 2000–4000 ciclos [23].

La función principal del BESS en una MERS es la gestión de los picos de potencia de los cargadores de EV: cuando dos cargadores de 50 kW operan simultáneamente (100 kW pico), el BESS puede absorber el excedente de generación solar o descargar para reducir la potencia importada de la red. El dimensionamiento óptimo del BESS en una estación de carga rápida se ha formulado como un problema de programación lineal entera mixta que minimiza el coste total anualizado incorporando la caracterización probabilística de la demanda de carga, la degradación de la batería y —de forma determinante— el término de potencia contratada de la tarifa [24]. En la escala temporal larga, la batería y el hidrógeno se reparten el trabajo en lugar de competir por la misma función: la primera cubre la respuesta rápida y los ciclos diarios, mientras que el almacenamiento en hidrógeno aporta la densidad energética y la duración que las baterías convencionales no alcanzan [25], que es precisamente la división de tareas sobre la que se construye el EMS de este trabajo.

El bloque de batería de 0ASIS.slx sigue el modelo de circuito equivalente descrito en el manual de Simugrid, parametrizado con tensión de circuito abierto $V_{bt,0} = 380$ V, capacidad máxima de 1 MWh, constante de polarización $K = 0.000739$ V, amplitud de la zona exponencial $A = 20.314$ V, resistencia interna $R = 0.00027$ Ω , corriente máxima de carga/descarga de 1 300 A y un estado de carga inicial del 70%. La capacidad en amperios-hora que el bloque utiliza internamente se deriva de los dos primeros parámetros, $C_{120} = 1$ MWh / 380 V ≈ 2632 Ah. De la tensión y la corriente máxima se obtiene el límite de potencia del bloque:

$$P_{\max, \text{BESS}} = V_{bt,0} \cdot I_{\max} = 380 \text{ V} \cdot 1300 \text{ A} \approx 494 \text{ kW}$$

Ese límite equivale a 0,5C sobre la capacidad de 1 MWh, un valor habitual en baterías estacionarias de ion-litio, y queda por encima tanto del mayor consumo simultáneo que la estación puede presentar (100 kW de cargadores, 200 kW de electrolizador y 15 kW de compresor) como de la mayor carga que recibe con excedente (en torno a 400 kW, el 80 % de un pico fotovoltaico de 500 kW). En la práctica, por tanto, la saturación de potencia de la batería no llega a activarse en las simulaciones de este trabajo, y el reparto de potencia entre batería y electrolizador descrito en Capítulo 5 queda gobernado por los umbrales de estado de carga. La capacidad de 1 MWh sí es dimensionalmente coherente con la instalación: equivale a unas dos horas de generación fotovoltaica a potencia pico, y a unos cuatro días de la demanda diaria de carga eléctrica estimada en Capítulo 3. Un dimensionamiento fino del BESS —que no se aborda aquí— debería partir del término de potencia contratada de la tarifa y del perfil de demanda de los cargadores [24], y no del límite interno del bloque de simulación.

2.8 Infraestructura de carga eléctrica (EV)

La norma IEC 61851 establece cuatro modos de carga para vehículos eléctricos, de los cuales los más relevantes para estaciones públicas son el Modo 3 (carga CA trifásica, hasta 22 kW) y el Modo 4 (carga CC rápida, 50–350 kW). La adopción creciente de sistemas DC fast charging (Level 3 según la clasificación norteamericana SAE J1772) responde a la demanda del usuario de tiempos de recarga compatibles con una parada en carretera [26].

El impacto de los cargadores DC rápidos sobre la red de distribución es significativo: un único cargador de 150 kW demanda una corriente de ≈ 217 A a 400 V trifásico, lo que puede provocar caídas de tensión, desbalances de fase y picos de potencia que saturan el transformador de distribución. La inestabilidad de red asociada a los picos súbitos de carga, las pérdidas eléctricas y la sobrecarga de los equipos de alta tensión son, de hecho, la motivación explícita de buena parte de los trabajos que integran generación renovable y almacenamiento en la propia estación [12]. La integración de BESS y gestión dinámica de carga (DLM, *Dynamic Load Management*) son estrategias clave para mitigar este impacto [27].

La Tabla 2.1 resume las características de los principales estándares de carga rápida DC actuales:

Estándar	Potencia máx.	Conector	Tensión DC	Mercado
CCS1 (SAE J1772)	350 kW	CCS Combo 1	200–1000 V	EEUU / Corea
CCS2 (IEC 62196)	350 kW	CCS Combo 2	200–1000 V	Europa
CHAdeMO 3.0	900 kW	CHAdeMO	500 V	Japón
NACS (Tesla)	250 kW	NACS	50–1000 V	EEUU (adoptado por SAE como J3400)
GB/T 20234.3	250 kW	GB/T	200–750 V	China

Tabla 2.1: Principales estándares de carga rápida DC para vehículos eléctricos.

2.9 Microrredes y sistemas de gestión de energía

2.9.1 Concepto de microrred

Una microrred (*microgrid*) es un sistema eléctrico de pequeña escala que agrupa fuentes de generación distribuida, almacenamiento y cargas, capaz de operar tanto conectado a la red (*grid-connected*) como en modo isla (*islanded*). La norma IEEE 1547.4 define los requisitos para la operación de microrredes en baja y media tensión [28].

En una microrred para movilidad, los componentes típicos son: generación renovable (PV, eólico), almacenamiento a corto plazo (baterías), almacenamiento a largo plazo (hidrógeno), cargas controlables (electrolizador, compresor) y cargas no controlables (cargadores EV, demanda H2) [29]. La arquitectura concreta de OASIS (componentes, potencias y señales que intercambian con el EMS) se describe en el Capítulo 5 (Figura 5.2).

2.9.2 Estrategias de gestión energética (EMS)

El Sistema de Gestión de Energía (EMS, *Energy Management System*) es el componente de software que coordina todos los flujos de potencia en la microrred para minimizar el coste operacional (energía importada de la red), maximizar el autoconsumo renovable y garantizar la calidad de servicio (evitar cortes de carga) [30].

Las estrategias de EMS se clasifican en tres grandes categorías:

Estrategias reactivas o basadas en reglas (*rule-based*): toman decisiones en tiempo real en función de umbrales predefinidos del estado del sistema (nivel del tanque, SOC de la batería, excedente solar). Son deterministas, fáciles de implementar e interpretar, y robustas frente a incertidumbre. Su limitación principal es que, en su forma básica, no incorporan información predictiva y por tanto no pueden anticiparse a eventos futuros; la vía natural de mejora es enriquecer las reglas con previsiones de generación y demanda sin abandonar la estructura heurística [31]. Este trabajo parte de esa vía y mide cuánto aporta.

Estrategias de control predictivo basado en modelos (MPC, *Model Predictive Control*): formulan el problema de gestión como una optimización a horizonte deslizante, e incorporan predicciones de generación, precio y demanda para calcular la secuencia de acciones óptima [32]. Ofrecen una mejor calidad de solución que las estrategias reactivas a costa de mayor complejidad computacional y dependencia de la calidad de las predicciones.

Estrategias basadas en aprendizaje automático: utilizan técnicas de aprendizaje por refuerzo (RL, *Reinforcement Learning*) o redes neuronales para aprender políticas de control óptimas a partir de

experiencia histórica. La revisión de [33] sobre aplicaciones del aprendizaje por refuerzo en sistemas energéticos, que abarca 283 trabajos repartidos en siete categorías de aplicación, observa que predominan los métodos actor-crítico, que los métodos *batch* están infrautilizados pese a la disponibilidad de datos históricos y —lo más relevante para este trabajo— que la comparación sistemática frente a métodos competidores sigue siendo escasa. Son especialmente prometedoras en entornos con alta variabilidad e incertidumbre, pero requieren grandes volúmenes de datos y pueden presentar comportamientos imprevisibles en condiciones no vistas durante el entrenamiento.

En el presente trabajo la capa base es también una heurística de reglas, y las previsiones LSTM de irradiancia y precio entran como dato de una decisión con margen económico (cuándo producir hidrógeno) en lugar de disparar acciones de magnitud fija. Cuánto aporta cada pieza, previsión y reglas, se mide por separado en el Capítulo 6.

2.9.3 EMS en instalaciones multi-energía: revisión bibliográfica

[34] formulan la gestión de una microrred basada en hidrógeno con almacenamiento híbrido como un problema de control predictivo que maximiza el beneficio económico minimizando simultáneamente la degradación de los equipos de almacenamiento, modelando la dinámica continua y discreta mediante *mixed logic dynamics* y resolviendo el problema resultante como un MIQP. Es un antecedente directo del enfoque de este trabajo en dos sentidos: incorpora explícitamente el desgaste de los equipos como objetivo (y no solo el coste), y procede del mismo grupo de investigación que el modelo de partida. [35] revisan el estado de las estaciones de repostaje de hidrógeno y su infraestructura, y señalan que el coste de producción y compresión del hidrógeno sigue siendo el factor dominante en la viabilidad de estas instalaciones, lo que justifica que la decisión económica «producir localmente o comprar fuera» ocupe un lugar central en el EMS.

En cuanto a la integración conjunta de ambos vectores en una misma instalación, [5] proponen un marco de diseño de estación híbrida que atiende simultáneamente carga de vehículo eléctrico y repostaje de hidrógeno evaluando múltiples atributos de diseño, lo que confirma que el problema de coordinar ambos servicios bajo un único sistema de gestión sigue siendo una línea abierta.

2.10 Predicción de irradiancia solar con redes neuronales

La predicción de irradiancia solar a horizonte de 24 horas es un problema bien establecido en la literatura de aprendizaje automático aplicado a energías renovables. Las redes LSTM han demostrado ser especialmente eficaces en este dominio por su capacidad de capturar dependencias temporales a múltiples escalas [36].

[37] revisan los métodos de aprendizaje profundo aplicados a la predicción de carga eléctrica y de generación renovable en microrredes inteligentes, y sitúan las arquitecturas recurrentes —LSTM y GRU (*Gated Recurrent Unit*)— entre las que mejor capturan la dependencia temporal de estas series frente a los enfoques estadísticos clásicos y a las redes *feedforward*.

El uso de los productos de reanálisis NASA POWER como fuente de datos de irradiancia, en lugar de medidas en tierra, ha sido validado de forma independiente. [38] los contrastan contra 22 estaciones sinópticas a lo largo de 35 años de registro y obtienen coeficientes de correlación de 0,59 a 0,94, errores cuadráticos medios de 0,13 a 0,46 kWh/m²/día y errores porcentuales medios del 1,11% al 6,34%, con el mejor acuerdo en las zonas de menor actividad convectiva. Un error de esa magnitud es aceptable para una aplicación de EMS, donde a la predicción le basta con ser suficientemente buena para discriminar entre días soleados y nublados; hay que tenerlo presente, en todo caso, porque se suma al error del propio modelo de predicción.

2.11 Predicción del precio spot de electricidad

La predicción del precio horario de la electricidad en el mercado mayorista es un problema de complejidad elevada, caracterizado por: alta variabilidad, presencia de picos extremos (*price spikes*), régimen marcadamente no estacionario y fuerte dependencia de variables exógenas (demanda, mix de generación, precio del gas natural) [39].

Los modelos LSTM y sus variantes (BiLSTM, TCN, Transformer) han desplazado progresivamente a los modelos estadísticos clásicos (ARIMA, SARIMA) y econométricos (GARCH) en las aplicaciones de predicción de precio de electricidad, especialmente a partir de 2018. [40] realizan el benchmark más completo hasta la fecha y comparan 27 métodos diferentes sobre 8 mercados europeos: los modelos basados en redes neuronales profundas superan a los clásicos en 6 de los 8 mercados, con una reducción media del MAE del 12–28%.

La incorporación de variables meteorológicas (irradiancia, temperatura, viento) como features del modelo de precio es una práctica consolidada en el mercado español, donde la alta penetración renovable hace que el precio spot esté fuertemente correlacionado con la generación solar y eólica [41]. Esta es precisamente la estrategia seguida en el modelo LSTM de precio del Capítulo 4, que combina el precio histórico con variables meteorológicas NASA y el índice de capacidad FV instalada.

El problema de los precios negativos [42] merece mención específica: en el mercado OMIE, los precios negativos se producen cuando la generación renovable supera la demanda (habitualmente en horas nocturnas de alta eólica o festivos con alta solar). Estos episodios son difícilmente predecibles con modelos estadísticos y requieren tratamiento especial en el EMS: en lugar de intentar predecirlos con precisión, es más efectivo diseñar el EMS para ser oportunista (cargar baterías y producir hidrógeno cuando el precio cae por debajo de un umbral predefinido, independientemente de la predicción exacta).

2.12 Simulación de microrredes con Simulink/Simscape

La validación de sistemas de gestión de energía previo a su implantación real se realiza típicamente mediante simulación en herramientas como MATLAB/Simulink, Modelica/Dymola o HOMER [43]. Simulink, con su biblioteca Simscape Electrical, proporciona bloques de circuito para modelar buses AC/DC, inversores, baterías, electrolizadores y pilas de combustible con distintos niveles de fidelidad [44].

La plataforma utilizada en este trabajo, Simugrid, es un entorno de simulación de microrredes desarrollado específicamente para modelar sistemas de almacenamiento y gestión de energía en el contexto de la movilidad sostenible. Su característica diferencial es la integración nativa de bloques de S-Functions en MATLAB que permiten conectar modelos de aprendizaje automático (como los LSTM desarrollados en este trabajo) directamente con el bucle de simulación de Simulink, y posibilitan así la validación de estrategias de EMS que incorporan predicciones en tiempo real.

Simugrid es la librería complementaria del libro *Model Predictive Control of Microgrids* [45], de C. Bordons, F. García-Torres y M. A. Ridao (este último, tutor de este TFG), publicado por Springer Nature dentro de la serie *Advances in Industrial Control*. La librería, desarrollada en el Dpto. de Ingeniería Automática de la Universidad de Sevilla, proporciona los modelos matemáticos de batería, pila de combustible, electrolizador y generación renovable en los que se apoya el bloque OASIS empleado en este trabajo, así como ejemplos de controladores MPC.

2.13 Posicionamiento del presente trabajo

A la vista de la revisión bibliográfica anterior, el presente trabajo combina tres elementos que apenas se encuentran tratados de forma conjunta en la literatura revisada:

1. **Integración de múltiples vectores energéticos (EV + H2)** bajo un único EMS en una estación de repostaje de carretera, con generación fotovoltaica local.
2. **Medida de lo que aporta la predicción dentro de un EMS de reglas:** dos modelos LSTM de irradiancia solar y precio, validados frente a líneas base no triviales e integrados en el bucle de Simulink mediante S-Functions, y una cadena de medida (comparación pareada por semilla, oráculo, descomposición de la importación por destinos y ablación por componentes) que separa la mejora atribuible a la previsión de la atribuible al diseño de las reglas que la consumen.
3. **Validación simulada con perfiles de demanda EV basados en datos reales** (dataset DESL-EPFL Level 3 DC fast charging), en lugar de perfiles sintéticos simplificados.

La combinación de estos tres elementos, en el contexto de la arquitectura de la estación OASIS y el entorno de Sevilla (alta irradiancia, precio spot español), constituye la contribución de este trabajo. Su resultado principal —que en esta instalación el margen económico estaba en el orden en que se usa la batería, y no en predecir mejor un precio que el mercado diario ya publica— se desarrolla en el Capítulo 5 y el Capítulo 6.

3 Datos de carga EV y dimensionamiento de la estación

El diseño de una estación de repostaje multi-energía requiere datos reales de uso para justificar tanto la potencia de los cargadores como su número. En este capítulo se describe el dataset de demanda de vehículos eléctricos (EV) del que se parte y se justifica el dimensionamiento de la estación propuesta.

3.1 Dataset de referencia: DESL-EPFL

3.1.1 Descripción del dataset

Se ha utilizado el dataset **Level-3-EV-charging-dataset** publicado por el Laboratorio de Sistemas Eléctricos Distribuidos de la EPFL (DESL-EPFL) [46]. Sus características principales se resumen en la Tabla 3.1:

Propiedad	Valor
Tipo de cargador	Level 3 (DC fast), 172.5 kW máximo
Enchufes	5 (2×CCS, 1×CHAdemo, 1×Type 2, 1×Tesla DC)
Sesiones totales	1 878 registradas / 1 875 válidas
Período	Abril 2022 — Julio 2023 (≈15 meses)
Resolución temporal	1 minuto (medidas), sesión (resumen)
Ubicación	Suiza (zona CET/CEST)
Licencia	MIT

Tabla 3.1: Características principales del dataset DESL-EPFL

El dataset incluye dos archivos principales: **Session_data.xlsx** (1 878 sesiones con hora de llegada, salida, energía cargada, SOC de llegada y salida, y potencia máxima) y **Measurement_data.xlsx** (64 277 mediciones a 1 minuto de resolución con potencia, SOC y energía acumulada).

3.1.2 Distribución de llegadas

La Figura 3.1 muestra la distribución temporal de llegadas de los EV a lo largo del día. Se observa un patrón bimodal con picos sobre las 8:00 h (llegadas matutinas) y las 17:00-18:00 h (llegadas vespertinas), coherente con un uso de tipo público/urbano donde los usuarios cargan durante las horas de actividad diurna.




Figura 3.1: Distribución de llegadas de EV por hora del día. Dataset DESL-EPFL.

3.1.3 Energía por sesión

La Figura 3.2 muestra la distribución de energía cargada por sesión. La media es de 32.2 kWh y la mediana de 29.4 kWh, con un rango típico de 10-50 kWh. Este valor es menor que la capacidad completa de las baterías modernas (50-80 kWh), lo que indica que los usuarios no cargan al 100% en cada visita, sino que realizan recargas parciales.




Figura 3.2: Distribución de energía cargada por sesión. Media: 32.2 kWh, mediana: 29.4 kWh.

3.1.4 Estado de carga (SOC)

La Figura 3.3 representa los valores de SOC de llegada y salida. Los EV llegan con un SOC medio del 34% (rango típico 15-50%) y se van con un SOC medio del 79% (rango típico 65-95%). Esto confirma que la energía media transferida por sesión es de aproximadamente 45 puntos porcentuales de SOC, consistente con la energía observada.




Figura 3.3: Distribución del estado de carga (SOC) de llegada y salida.

3.2 Comparación Level 2 vs Level 3

3.2.1 Definición de niveles

La clasificación en niveles (*Level 1/2/3*) procede de la práctica norteamericana asociada a la norma SAE J1772 y es la que se emplea habitualmente en la literatura de datasets de recarga, incluidos los utilizados en este capítulo. No debe confundirse con los cuatro **modos** de carga que define la norma IEC 61851 (Capítulo 2), que es una taxonomía distinta y no equivalente: los modos describen el esquema de protección y comunicación del punto de recarga, no su nivel de potencia. La Tabla 3.2 resume las características de cada nivel en la clasificación por potencia.

Nivel	Tipo	Potencia	Tiempo de carga típico
Level 1	CA monofásica	1.4 — 1.9 kW	8 — 24 h
Level 2	CA trifásica	6 — 22 kW	2 — 8 h
Level 3	CC (DC fast)	50 — 350 kW	10 — 60 min

Tabla 3.2: Clasificación de cargadores de EV por nivel de potencia (convención SAE J1772).

3.2.2 Comparación con datos reales

Para comparar ambos niveles con medidas, y no con valores de catálogo, se han utilizado dos datasets públicos:

- **Caltech ACN-Data** (Level 2): ≈ 54 cargadores CA de 6.6 kW en el campus de Caltech, USA. 2 449 sesiones válidas de 2020 [47].
- **DESL-EPFL** (Level 3): 2 cargadores CCS de 172.5 kW en Suiza. De las 1 878 sesiones CCS registradas se descartaron 3 por energía nula o marcas de tiempo inconsistentes, de modo que quedan 1 875 sesiones válidas de abril 2022 a julio 2023 [46].

La Tabla 3.3 recoge las características de los dos niveles y la Tabla 3.4, las métricas medidas sobre esos datasets.

Característica	Level 2 (CA)	Level 3 (CC)
Tensión	208/240 V AC	200-1000 V DC
Corriente máxima	32-80 A	100-500 A
Potencia típica	6-22 kW	50-172.5 kW
Conector	Type 1 / Type 2	CCS / CHAdeMO / NACS
Uso típico	Residencial / workplace	Estación de servicio / corredor
Coste instalación	1 000-5 000 €	25 000-100 000 €
Impacto red	Bajo	Moderado-Alto

Tabla 3.3: Comparación entre cargadores Level 2 y Level 3.

Métrica	Level 2 (Caltech)	Level 3 (DESL-EPFL)
Potencia del cargador	≈6.6 kW	172.5 kW
Sesiones analizadas	2 449	1 875
Energía media por sesión	8.2 kWh	32.2 kWh
Energía mediana por sesión	5.5 kWh	29.4 kWh
Duración media	306 min (5.1 h)	33 min
Duración mediana	290 min (4.8 h)	30 min
Potencia media real	2.5 kW	62.4 kW
Sesiones/día	11.5	8.5

Tabla 3.4: Comparación de métricas reales entre Level 2 y Level 3, medidas sobre los datasets Caltech (Level 2) y DESL-EPFL (Level 3).

El Level 3 es 9.3 veces más rápido que el Level 2 para una sesión típica y entrega 3.9 veces más energía por sesión (32.2 kWh frente a 8.2 kWh). La causa es el caso de uso: en Level 2 el usuario deja el coche conectado toda la jornada laboral (parking de trabajo), mientras que en Level 3 espera cerca del vehículo y busca una recarga rápida. Los patrones de llegada lo confirman: el Level 2, en un campus universitario, tiene un único pico matutino (8-10 h) correspondiente a la llegada al trabajo, mientras que el Level 3 presenta el patrón bimodal de la Figura 3.1, con un máximo a las 8:00 y otro, más acusado, a las 17:00-18:00.

Ambos niveles difieren también en el perfil de potencia dentro de la sesión. En Level 2 la potencia es constante durante toda la sesión (curva rectangular); en Level 3 la batería sigue una curva CC-CV (*constant current — constant voltage*): carga a potencia constante hasta aproximadamente el 80 % de SOC y después la potencia decae exponencialmente hasta completar la carga [48]. La Figura 3.4 muestra la distribución de potencia media por sesión, con una media del Level 3 (≈62 kW) casi diez veces superior a la del Level 2 (≈6 kW). La Figura 3.5 muestra el efecto de la curva CC-CV: en Level 2 la relación entre energía y duración es lineal, mientras que en Level 3 aparece una dispersión mayor por el tramo CV y por la variabilidad de potencia que solicita cada modelo de EV.




Figura 3.4: Distribución de potencia media por sesión: Level 2 vs Level 3.




Figura 3.5: Relación energía vs duración: Level 2 (izq) vs Level 3 (der).

3.3 Justificación de la potencia del cargador (50 kW)

3.3.1 Criterio de selección de 50 kW

La potencia del cargador DC de la estación multi-energía se ha fijado en 50 kW según los siguientes criterios:

1. **Posicionamiento estratégico.** El rango de potencias DC comerciales se extiende desde 50 kW (carga rápida de entrada) hasta 350 kW (ultra-rápida). Los 50 kW equilibran coste, tiempo de espera y eficiencia de la red:
 - Frente a 22 kW (Level 2 máximo): 50 kW reduce el tiempo de carga en un factor $2.3\times$ y permite atender más usuarios por día.
 - Frente a 150+ kW (ultra-rápida): 50 kW evita la necesidad de transformadores de media tensión y reduce el coste de instalación en un factor $5\text{-}10\times$.
2. **Tiempo de carga competitivo.** Con la energía media observada en el dataset DESL-EPFL (32.2 kWh), un cargador de 50 kW completa la recarga en:

$$t = \frac{E}{P} = 32.2 \frac{\text{kWh}}{50} \text{ kW} = 0.644 \text{ h} \approx 39 \text{ min}$$

Ese tiempo no es comparable al de un repostaje convencional, ni al de un FCEV, que la propia estación resuelve en menos de cinco minutos. Sí es coherente, en cambio, con el uso real observado: la duración mediana de sesión en el dataset DESL-EPFL es de 30 minutos, es decir, los usuarios ya aceptan de hecho paradas de ese orden en estaciones de carga rápida. Para una recarga parcial típica de 20 kWh (del 30% al 70% de SOC), el tiempo baja además a 24 minutos.

3. **Alineación con la demanda real.** La Figura 3.4 muestra que la potencia media real en el dataset DESL-EPFL es de 62.4 kW, pero con una distribución amplia donde muchas sesiones operan por debajo de 50 kW (debido a la limitación de potencia del propio EV o a la fase CV de la curva de carga). La potencia mediana por sesión queda por debajo de los 50 kW, de modo que un cargador de esa potencia no limita a la mayoría de las sesiones observadas; las que sí exceden esa potencia se ven alargadas proporcionalmente, no impedidas.

4. **Impacto en la red eléctrica.** Un cargador de 50 kW demanda una corriente de aproximadamente 72 A a 400 V trifásica:

$$I = \frac{P}{\sqrt{3} \times V} = \frac{50000}{\sqrt{3} \times 400} \approx 72 \text{ A}$$

Esta corriente es gestionable con un transformador de distribución de baja tensión estándar (250 kVA), sin necesidad de infraestructura de media tensión. Cargas de 150+ kW requerirían transformadores dedicados y acometidas de media tensión, lo que incrementa el coste de instalación.

5. **Ratio de rotación.** Con una duración media de 39 min y 2 cargadores, la capacidad teórica máxima de la estación es:

$$\text{Capacidad} = 2 \text{ cargadores} \times 60 \frac{\text{min/h}}{39} \text{ min/sesión} \approx 3.1 \text{ sesiones/h}$$

En un horario de operación de 14 h (8:00-22:00), esto da una capacidad teórica de ≈ 43 sesiones/día. Sin embargo, la demanda real observada en el dataset es de 8-9 sesiones/día, lo que implica una utilización del $\approx 20\%$. Este margen permite absorber picos de demanda sin tiempos de espera excesivos.

6. **Escalabilidad y futuro.** 50 kW es una potencia que permite cargos de 10% a 80% SOC en la mayoría de EVs modernos (baterías de 40-80 kWh) en un tiempo razonable. A medida que la flota de EVs evolucione hacia baterías de mayor capacidad, los cargadores de 50 kW seguirán cubriendo recargas parciales como la de 20 kWh en 24 minutos calculada más arriba.

3.3.2 Comparación con alternativas

La Tabla 3.5 compara las opciones de potencia consideradas.

Potencia	Tipo	Tiempo (32.2 kWh)	Capacidad teórica/día	Coste aprox.
22 kW	Level 2	≈1 h 28 min	≈19	2 000-5 000 €
50 kW	DC fast	≈39 min	≈43	25 000-40 000 €
150 kW	DC fast	≈13 min	≈130	80 000-120 000 €
350 kW	Ultra-rápida	≈5.5 min	≈304	150 000-250 000 €

Tabla 3.5: Comparación de opciones de potencia para el cargador DC. Tiempo calculado con $t = \frac{E}{P}$ y la energía media del dataset (32.2 kWh) para las cuatro potencias, de forma consistente con el cálculo de la sección anterior. Capacidad teórica máxima con 2 cargadores operando 14 h (8:00-22:00) sin tiempos muertos entre sesiones — un límite superior, no la demanda esperada.

Los 50 kW son la opción preferible para una estación de tamaño pequeño/medio: ofrecen un tiempo de carga competitivo (39 min) con un coste de instalación razonable (25 000-40 000 €), sin requerir infraestructura de media tensión. Alternativas de mayor potencia (150-350 kW) solo se justifican en estaciones de alto tráfico (corredores de alta velocidad, gasolineras de alto volumen) donde el ratio de rotación es crítico; la capacidad teórica de ≈43 sesiones/día a 50 kW queda muy por encima de la demanda real observada (8-9/día, Tabla 3.7) y no llega a ser una limitación.

3.3.3 Validación con el dataset

La Figura 3.6 muestra que la mayoría de las sesiones en el dataset DESL-EPFL duran entre 20 y 45 minutos, lo que es consistente con el tiempo de carga a 50 kW calculado anteriormente. Las sesiones muy cortas (< 15 min) corresponden a recargas parciales de EVs que ya tenían un SOC alto, y las sesiones muy largas (>60 min) representan vehículos que permanecieron conectados más tiempo del necesario.




Figura 3.6: Distribución de duración de sesiones en DESL-EPFL. Media: 33 min, mediana: 30 min.

3.4 Dimensionamiento de la estación

3.4.1 Número de cargadores EV

Un primer acercamiento consistiría en fijar el número de cargadores igual al del dataset de referencia (DESL-EPFL cuenta con 2 puntos CCS). Sin embargo, ese razonamiento es circular: el dataset tiene 2 cargadores porque así se instalaron en Suiza, no porque 2 sea el número que la demanda de este

trabajo requiere. El número de cargadores se dimensiona aquí mediante un análisis de teoría de colas (modelo M/M/c) sobre la tasa de llegadas real observada en el dataset.

Tasa de llegadas en hora punta. La distribución horaria de llegadas del dataset (Figura 3.1) tiene su máximo a las 18:00, con una probabilidad de 8.32 % de las llegadas diarias. Con una media global de 8.48 sesiones/día, esto da una tasa de llegadas en la hora más cargada de:

$$\lambda_{\text{pico}} = 8.48 \times 0.0832 \approx 0.71 \text{ EV/h}$$

Tiempo de servicio. Con la energía media del dataset (32.2 kWh) y un cargador de 50 kW, el tiempo medio de sesión es $t = \frac{32.2}{50} \approx 38.7 \text{ min}$, es decir $\mu \approx 1.55$ servicios/hora por cargador.

Comparación M/M/c. La Tabla 3.6 compara el tiempo de espera medio en cola (fórmula de Erlang C) para distintos números de cargadores en la hora punta.

Cargadores (c)	Ocupación (ρ)	Espera media en cola
1	45.5 %	$\approx 32.3 \text{ min}$
2	22.8 %	$\approx 2.1 \text{ min}$
3	15.2 %	$\approx 0.2 \text{ min}$

Tabla 3.6: Espera media en cola en la hora punta (18:00) según el número de cargadores, modelo M/M/c con $\lambda = 0.71 \text{ EV/h}$ y $\mu = 1.55$ servicios/h.




Figura 3.7: Espera media en cola W_q (Erlang C) frente al número de cargadores, para $\lambda = 0.71 \text{ EV/h}$ y $\mu = 1.55$ servicios/h. El salto entre $c = 1$ y $c = 2$ (de $\approx 33 \text{ min}$ a $\approx 2 \text{ min}$) sustenta la elección de 2 cargadores; a partir de $c = 3$ la mejora es marginal.

Con un solo cargador, un usuario que llega en hora punta espera de media más de media hora: un tiempo inaceptable para una parada de repostaje en carretera, donde la propuesta de valor frente a un FCEV o una gasolinera es precisamente la rapidez. Pasar a 2 cargadores reduce la espera media a poco más de 2 minutos, una mejora de un orden de magnitud. Un tercer cargador solo aportaría 2 minutos adicionales de mejora, a cambio de duplicar la inversión en electrónica de potencia y ocupar más espacio en la parcela. Se adoptan por tanto 2 cargadores, el punto donde la mejora marginal en calidad de servicio deja de justificar el coste adicional.

Tabla 3.7 resume el resultado junto con los datos de partida.

Parámetro	Valor
Sesiones/día (laborable, DESL-EPFL)	8.3
Sesiones/día (fin de semana, DESL-EPFL)	9.1
Llegadas en hora punta (18:00)	≈ 0.71 EV/h
Potencia del cargador	50 kW
Duración media por sesión a 50 kW	≈ 39 min
Espera media en cola, $c=1$	≈ 32.3 min
Espera media en cola, $c=2$	≈ 2.1 min
Número de cargadores EV dimensionados	2
Capacidad diaria estimada (lab)	≈ 8 sesiones
Capacidad diaria estimada (finde)	≈ 9 sesiones

Tabla 3.7: Dimensionamiento de cargadores EV, basado en el análisis de colas de la Tabla 3.6.

El sistema de colas FIFO implementado en la generación de perfiles de demanda (Capítulo 3) es coherente con este análisis: modela explícitamente la espera cuando ambos cargadores están ocupados, en vez de asumir disponibilidad instantánea.

La demanda de 8-9 sesiones/día es representativa de una estación de servicio de carretera de tamaño pequeño/medio en Europa. El dataset DESL-EPFL, aunque capturado en Suiza, refleja un uso público/urbano con penetración de EV alta, lo que produce una demanda conservadora (no excesiva) para un emplazamiento de autopista en España donde la penetración de EV es actualmente menor. El análisis de colas anterior usa esta tasa de llegadas como referencia de partida: las 8-9 sesiones/día observadas suponen una utilización del $\approx 20\%$ de la capacidad teórica, y conviene repetir el análisis con una tasa de llegadas actualizada si la flota de EVs crece de forma significativa.

3.4.2 Número de surtidores de hidrógeno

El surtidor de hidrógeno se ha dimensionado con 1 módulo de repostaje a 1.2 kg/min (72 kg/h). Considerando que un Toyota Mirai alberga aproximadamente 5.6 kg de H_2 a 700 bar, un repostaje completo dura unos 4.7 minutos. En condiciones ideales de operación continua (sin tiempos de maniobra ni conexión), la estación podría atender hasta 10-12 vehículos/hora. Esa capacidad de dispensación es sobradamente suficiente para la flota FCEV actual; el surtidor no es el cuello de botella de la estación: lo son, como se muestra a continuación, la producción y el almacenamiento.

Esta capacidad de dispensación no debe confundirse con la capacidad de producción. El electrolizador de OASIS (200 kW, ≈ 50 kWh/kg, Capítulo 2) produce como máximo:

$$\dot{m}_{H_2, \max} = 200 \frac{\text{kW}}{50} \text{ kWh/kg} = 4 \text{ kg/h}$$

es decir, 18 veces menos que el caudal de dispensación (72 kg/h). Un único repostaje completo (5.6 kg) que se dispensa en menos de 5 minutos necesita después 1 h 24 min de electrolizador funcionando a máxima potencia para reponerse:

$$t_{\text{reposición}} = 5.6 \frac{\text{kg}}{4} \text{ kg/h} \approx 1.4 \text{ h}$$

Esta asimetría no es necesariamente un problema si la demanda de FCEV es tan esporádica como se asume, pero afirmarlo requiere un balance explícito de producción, consumo y almacenamiento,

y no solo la observación de que la flota es pequeña. Ese balance se plantea a continuación con los parámetros de OASIS.

Término de producción. Con los parámetros del generador de perfiles de este capítulo (entre 4 y 8 FCEV al día y entre 3 y 5 kg por repostaje), la demanda diaria de hidrógeno se sitúa entre 12 y 40 kg/día. A un caudal máximo de 4 kg/h, el electrolizador necesita entre 3 y 10 horas a plena potencia (200 kW) solo para reponer el consumo del día, lo que equivale a un consumo eléctrico de 600 a 2000 kWh diarios dedicados en exclusiva a hidrógeno. Sobre un generador fotovoltaico de ≈ 500 kWp en Sevilla (Capítulo 2), cuya producción diaria es del orden de 2-3 MWh, el extremo alto de ese rango absorbe la mayor parte del recurso solar disponible y compite directamente con la carga de los vehículos eléctricos y con la recarga de la batería. Además, la ventana útil de excedente fotovoltaico, del orden de 5 a 7 horas en torno al mediodía, es más corta que las 10 h que exigiría el escenario de 40 kg/día, por lo que en ese caso parte de la producción tendría que hacerse forzosamente con energía de red, y la decisión económica «producir localmente o no cubrir el déficit» descrita en Metodología pasa a ser determinante.

Término de almacenamiento. La instalación almacena hidrógeno en dos etapas (Capítulo 2): un tanque tampón de baja presión de 3,1 m³ hasta 40 bar, que contiene del orden de 10 kg cuando está lleno, y el tanque de alta de 0,41 m³, que con las densidades de gas real recogidas en Capítulo 2 almacenaría unos 14,2 kg a los 600 bar con los que está parametrizado el modelo. El primer dato relevante es que el grueso de la reserva está en el tanque de baja, no en el de alta: el de alta es un depósito de dispensación, no un almacén.

El segundo es que la franja realmente utilizable del tanque de alta es estrecha. Los umbrales del EMS lo mantienen entre su nivel crítico (72 %) y su techo de seguridad (97 %), y esos porcentajes son fracciones de presión (Capítulo 5): sobre 600 bar equivalen a operar entre 432 y 582 bar, es decir, entre unos 11,0 y 14,0 kg de gas real. Quedan por tanto del orden de 3 kg de hidrógeno disponibles antes de tocar el nivel crítico, menos que un único repostaje completo de un Toyota Mirai (5,6 kg). Basta con que un solo vehículo llegue con el depósito vacío para llevar LOH_High por debajo del umbral crítico. El tanque de alta no actúa, en consecuencia, como colchón entre repostajes consecutivos: la continuidad del servicio depende en tiempo real de la cadena tanque de baja → compresor → electrolizador, y el tiempo de reposición relevante no es el de llenar un tanque vacío sino el de recuperar la franja de operación tras cada evento.

Debe tenerse presente al leer los resultados que los bloques de tanque del modelo emplean la ecuación de los gases ideales (Capítulo 2), que a estas presiones sobrestima la masa almacenada en torno a un 50 %. Las cifras de este balance, calculadas con densidades de gas real, son por tanto más exigentes que las que producirá la simulación: si el nivel del tanque de alta ya resulta ajustado en simulación, en una instalación real lo sería más.

De este balance se derivan dos consecuencias que condicionan la lectura del capítulo de Resultados. La primera es que es esperable que LOH_High cruce el nivel crítico tras cada evento de demanda de H₂ significativo: el indicador de porcentaje de tiempo en nivel crítico definido en Metodología medirá sobre todo la velocidad de recuperación del sistema y la capacidad del EMS para anticiparse, no la ausencia de incidencias. La segunda es que el dimensionamiento actual (200 kW de electrolizador, 3,1 m³ de tanque tampón y 0,41 m³ de tanque de alta, con una reserva conjunta del orden de 24 kg frente a una demanda diaria de 12 a 40 kg) queda acotado al escenario de baja demanda que aquí se simula: en el extremo alto del rango, la estación dispone de menos de un día de autonomía. Extrapolar a una flota FCEV más densa exige un estudio de sensibilidad conjunto sobre los volúmenes de ambos tanques y la potencia del electrolizador, que queda como línea de trabajo futura.

3.5 Generación de perfiles de demanda

3.5.1 Metodología

A partir del dataset DESL-EPFL se extrajeron las distribuciones mostradas en las Figura 3.1, Figura 3.2 y Figura 3.3. Estas distribuciones se utilizaron como entradas del generador de perfiles de demanda (`Demanda_Coches_Aleatoria.m`), que implementa:

1. **Muestreo de llegadas.** La hora de llegada de cada EV se muestrea de la distribución empírica del dataset, en vez de una distribución uniforme.
2. **Muestreo de energía.** La energía necesaria por cada EV se muestrea de la distribución real (media: 32.2 kWh), no de un rango arbitrario.
3. **Cálculo de duración.** La duración de cada sesión se calcula dividiendo la energía muestreada entre la potencia del cargador (50 kW), y la potencia instantánea sigue la curva CC-CV.
4. **Sistema de colas FIFO.** Cada cargador se modela como un servidor en un sistema de colas. Si todos los cargadores están ocupados, el EV espera hasta que se libere uno. Esto produce perfiles de demanda temporalmente coherentes.

3.5.2 Escalado

El análisis de colas de la Capítulo 3.4.1 concluye de forma independiente que la estación necesita 2 cargadores, y ese número coincide con el de la instalación de la que procede el dataset. Por tanto, el factor de escala es 1 y no es necesario ajustar el número de sesiones diarias. En caso de evaluar un dimensionamiento diferente (por ejemplo, 4 cargadores), el generador permite configurar `N_postes_EV` y aplica un factor de escala lineal sobre el número de sesiones; las distribuciones horarias y de energía se mantienen invariables.

3.5.3 Resultados

La Figura 3.8 muestra la distribución de sesiones por día de la semana en el dataset. Se observa que los fines de semana tienen una demanda ligeramente superior (9.1 sesiones/día) respecto a los laborables (8.3 sesiones/día), lo que es coherente con un uso de tipo público/ocio, en el que el usuario dispone de más margen horario.




Figura 3.8: Sesiones por día de la semana. Laborables en azul, fines de semana en rojo.

La Figura 3.9 muestra un ejemplo de perfil de potencia demandada por los cargadores EV a lo largo de 24 horas en un día laborable. Se aprecian los pulsos individuales de carga con la forma característica

de la curva CC-CV: fase de potencia constante (50 kW) seguida de un decaimiento exponencial. Cuando ambos cargadores están activos simultáneamente, la potencia total alcanza 100 kW.




Figura 3.9: Perfil de potencia demandada por los cargadores EV (modo laborable). Cada pulso corresponde a una sesión de carga con curva CC-CV.

3.5.4 Descripción del proceso de generación

El generador de perfiles de demanda (`Demanda_Coches_Aleatoria.m`) produce dos archivos `.mat` conteniendo timeseries de 24 horas con resolución de 1 segundo: uno para cargadores EV y otro para el surtidor de hidrógeno. Cada archivo contiene perfiles para modo laborable y fin de semana. A continuación se describe el proceso completo.

1. Muestreo de parámetros por sesión.

Para cada EV que llega a la estación, se muestrean los siguientes parámetros de las distribuciones empíricas del dataset DESL-EPFL:

- **Hora de llegada:** se extrae de la distribución de llegadas por hora (ponderada por probabilidad), con un minuto aleatorio dentro de esa hora. Esto reproduce el patrón bimodal real de llegadas, con picos a primera hora de la mañana y a última hora de la tarde (Figura 3.1).
- **Energía necesaria:** se muestrea de la lista de energías reales del dataset (media: 32.2 kWh, mediana: 29.4 kWh). No se asume una distribución paramétrica.
- **SOC de llegada:** se muestrea de la distribución de SOC reales (media: 33.7%), limitado al rango 5-90% para evitar valores extremos.
- **Capacidad de batería:** se asigna aleatoriamente entre 50 y 80 kWh, un rango que representa la variedad de vehículos del mercado actual.
- **SOC de salida:** se calcula como $\text{SOC}_{\text{ini}} + \left(\frac{E}{C_{\text{bat}}} \right) \times 100$, limitado al 95%.

2. Sistema de colas FIFO.

Una vez muestreados los parámetros de todos los EVs del día, se aplica un sistema de colas FIFO con N servidores en paralelo (por defecto $N = 2$):

- Los EVs se ordenan por hora de llegada.
- Cada EV se asigna al cargador que se libere antes.
- Si todos los cargadores están ocupados, el EV espera en cola.
- El tiempo de inicio real es $\max(t_{\text{llegada}}, t_{\text{libre}})$.
- La salida se produce al completar la carga.

Este sistema produce perfiles de demanda temporalmente coherentes: en horas pico puede haber 2 EVs simultáneos (con 2 cargadores), y en horas valle puede haber 0. El análisis de esperas permite evaluar la calidad de servicio.

3. Curva de carga CC-CV.

La potencia instantánea de cada cargador se modela con una curva CC-CV (Corriente Constante - Voltaje Constante), que es el perfil real de carga de las baterías de litio:

- **Fase CC:** potencia constante de 50 kW hasta que la batería alcanza el 80% de SOC. Esta fase representa la mayor parte de la energía entregada.
- **Fase CV:** decaimiento exponencial de la potencia con constante de tiempo $\tau = \frac{t_{total} - t_{CC}}{3}$. La potencia sigue la ley $P(t) = P_{max} \times e^{-\frac{t - t_{CC}}{\tau}}$.

La duración total de la sesión se resuelve por bisección para que la integral de la curva CC-CV iguale la energía necesaria muestreada.

4. Generación de demanda H₂.

El perfil de hidrógeno se genera con el mismo procedimiento que EV pero con simplificaciones debidas a la ausencia de datasets públicos de sesiones de repostaje FCEV:

- **Número de FCEV:** entre 4 y 8 (configurable), determinado aleatoriamente.
- **Hora de llegada:** se muestrea de la misma distribución bimodal que los EV (DESL-EPFL), ya que los FCEV siguen patrones de desplazamiento similares. Si no hay datos disponibles, se usa una distribución uniforme entre 7:00 y 21:00 como fallback.
- **Cantidad de H₂:** entre 3 y 5 kg por repostaje (estimado para un Toyota Mirai con tanque de 5.6 kg).
- **Duración:** calculada como $\frac{\text{kg}}{\text{caudal}}$ con caudal de 1.2 kg/min (0.02 kg/s).
- **Cola FIFO:** igual que para EV, con 1 surtidor.

El vector resultante almacena el caudal instantáneo en kg/s (0.02 kg/s por vehículo activo). La limitación principal es la ausencia de un dataset de referencia para llegadas FCEV; la distribución bimodal heredada de los EV es una aproximación razonable pero debe validarse con datos de ElaadNL u otras fuentes cuando estén disponibles.

3.6 Limitaciones del dataset

El dataset DESL-EPFL presenta dos limitaciones que deben tenerse en cuenta al interpretar los resultados:

En primer lugar, corresponde a una única estación en Suiza, con patrones de movilidad y penetración de EV propios de Europa central que pueden diferir del contexto español. Los horarios de actividad en España son generalmente más tardíos (comidas sobre las 14:00-15:00 h, cierre de jornada sobre las 19:00-20:00 h) frente a los patrones más concentrados en la mañana y primera tarde que muestra el dataset. Esto no invalida el trabajo, pero los resultados deben interpretarse como una aproximación al comportamiento esperable en el emplazamiento real.

En segundo lugar, el perfil de hidrógeno se genera sin datos reales de sesiones de repostaje FCEV, al no existir datasets públicos disponibles para este tipo de vehículo. Las llegadas se modelan con la misma distribución bimodal que los EV como aproximación razonable, dado que ambos tipos de vehículo siguen patrones de desplazamiento similares. Esta aproximación debe validarse con datos de ElaadNL u otras fuentes cuando estén disponibles.

3.7 Referencias de datos

El dataset DESL-EPFL está disponible en <https://github.com/DESL-EPFL/Level-3-EV-charging-dataset> bajo licencia MIT. Las distribuciones extraídas se encuentran en `codigo/data/desl_epfl/` y son utilizadas por el script `Demanda_Coches_Aleatoria.m` para generar perfiles de demanda realistas en cada ejecución de la simulación.

4 Modelos de predicción basados en redes LSTM

Los sistemas de gestión de energía proactivos requieren predicciones fiables de las variables que más influyen en la operación de la estación: la irradiancia solar —que determina la generación fotovoltaica— y el precio horario de la electricidad en el mercado spot (que condiciona cuándo conviene comprar de la red o producir hidrógeno). En este capítulo se describen los dos modelos de redes neuronales recurrentes de tipo LSTM (*Long Short-Term Memory*) desarrollados para cubrir ambas necesidades: el modelo solar, entrenado con datos meteorológicos del satélite NASA POWER, y el modelo de precio, entrenado con datos históricos del mercado ENTSO-E junto con variables meteorológicas y temporales.

Ambos modelos se integran en la simulación Simulink mediante *S-Functions* de MATLAB que se ejecutan en tiempo real durante la simulación, actualizan su predicción cada hora y entregan un vector de 24 valores que cubre el horizonte del día siguiente.

4.1 Fundamentos de las redes LSTM

Las redes neuronales recurrentes (RNN) son una familia de arquitecturas diseñadas para procesar secuencias de datos con dependencias temporales. A diferencia de las redes *feedforward* convencionales, las RNN mantienen un estado interno (memoria) que se actualiza en cada paso de tiempo y permite capturar patrones de largo alcance en series temporales.

Las LSTM [49] son una variante especialmente diseñada para evitar el problema del desvanecimiento del gradiente (*vanishing gradient*), que limita la capacidad de las RNN estándar para aprender dependencias a largo plazo. La célula LSTM incorpora tres puertas (*gates*) que regulan el flujo de información:

- **Puerta de olvido** (f_t): decide qué información del estado de la célula anterior se descarta.
- **Puerta de entrada** (i_t): decide qué información nueva se almacena en el estado de la célula.
- **Puerta de salida** (o_t): decide qué parte del estado de la célula se expone como salida.

Las ecuaciones que gobiernan una célula LSTM son:

$$\begin{aligned}f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f) \\i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i) \\\tilde{C}_t &= \tanh(W_C[h_{t-1}, x_t] + b_C) \\C_t &= f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \\o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o) \\h_t &= o_t \cdot \tanh(C_t)\end{aligned}$$

donde x_t es el vector de entrada en el instante t , h_t es el estado oculto, C_t es el estado de la célula, y W_* , b_* son los pesos y sesgos aprendidos durante el entrenamiento.

En el presente trabajo se utiliza una arquitectura de dos capas LSTM apiladas, con una capa totalmente conectada al final que colapsa el estado oculto en el vector de salida de 24 valores. Esta configuración permite al modelo capturar tanto patrones de corto plazo (variaciones hora a hora) como ciclos más lentos (día/semana/estacionalidad).

4.2 Modelo LSTM solar: predicción de irradiancia

4.2.1 Datos de entrada y fuente

El modelo solar predice las 24 horas siguientes de irradiancia horizontal global (*ALLSKY Surface SW Down*, en Wh/m²), que es la variable que determina la potencia fotovoltaica generada. Los datos de entrenamiento provienen del servicio NASA POWER (*Prediction Of Worldwide Energy Resource*), que proporciona datos meteorológicos horarios basados en análisis de reanálisis atmosférico y observaciones satelitales [50].

Se han descargado datos horarios para la ubicación de Sevilla (latitud 37.39°N, longitud 5.99°W) correspondientes al período 2007–2025, es decir, 19 años de registro.

Las variables empleadas como entrada (*features*) al modelo son las siguientes:

Feature	Descripción	Normalización
ALLSKY	Irradiancia horizontal global (Wh/m ²)	Min-Max → [0, 1]
RH2M	Humedad relativa a 2 m (%)	Min-Max → [0, 1]
PS	Presión superficial (kPa)	Min-Max → [0, 1]
cloud_idx	Índice de nubosidad: $1 - \frac{ALLSKY}{CLRSKY}$	Calculada, ∈ [0, 1]
hora_sin	$\sin\left(2\pi \cdot \frac{h}{24}\right)$	Codificación cíclica
hora_cos	$\cos\left(2\pi \cdot \frac{h}{24}\right)$	Codificación cíclica
dia_sin	$\sin\left(2\pi \cdot \frac{d_{año}}{365}\right)$	Codificación cíclica
dia_cos	$\cos\left(2\pi \cdot \frac{d_{año}}{365}\right)$	Codificación cíclica

Tabla 4.1: Features de entrada al modelo LSTM solar (8 variables).

La codificación cíclica (*circular encoding*) se emplea para representar variables periódicas como la hora del día y el día del año de forma que el modelo perciba correctamente la continuidad entre el último y el primer valor del ciclo (por ejemplo, que las 23:00 es adyacente a las 00:00). Es una técnica estándar de preprocesado en predicción de series temporales con estacionalidad conocida.

El índice de nubosidad se calcula como la fracción de irradiancia bloqueada respecto al cielo despejado: si $CLRSKY > 10$ Wh/m², entonces $cloud_idx = 1 - \frac{ALLSKY}{CLRSKY}$, con saturación en [0, 1]. Este índice resume en un único valor el estado de la nubosidad instantánea.

4.2.2 Arquitectura y entrenamiento

El modelo se construye con una arquitectura LSTM de dos capas apiladas seguida de dos capas totalmente conectadas:

Capa	Tipo	Unidades / Parámetro
1	sequenceInputLayer	8 features
2	lstmLayer (OutputMode: sequence)	128 unidades
3	dropoutLayer	20%
4	lstmLayer (OutputMode: last)	64 unidades
5	dropoutLayer	20%
6	fullyConnectedLayer	64 neuronas
7	reluLayer	—
8	fullyConnectedLayer	24 neuronas (salida)
9	reluLayer	—
10	regressionLayer	—

Tabla 4.2: Arquitectura de la red LSTM solar.

La primera capa LSTM opera en modo *sequence* para pasar el estado oculto a cada paso de tiempo a la segunda capa, mientras que la segunda opera en modo *last* para comprimir toda la secuencia en un único vector de estado. Las capas de *dropout* (20%) se añaden entre ambas LSTM para reducir el sobreajuste. La capa final de activación rectificada (*reluLayer*) tras la salida de 24 valores impone por construcción que la irradiancia predicha no sea negativa, una restricción física que el modelo de precio no puede adoptar (el precio spot sí admite valores negativos) y que explica por qué en aquel caso hace falta el mecanismo de recorte descrito en Capítulo 4.3.7.

La red se entrena con los siguientes hiperparámetros:

Hiperparámetro	Valor
Optimizador	Adam
Tasa de aprendizaje inicial	0.001
Descenso de tasa (factor / periodo)	0.3 / cada 80 épocas
Máximo de épocas	300
Tamaño de mini-lote	64
Umbral de gradiente	1.0
Paciencia de validación	20 épocas
Ventana de historia (<i>lookback</i>)	48 h
Horizonte de predicción	24 h
División train/val/test	80% / 10% / 10% cronológico
RMSE de validación (escala normalizada)	0,27761
Época de parada	21 de 300 (criterio de validación)

Tabla 4.3: Hiperparámetros de entrenamiento del modelo LSTM solar.

La división 80/10/10 se realiza de forma cronológica, no aleatoria: las secuencias se reparten en bloques consecutivos en el tiempo, de modo que el modelo nunca ve datos posteriores a los de evaluación. Sobre las 166 465 secuencias disponibles, el conjunto de test resultante cubre del 5 de

febrero de 2024 al 30 de diciembre de 2025, por lo que el año 2025 (el que se emplea en la campaña de simulación) queda íntegramente fuera del entrenamiento.

El entrenamiento se realiza con aceleración GPU mediante CUDA y se detiene por criterio de validación en la época 21 de 300, con un RMSE de validación de 0,27761 en la escala normalizada. La Figura 4.1 muestra que el error cae en las primeras iteraciones y que, a partir de ahí, las curvas de entrenamiento y validación se mantienen superpuestas en torno a ese valor sin separarse.




Figura 4.1: Curva de entrenamiento del modelo LSTM solar: evolución del error cuadrático medio en entrenamiento y validación a lo largo de las épocas.

4.2.3 Resultados de validación

La Figura 4.2 muestra la predicción del modelo para el primer paso del horizonte ($h+1$) durante una semana del conjunto de test, comparada con los valores reales de irradiancia. La Figura 4.3 muestra un ejemplo de predicción completa a 24 horas para un día individual.




Figura 4.2: Predicción LSTM solar ($h+1$) vs. irradiancia real ALLSKY durante una semana del conjunto de test (Sevilla, NASA POWER).




Figura 4.3: Predicción LSTM solar completa a 24 horas para un día de test. Cada punto corresponde a un horizonte $h+1$, $h+2$, ..., $h+24$.

Horizonte	MAE (Wh/m ²)	RMSE (Wh/m ²)	R ²
$h+1$	16,89	31,70	—
$h+6$	32,06	60,49	—
$h+12$	30,53	62,92	—
$h+24$	32,43	67,31	—
Global ($h+1 \dots h+24$)	30,19	61,08	0,955
Global, sólo horas de día	59,38	—	—

Tabla 4.4: Métricas de validación del modelo LSTM solar por horizonte, sobre el conjunto de test (05-feb-2024 a 30-dic-2025, 16 647 secuencias).

El error no crece de forma monótona con el horizonte: $h+12$ (30,53 Wh/m²) es menor que $h+6$ (32,06). Esto sucede porque en una serie con un ciclo diario tan marcado el error depende sobre todo de la posición del instante predicho dentro del día, y no solo de su distancia al instante de emisión: al repartirse los instantes de emisión por las 24 horas, cada horizonte mezcla objetivos diurnos y nocturnos en proporciones distintas.

El 49,3 % de las horas del horizonte de predicción corresponden a horas nocturnas, en las que la irradiancia es nula y cualquier modelo acierta. Por ello se reporta también el MAE restringido a horas de día, que es el doble del global: 59,38 Wh/m² frente a una irradiancia media diurna de 415 Wh/m², es decir un error relativo del 14,3 %. Esta es la cifra comparable con la literatura de predicción de irradiancia; el MAE global de 30,19 Wh/m² está diluido por las noches y no debe interpretarse de forma aislada.

4.2.4 Evaluación frente a líneas base

El coeficiente de determinación de la irradiancia está dominado por el ciclo día/noche, y por tanto un valor elevado no acredita por sí mismo capacidad predictiva. Para dimensionar el resultado se comparan dos referencias clásicas, evaluadas sobre las mismas secuencias de test:

- **Persistencia lag-24:** repetir las 24 últimas horas observadas.
- **Persistencia de cielo claro** (*smart persistence*): índice de cielo claro de las últimas 24 h, $k_t = \sum \text{ALLSKY} / \sum \text{CLRSKY}$, aplicado a la curva de cielo claro del día siguiente. Al ser CLRSKY una magnitud puramente geométrica, su valor futuro es conocido de antemano. Es la referencia habitual en predicción de irradiancia [36].

Modelo	MAE (Wh/m ²)	MAE diurno	R ²
LSTM	30,19	59,38	0,955
Persistencia lag-24	33,59	66,23	0,924
Persistencia de cielo claro	27,74	54,71	0,945
Sólo el ciclo día/noche	—	—	0,891

Tabla 4.5: Comparación del modelo LSTM solar con las líneas base, sobre el mismo conjunto de test. La última fila corresponde a una curva de cielo claro escalada por una constante, un modelo que no incorpora ninguna información meteorológica.

Una curva de cielo claro escalada por una constante, sin información meteorológica alguna, alcanza ya $R^2 = 0,891$, y la persistencia de cielo claro llega a 0,945 frente a los 0,955 del modelo LSTM (Tabla 4.5). En consecuencia, el R^2 no se emplea aquí como argumento de calidad: la métrica relevante es la mejora relativa frente a la línea base (*skill*).

En el promedio de las 24 horas del horizonte, el modelo mejora un 10,1 % a la persistencia lag-24 pero queda un 8,8 % por debajo de la persistencia de cielo claro. Ese promedio, sin embargo, oculta un comportamiento fuertemente dependiente del horizonte:

Horizonte	LSTM	Cielo claro	Skill
h+1	16,89	19,72	+14,4 %
h+2	17,09	22,15	+22,8 %
h+3	21,65	24,17	+10,4 %
h+4	25,30	25,76	+1,8 %
h+5	29,79	26,94	-10,6 %
h+6	32,06	27,74	-15,6 %
Media h+1...h+3	18,54	22,01	+15,8 %

Tabla 4.6: MAE (Wh/m²) del modelo LSTM solar frente a la persistencia de cielo claro por horizonte, y mejora relativa. El modelo aporta información hasta h+4 y a partir de h+5 es superado por la línea base.

El modelo bate a la línea base en las cuatro primeras horas del horizonte y es superado a partir de la quinta. Este resultado acota el tramo del horizonte útil para el EMS de la Versión B (Capítulo 5), que promedia únicamente las primeras horas del vector de previsión: sobre las tres primeras la mejora es del 15,8 %, mientras que extenderlo a seis horas la reduciría al 2,5 %. Este análisis por horizonte se ha realizado sobre el conjunto de test; el valor definitivo de N_PV_H se fija sobre el conjunto de validación (apartado siguiente).

El comportamiento por tipo de día completa la interpretación. Sobre los cuatro días empleados en la campaña de simulación:

Día	Irradiancia (Wh/m ² ·día)	MAE LSTM	MAE cielo claro
2 jul (despejado)	8 163	22,59	6,04
17 sep (despejado)	6 017	13,78	0,99
13 jul (despejado tras día nuboso)	8 324	37,20	107,05
11 feb (nublado)	1 451	53,67	75,13

Tabla 4.7: MAE (Wh/m²) del modelo LSTM solar y de la persistencia de cielo claro en los cuatro días de la campaña de simulación.

En días de tiempo estable y cielo despejado la línea base es netamente superior (hasta un orden de magnitud el 17 de septiembre), simplemente porque no hay nada que predecir: la geometría solar basta. El modelo aporta cuando el estado del cielo cambia respecto al día anterior, ya sea al despejar (13 de julio, donde la persistencia falla al arrastrar la nubosidad del día previo) o en jornadas nubosas (11 de febrero). Este es precisamente el régimen en el que un EMS reactivo se equivoca, y por tanto el régimen en el que la predicción puede modificar la operación.

La comparación no es del todo simétrica, y esa asimetría explica en buena medida por qué el modelo pierde a partir de h+5. La persistencia de cielo claro dispone de la curva CLRSKY del día siguiente y solo tiene que estimar un escalar: el índice de cielo claro. El modelo LSTM, en cambio, predice la irradiancia en bruto y no recibe CLRSKY futuro entre sus entradas, por lo que debe reconstruir a partir de las codificaciones cíclicas de hora y día la misma componente determinista que la línea base recibe gratis. Se le exige por tanto aprender la geometría solar además de la meteorología, y es en los horizontes largos —donde la componente geométrica domina sobre la meteorológica— donde ese sobrecoste se paga.

La práctica habitual en predicción de irradiancia consiste precisamente en evitarlo: modelar el índice de cielo claro $k_t = \text{ALLSKY} / \text{CLRSKY}$ en lugar de la irradiancia bruta, y recuperar la predicción final multiplicando por la curva CLRSKY conocida del horizonte. Importa precisar el alcance exacto de lo que falta, porque el modelo no es del todo ajeno a esta idea: la *feature* `cloud_idx` de la Tabla 4.1 es justamente $1 - k_t$, de modo que el índice de cielo claro ya entra en la red como variable de entrada. Lo que no está es, por un lado, k_t como variable objetivo (la red predice irradiancia bruta y debe por tanto reproducir la envolvente geométrica) y, por otro, el valor futuro de CLRSKY, que la línea base sí utiliza.

De ahí se derivan dos líneas de mejora de coste muy distinto. La primera, y la más barata, no requiere reentrenar nada: basta con proyectar la predicción ya existente sobre la envolvente de cielo claro conocida, es decir, calcular el índice implícito $\hat{k}_t = \hat{y} / \text{CLRSKY}$, acotarlo al intervalo físicamente admisible y reconstruir la predicción multiplicando de nuevo por CLRSKY. Esto corrige las predicciones que violan la envolvente (el modo de fallo más probable en los horizontes largos) y puede evaluarse sobre las predicciones de test ya guardadas. La segunda, reentrenar la red tomando k_t como objetivo, es la solución de fondo, pero obliga a revalidar el modelo y a repetir las simulaciones del Capítulo 5, que se realizaron con la versión ya entrenada. La primera se ha llevado a cabo, y su resultado se presenta en la sección siguiente.

Conviene también matizar la fortaleza aparente de la línea base en los días despejados de la Tabla 4.7. ALLSKY y CLRSKY proceden de la misma cadena de cálculo radiativo de NASA POWER, y por eso en un día genuinamente despejado ambos productos coinciden casi exactamente y el índice k_t vale prácticamente 1 dos días seguidos: el MAE de 0,99 Wh/m² del 17 de septiembre no mide tanto la calidad de la persistencia como el acuerdo interno del reanálisis. Frente a medidas de piranómetro, con nubosidad parcial real no capturada por el producto satelital, esa ventaja sería sensiblemente menor.

En síntesis, el modelo LSTM solar queda validado para el uso que se le da en este trabajo (previsión a pocas horas, empleada para anticipar la evolución del excedente fotovoltaico) con un error relativo diurno del 14,3 % y una mejora del 15,8 % sobre la persistencia de cielo claro en el tramo $h+1 \dots h+3$. La salida cruda de la red no queda validada, en cambio, como predictor de irradiancia a 24 horas: en el horizonte completo una línea base trivial es mejor, y afirmar lo contrario a partir del R^2 sería un error de interpretación.

Esta última limitación es de la red aislada, y los dos apartados siguientes la resuelven. La conclusión hacia la que apuntan puede adelantarse aquí: proyectando la predicción sobre la envolvente física de cielo claro y combinándola después con la línea base, la señal resultante —que es la que consume la Versión B— sí bate a la persistencia también en el agregado de 24 horas, con un skill del +5,8 %.

El comportamiento sobre los cuatro días concretos que consume la campaña de simulación (Tabla 5.7) añade un matiz que el agregado esconde:




Figura 4.4: Predicción de irradiancia frente al valor real de NASA POWER en los cuatro días de la campaña de simulación.

En los tres días despejados el modelo sigue la curva casi exactamente (22,6 Wh/m² de MAE el 2 de julio, 37,2 el 13 de julio y 13,8 el 17 de septiembre), pero en el laborable nublado del 11 de febrero el error se dispara a 53,7 Wh/m², más del doble: la red predice un máximo de 425 Wh/m² frente a los 265 reales y no ve en absoluto el paso de nubes de las 13 a las 15 h, que hunde la irradiancia a un tercio de lo previsto.

La asimetría es la misma que se observará en el modelo de precio y conviene retenerla, porque es la que gobierna el valor operativo de la previsión: el modelo acierta en los días en los que acertar no aporta nada (un día despejado lo predice igual de bien la persistencia de cielo claro, sin red neuronal alguna) y falla justo en el día en que anticipar la caída de excedente sería útil. El mecanismo de la Versión B que consume PVPred está pensado precisamente para adelantar producción de hidrógeno ante una caída de irradiancia; el 11 de febrero es el escenario donde más margen tendría para aportar, y es donde la previsión es peor.

4.2.5 Proyección sobre la envolvente y elección del horizonte operativo

Para separar las dos hipótesis del apartado anterior (error por parametrización frente a incertidumbre meteorológica irreducible) se ha proyectado la predicción ya entrenada sobre la envolvente de cielo claro, sin reentrenar nada: se calcula el índice implícito $\hat{k}_t = \hat{y} / \text{CLRSKY}$, se acota a un techo $k_{\max}$ y se reconstruye la predicción como $\hat{k}_t \cdot \text{CLRSKY}$.

Un 6,65 % de las predicciones diurnas superan $1,10 \cdot \text{CLRSKY}$, con un exceso medio de $21,6 \text{ Wh/m}^2$ y un máximo de $100,9$; ninguna es negativa.

Tratamiento	MAE glob.	MAE diurno	R ²	Skill vs. c. claro
Sin proyectar	30,19	59,38	0,9554	-8,8 %
Sólo horas de noche a 0	30,18	59,38	0,9554	-8,8 %
1. envolvente $k_{\max} = 1,00$	28,47	56,00	0,9571	-2,6 %
1. envolvente $k_{\max} = 1,05$	29,15	57,33	0,9565	-5,1 %
1. envolvente $k_{\max} = 1,10$	29,45	57,94	0,9561	-6,2 %
1. envolvente $k_{\max} = 1,20$	29,76	58,54	0,9558	-7,3 %

Tabla 4.8: Efecto de proyectar la predicción sobre la envolvente de cielo claro, sobre el mismo conjunto de test. MAE en Wh/m^2 .

Enmascarar las horas nocturnas no cambia el MAE diurno ($59,38 \text{ Wh/m}^2$ antes y después): la mejora de las filas siguientes procede de la envolvente. El mejor techo resulta ser $k_{\max} = 1,00$, es decir, no permitir que la predicción supere en ningún caso la irradiancia de cielo despejado; esto es coherente con la naturaleza del dato, ya que ALLSKY y CLRSKY proceden de la misma cadena radiativa de NASA POWER y el primero no excede al segundo por construcción. Con ese techo el MAE diurno baja de $59,38$ a $56,00 \text{ Wh/m}^2$ (una mejora del $5,7 \%$) y el déficit frente a la línea base se reduce de $-8,8 \%$ a $-2,6 \%$.

Más informativo aún es dónde actúa la corrección:

Horizonte	LSTM	Proyectado	Cielo claro	Mejora
h+1	16,89	13,92	19,72	17,6 %
h+2	17,09	16,02	22,15	6,3 %
h+3	21,65	21,51	24,17	0,7 %
h+6	32,06	30,55	27,74	4,7 %
h+12	30,53	30,10	28,80	1,4 %
h+16	36,53	36,52	28,82	0,0 %
h+20	32,72	32,65	28,87	0,2 %
h+24	32,43	30,53	29,63	5,9 %

Tabla 4.9: MAE (Wh/m^2) por horizonte antes y después de proyectar sobre la envolvente. El desglose se calculó con $k_{\max} = 1,10$, el techo con el que se hizo el diagnóstico; el techo que finalmente se despliega es $1,00$ (Tabla 4.8). La mejora se concentra en las primeras horas y se anula en el tramo central.

La mejora se concentra en h+1 ($17,6 \%$) y h+2 ($6,3 \%$), y se anula por completo entre h+13 y h+20, donde la corrección no llega al $0,2 \%$. Y, lo más concluyente, el punto de cruce con la línea base no se mueve: sigue en h+5.

De aquí se siguen dos conclusiones distintas, que no deben mezclarse. En el corto plazo, la parametrización sí estaba costando precisión: el modelo emitía predicciones por encima de la envolvente física y corregirlas recupera casi un 18 % de error en $h+1$. En el largo plazo, en cambio, la hipótesis queda refutada: el error de los horizontes centrales no es un artefacto de haber predicho irradiancia bruta en lugar del índice de cielo claro, porque forzar la envolvente no lo reduce. Es incertidumbre meteorológica genuina, la que solo se resolvería incorporando una previsión NWP como entrada. Reentrenar la red tomando k_t como objetivo no está por tanto justificado: no es donde está el problema, y obligaría a repetir toda la campaña de simulación. La proyección, en cambio, es un posprocesado que sí conviene aplicar, porque actúa justo sobre el tramo que consume el EMS.

Elección del horizonte operativo. El parámetro N_PV_H de la Versión B se ha fijado repitiendo el análisis por horizonte sobre el conjunto de validación, y no sobre el de test. Sobre validación, el promedio de las dos primeras horas del horizonte alcanza un skill del 9,6 % frente a la persistencia de cielo claro, superior tanto al de una sola hora (3,2 %) como al de tres (6,9 %), y a partir de la quinta el skill se vuelve negativo. Se adopta en consecuencia $N_PV_H = 2$. Sobre test, el promedio de $h+1$ y $h+2$ da un skill del 18,8 % frente al 15,8 % del promedio de tres horas, y con la proyección aplicada sube al 28,5 %.

4.2.6 Combinación con la línea base

Las secciones anteriores dejan un modelo que gana con claridad en las primeras horas del horizonte y pierde a partir de la quinta. Elegir uno de los dos predictores desperdicia información: la alternativa estándar, propuesta por [51] y hoy rutinaria en predicción de series energéticas, es combinarlos horizonte a horizonte,

$$\hat{y}_{\text{comb}}(h) = w(h) \cdot \hat{y}_{\text{LSTM}}(h) + (1 - w(h)) \cdot \hat{y}_{\text{cielo claro}}(h)$$

con los pesos $w(h)$ ajustados por barrido fino minimizando el MAE sobre el conjunto de validación, nunca sobre el de test. Es el mismo tratamiento que se aplica al modelo de precio, de forma que ambos reciben el mismo criterio. La combinación de predictores es, además, notoriamente difícil de batir en predicción de precios eléctricos [40]. La señal de la LSTM que entra en la combinación es la ya proyectada sobre la envolvente con $k_{\text{max}} = 1,00$, que es la que se despliega.

Los pesos ajustados reproducen con fidelidad el diagnóstico del apartado anterior: valen 0,92 y 0,90 en $h+1$ y $h+2$, caen a 0,20 en $h+6$ y se anulan casi por completo entre $h+15$ y $h+19$, donde la red no aporta nada sobre la geometría solar. La recuperación parcial en las últimas horas del horizonte (0,44 y 0,48 en $h+23$ y $h+24$) no es ruido de ajuste: esos horizontes, emitidos a lo largo de todo el día, caen mayoritariamente sobre las primeras horas del día siguiente, donde la red vuelve a tener información útil.

Señal	MAE glob.	MAE diurno	R ²	Skill vs. c. claro
LSTM sola	30,19	59,38	0,9554	-8,8 %
LSTM proyectada	29,45	57,94	0,9561	-6,2 %
Cielo claro (línea base)	27,74	54,71	0,9446	—
Combinada	26,14	51,51	0,9529	+5,8 %

Tabla 4.10: Comparación de las cuatro señales sobre el conjunto de test. La combinada es la única que bate a la línea base en el agregado de 24 h. MAE en Wh/m².

La señal combinada es la primera que bate a la persistencia de cielo claro en el agregado de las 24 horas, con un skill del +5,8 % frente al -8,8 % de la red sola. Y no lo consigue a costa de empeorar

en ningún tramo: al comparar horizonte a horizonte contra la mejor de las dos señales por separado, la combinada nunca queda por detrás. En $h+1$ el MAE baja a 10,78 Wh/m², frente a los 19,72 de la línea base; parte de esa mejora procede, no obstante, de la proyección sobre la envolvente y no de la mezcla en sí, porque la combinación se construye sobre la señal ya proyectada.

Esto tiene dos consecuencias prácticas. La primera es que la Versión B debe consumir la señal combinada y no la salida cruda de la red; se ha implementado en consecuencia, y el detalle se describe en el apartado siguiente. La segunda, y más interesante, es que una previsión que es fiable en las 24 horas (y no solo en las dos primeras) abre la puerta a decisiones que el EMS hoy no toma: en particular, decidir a media tarde si merece la pena arrancar el electrolizador contando con el excedente que quede de jornada, una decisión de horizonte largo que tolera mucho más error que el reparto instantáneo de potencia. Esa ampliación queda propuesta como trabajo futuro.

4.2.7 Integración en Simulink: S-Function `lstm_sol.m`

El modelo entrenado se guarda en `codigo/modelos/lstm_solar_sevilla.mat` junto con los parámetros de normalización (`norm_params`). Durante la simulación, la S-Function `lstm_sol.m` lo carga en `InitializeConditions` y realiza una inferencia por hora en la función `Outputs`.

La S-Function recibe dos puertos de entrada: el vector de 8 features del instante actual (procedente del bloque *From Workspace* que lee `features_solar`) y el tiempo de simulación en segundos. Mantiene internamente un buffer circular de 48 horas que se actualiza en cada llamada, y sólo realiza una nueva inferencia cuando la hora ha cambiado (`hora_actual` $\neq$ `ultima_hora`), lo que evita cálculos redundantes.

La salida no es la predicción cruda de la red. Sobre ella se aplican, en este orden, los dos posprocesados justificados en los apartados anteriores: la proyección sobre la envolvente con $k_{\max} = 1,00$ y la combinación convexa con la persistencia de cielo claro. Esto obliga a llevar CLRSKY al modelo de Simulink: se ha añadido la serie horaria `clrsky_real` a `datos_OASIS.mat` en `preparar_workspace_simulink.m`, y `init_OASIS.m` la recorta al día simulado.

Los pesos $w(h)$ se leen de `w_combi_sol`, junto con `KT_MAX_COMBI`, en el archivo del modelo, donde los deja el script de entrenamiento. Si no están, o si `clrsky_hour` no está en el *workspace* base, la S-Function emite la predicción cruda.

La salida es, en definitiva, un vector de 24 valores de irradiancia prevista en Wh/m² —la señal combinada, con skill del +5,8 % frente a la línea base— que el EMS usa para estimar la generación fotovoltaica de las próximas horas.

4.3 Modelo LSTM de precio: predicción del mercado spot

4.3.1 Motivación y fuente de datos

El precio horario de la electricidad en el mercado spot español (OMIE/ENTSO-E) presenta una variabilidad elevada y patrones complejos: ciclos diarios (pico mañana y tarde, valle nocturno), ciclos semanales (festivos y fines de semana con precios distintos), estacionalidad anual y episodios extremos (precios negativos o superiores a 200 €/MWh) asociados a excedentes renovables o tensiones de suministro.

Predecir correctamente el precio de las próximas 24 horas permite al EMS tomar decisiones óptimas: operar el electrolizador cuando el precio es bajo (hidrógeno barato), importar energía en valles nocturnos para almacenarla en la batería, y evitar importar en horas punta.

Los datos de entrenamiento provienen del conjunto unificado `datos_entsoe_unificado_2021_2025.csv`, que contiene el precio horario spot (€/MWh) junto con la demanda nacional y la generación solar y eólica de España, alineados temporalmente con los datos NASA de meteorología. De todas ellas, el modelo final emplea el precio y las variables meteorológicas: la demanda nacional y la generación agregada se descargaron y permanecen en el conjunto unificado, pero no se incorporaron como *features* porque en operación real no se conocen para el horizonte que se predice, y usarlas con su valor observado habría introducido información no disponible en el instante de decisión. Su efecto se aproxima de forma indirecta mediante `fv_allsky`. El período de datos cubre desde enero de 2021 hasta diciembre de 2025 (~43 800 horas, 5 años), con split por años: entrenamiento en 2021–2023, validación en 2024 y test en 2025.

4.3.2 Features del modelo (14 variables)

A diferencia del modelo solar, el modelo de precio es altamente multivariante. La matriz de features tiene 14 columnas:

#	Feature	Descripción	Normalización
1	precio	Precio spot España (€/MWh)	Z-score (μ , σ)
2	ALLSKY	Irradiancia horizontal (Wh/m ²)	Z-score
3	T2M	Temperatura a 2 m (°C)	Z-score
4	WS50M	Velocidad de viento a 50 m (m/s)	Z-score
5	hora_sin	$\sin(2\pi \cdot \frac{h}{24})$	Codificación cíclica
6	hora_cos	$\cos(2\pi \cdot \frac{h}{24})$	Codificación cíclica
7	dia_sin	$\sin(2\pi \cdot \frac{d_{sem}}{7})$	Codificación cíclica
8	dia_cos	$\cos(2\pi \cdot \frac{d_{sem}}{7})$	Codificación cíclica
9	mes_sin	$\sin(2\pi \cdot \frac{m}{12})$	Codificación cíclica
10	mes_cos	$\cos(2\pi \cdot \frac{m}{12})$	Codificación cíclica
11	precio_lag24	Precio de hace 24 h (€/MWh)	Z-score
12	precio_lag168	Precio de hace 168 h = 1 semana (€/MWh)	Z-score
13	fv_norm	Capacidad FV instalada en España normalizada	Min-Max $\rightarrow [0, 1]$
14	fv_allsky	ALLSKY $\cdot$ fv_norm (proxy de generación FV)	Z-score

Tabla 4.11: Features de entrada al modelo LSTM de precio (14 variables).

Los lags de precio (`precio_lag24`, `precio_lag168`) son especialmente relevantes: el precio de hoy a las 14:00 está fuertemente correlacionado con el precio de ayer a las 14:00 (lag-24) y con el precio del mismo día de la semana anterior (lag-168). La variable `fv_norm` codifica el crecimiento de la capacidad fotovoltaica instalada en España año a año (15 GW en 2021, 36 GW en 2025), y captura así la tendencia secular a la baja del precio en horas centrales del día debida a la mayor penetración solar.

La normalización se realiza mediante Z-score ($z = \frac{x-\mu}{\sigma}$) con parámetros calculados sobre el conjunto de entrenamiento y guardados en `norm_params` junto con el modelo. La S-Function aplica estos mismos parámetros en tiempo de inferencia.

4.3.3 Arquitectura y entrenamiento

La arquitectura del modelo de precio es análoga a la del modelo solar, con la adaptación del número de features de entrada (14 en lugar de 8) y un dropout ligeramente mayor (30%) para combatir el mayor riesgo de sobreajuste por la mayor dimensionalidad:

Capa	Tipo	Unidades / Parámetro
1	sequenceInputLayer	14 features
2	lstmLayer (OutputMode: sequence)	128 unidades
3	dropoutLayer	30%
4	lstmLayer (OutputMode: last)	64 unidades
5	dropoutLayer	30%
6	fullyConnectedLayer	64 neuronas
7	reluLayer	—
8	fullyConnectedLayer	24 neuronas (salida)
9	regressionLayer	—

Tabla 4.12: Arquitectura de la red LSTM de precio.

Los hiperparámetros de entrenamiento difieren en el *lookback* (168 h = 7 días, para capturar el ciclo semanal completo) y en el split temporal (por años en lugar de por proporción fija):

Hiperparámetro	Valor
Optimizador	Adam
Tasa de aprendizaje inicial	0.001
Descenso de tasa (factor / periodo)	0.5 / cada 50 épocas
Máximo de épocas	200
Tamaño de mini-lote	64
Regularización L2	1×10^{-4}
Umbral de gradiente	1.0
Paciencia de validación	15 épocas
Ventana de historia (<i>lookback</i>)	168 h (7 días)
Horizonte de predicción	24 h
Conjunto de entrenamiento	2021–2023
Conjunto de validación	2024
Conjunto de test	2025
RMSE de validación (escala normalizada)	0,63358
Época de parada	29 de 200 (criterio de validación)

Tabla 4.13: Hiperparámetros de entrenamiento del modelo LSTM de precio.

El split temporal por años (en lugar de aleatorio) respeta la causalidad de la serie temporal: el modelo nunca ve datos del futuro durante el entrenamiento, y el test se realiza sobre el año más reciente disponible (2025), que no forma parte de la distribución de entrenamiento. El corte por año natural garantiza además que ninguna ventana de entrenamiento tenga su horizonte de predicción dentro del

conjunto de validación; en el modelo solar, cuyo corte es proporcional y no por fecha, las últimas ventanas de cada conjunto sí solapan sus 24 h de horizonte con el conjunto siguiente (71 h de traslape en total), un efecto pequeño que se eliminaría descartando ventana + horizonte muestras en cada frontera. Esta práctica es la más rigurosa para evaluar modelos de predicción de precios de energía [39].

El entrenamiento se detiene por criterio de validación en la época 29 de 200, con un RMSE de validación de 0,63358 en la escala normalizada. La Figura 4.5 muestra que el error de validación desciende de forma sostenida hasta ese valor y se mantiene por debajo del de entrenamiento en todo momento, es decir, lo contrario del patrón que delata el sobreajuste.




Figura 4.5: Curva de entrenamiento del modelo LSTM de precio: evolución del error en entrenamiento y validación. La parada temprana (*early stopping*) se activa cuando la pérdida de validación no mejora durante 15 épocas consecutivas.

4.3.4 Resultados de validación

La Figura 4.6 muestra la predicción del modelo para tres días representativos del conjunto de test (2025), comparada con el precio real ENTSO-E.




Figura 4.6: Predicción LSTM de precio (línea roja) vs. precio real ENTSO-E (línea azul) para tres días del conjunto de test de 2025. La línea punteada representa el *baseline* de persistencia lag-24 (precio de ayer a la misma hora).

La señal que finalmente consume la Versión B bate a la línea base, con un MAE de 18,47 €/MWh frente a los 19,77 de la persistencia de 24 horas, un skill del +6,6 %. Llegar hasta ahí, sin embargo, exige un diagnóstico previo, porque la salida cruda de la red no alcanza ese resultado por sí sola. Los tres apartados siguientes cubren qué mide la red frente a las líneas base, por qué se queda corta y cómo se corrige.

Como en el modelo solar, la evaluación no se apoya en un único número: el precio spot tiene una persistencia diaria muy fuerte, de modo que la referencia obligada (y exigida como mínimo por las guías de buenas prácticas del campo [40]) es la persistencia *naïve* a 24 horas —el precio de ayer a la misma hora— y, secundariamente, la persistencia semanal a 168 horas. Los tres predictores se evalúan sobre el mismo conjunto de test (2025, 8 736 horas, 209 664 pares horizonte-hora).

Modelo	MAE	RMSE	sMAPE
Persistencia lag-24	19,77	28,50	—
Persistencia lag-168	28,75	40,30	—
LSTM (lazo abierto)	21,17	27,94	58,5 %
LSTM, horas con precio > 5 €/MWh	22,05	28,80	37,8 %

Tabla 4.14: Métricas del modelo LSTM de precio frente a las líneas base de persistencia, sobre el conjunto de test de 2025. MAE y RMSE en €/MWh.

En el agregado de las 24 horas la red no alcanza a la persistencia de 24 horas en MAE: 21,17 frente a 19,77 €/MWh, un déficit del 7,1 %. Sí bate con holgura a la persistencia semanal, que queda un 45,4 % por detrás, pero ésa es una referencia débil. El único horizonte en el que la red gana es el primero: $h+1$ da un skill del +2,2 %, que se pierde ya al promediar el tramo $h+1 \dots h+6$ (-2,9 %).

Hay, sin embargo, un matiz que el MAE no recoge: la red gana en RMSE, 27,94 frente a 28,50 €/MWh. Como el RMSE penaliza cuadráticamente los errores grandes, la lectura conjunta de ambas métricas es que la LSTM es peor en la hora típica pero mejor en las horas difíciles: evita los fallos

gruesos que comete la persistencia cuando el perfil del día cambia respecto al anterior, a costa de acertar menos fino en los días tranquilos, que son la mayoría. Para un EMS que toma decisiones económicas, esa asimetría no es irrelevante —los errores caros son los grandes—, pero tampoco basta para declarar superior al modelo.

El sMAPE del 58,5 % debe interpretarse con cautela y se reporta por completitud: al ser una métrica relativa, se dispara en las horas de precio próximo a cero, cada vez más frecuentes con la penetración fotovoltaica. Restringiendo el cálculo a las horas con precio superior a 5 €/MWh baja al 37,8 %, que es la cifra interpretable.




Figura 4.7: Error MAE del modelo LSTM de precio por horizonte temporal ($h+1$ a $h+24$), comparado con las líneas base de persistencia lag-24 y lag-168.

La Figura 4.7 muestra un comportamiento muy distinto al del modelo solar. El error crece con el horizonte, pero muy poco: 19,38 €/MWh en $h+1$, 21,02 en $h+6$, 21,33 en $h+12$, 21,16 en $h+18$ y 22,66 en $h+24$, es decir un cociente $h+24/h+1$ de sólo 1,17. Frente al factor 1,9 del modelo solar, la curva es casi plana. Una curva plana no es aquí una virtud sino un indicio: sugiere que la red no está explotando la información reciente, y que su predicción a una hora es de calidad similar a la de un día.

El diagnóstico se confirma con el análisis de importancia de *features*, obtenido por permutación sobre el conjunto de test (incremento del MAE al barajar cada variable):

Feature	Δ MAE	Feature	Δ MAE
fv_allsky	+3,59	mes_sin	+0,79
hora_sin	+1,74	T2M	+0,43
dia_cos	+1,70	WS50M	+0,22
hora_cos	+1,61	precio_lag24	+0,14
ALLSKY	+1,55	precio_lag168	+0,13
dia_sin	+1,45	fv_norm	-0,00
mes_cos	+1,43		

Tabla 4.15: Importancia de las *features* del modelo de precio por permutación, medida como incremento del MAE (€/MWh) al aleatorizar cada variable sobre el conjunto de test.

La variable dominante es *fv_allsky*, el proxy de generación fotovoltaica, seguida del bloque de codificaciones cíclicas de hora, día de la semana y mes. Es decir: el modelo ha aprendido el perfil calendario-solar del precio, que explica buena parte de la varianza (la curva de «pato» que hunde el

precio en las horas centrales del día), pero es exactamente la parte de la señal que la persistencia de 24 horas reproduce gratis.

Las dos últimas entradas de la tabla explican buena parte de lo anterior: `precio_lag24` y `precio_lag168` valen +0,14 y +0,13 €/MWh, es decir que la red apenas se apoya en los retardos de precio, pese a que el retardo de 24 horas por sí solo constituye la línea base que la supera. La información está disponible en la entrada; el modelo simplemente no la aprovecha. La explicación más plausible es que, con 168 pasos temporales y sólo dos de ellos portando el precio pasado en forma explícita, la señal de precio del buffer queda diluida frente a un bloque de variables deterministas que reducen la pérdida de entrenamiento más deprisa y de forma más estable. El modelo converge así a la componente más fácil de ajustar (el perfil medio del día) sin llegar a aprender la corrección de nivel que aportaría el precio de la jornada anterior.

La misma conclusión se alcanza desde la distribución de las predicciones. Sobre el test, el precio real tiene media 64,9 €/MWh y desviación típica 47,2, mientras que la predicción tiene media 61,0 y desviación típica 37,4: un cociente de dispersión de 0,79. La red está sistemáticamente subdispersa, aplana los extremos y regresa hacia la media, que es el comportamiento esperable de un modelo entrenado con error cuadrático sobre una serie de colas pesadas. Para el EMS esto tiene una consecuencia directa: las horas verdaderamente baratas se predicen menos baratas de lo que son, y las caras menos caras. Por tanto, la señal de precio predicho discrimina peor entre horas que el precio observado.

Queda por examinar el comportamiento sobre los cuatro días concretos de la campaña de simulación, que es el tramo más desfavorable del análisis:

Escenario	MAE LSTM	MAE lag-24	Skill
E1 · 2 jul., laborable soleado	9,0	11,0	+17,6 %
E2 · 11 feb., laborable nublado	18,6	8,9	-109,0 %
E3 · 13 jul., fin de semana soleado	22,3	12,8	-74,2 %
E4 · 17 sep., volatilidad	26,0	18,7	-38,8 %

Tabla 4.16: Error del modelo de precio en los cuatro escenarios de la campaña de simulación (Tabla 5.7), frente a la persistencia de 24 horas. MAE en €/MWh.




Figura 4.8: Predicción del modelo de precio frente al precio real ENTSO-E en los cuatro días seleccionados para la campaña de simulación.

El modelo sólo mejora a la línea base en E1 (el laborable soleado de precio plano, que es además el día en que la precisión importa menos) y queda por detrás en los otros tres, con un déficit que llega a duplicar el error de la línea base en E2. El caso más desfavorable es E4, el día de mayor diferencial de precio del año ($24 \rightarrow 252$ €/MWh), que se eligió precisamente por ser aquel en el que PrecioPred tiene más margen para aportar: allí la red se queda un 38,8 % por detrás de repetir el precio de ayer. La Figura 4.8 muestra por qué: en los días de perfil marcado la predicción reproduce la forma general pero aplana la amplitud, que es el mismo sesgo de subdispersión ya identificado en el agregado.

Este resultado se retiene explícitamente para la discusión del Capítulo 6: cualquier ventaja que la Versión B obtenga en esos escenarios no podrá atribuirse a la calidad de la previsión de precio. Es también el argumento que obliga a desplegar la señal combinada, y no la salida cruda de la red, en el modelo de Simulink.

4.3.5 Combinación con la línea base

Se aplica al modelo de precio el mismo tratamiento que al solar: una combinación convexa por horizonte con la línea base, con los pesos ajustados sobre el conjunto de validación (2024) y evaluada sobre test (2025).

$$\hat{p}_{\text{comb}}(h) = w(h) \cdot \hat{p}_{\text{LSTM}}(h) + (1 - w(h)) \cdot p_{t-24+h}$$

Los pesos resultantes son mucho más planos que en el caso solar: parten de 0,74 en $h+1$ y descienden suavemente hasta 0,52 en $h+24$, sin llegar a anularse en ningún horizonte. La lectura es coherente con todo lo anterior: los dos predictores cometen errores poco correlacionados —la red captura el

perfil calendario-solar, la persistencia captura el nivel del día— y ninguno domina al otro, que es justamente la situación en la que una combinación aporta más.

Señal	MAE	Skill vs. lag-24
Persistencia lag-24	19,77	—
LSTM sola	21,17	−7,1 %
Combinada	18,47	+6,6 %

Tabla 4.17: Efecto de la combinación convexa en el modelo de precio, sobre el conjunto de test. MAE en €/MWh.

La combinación recupera el resultado: 18,47 €/MWh frente a los 19,77 de la persistencia, un skill del +6,6 %, y un 12,8 % mejor que la red sola. La mejora se sostiene en todo el horizonte (16,69 €/MWh en h+1, 17,06 en h+2, 17,61 en h+3, 18,44 en h+6, 18,76 en h+12 y 19,11 en h+24), de modo que incluso el peor horizonte de la señal combinada bate a la línea base en su conjunto. Como en el modelo solar, el predictor que se despliega no es la salida cruda de la red, sino la mezcla.

4.3.6 Evaluación en lazo cerrado

Todas las cifras anteriores son de lazo abierto: en cada instante se alimenta a la red con los 168 precios reales previos. La S-Function `lstm_precios.m`, en cambio, se despliega en lazo cerrado, realimentando su propia predicción a un paso. Para cuantificar esa discrepancia se ha replicado el mecanismo de realimentación sobre el conjunto de test, emulando el buffer autorregresivo de la S-Function.

Horizonte	Degradación del MAE
h+1	+0,0 %
h+3	−2,2 %
h+6	+13,6 %
h+12	+16,6 %
h+18	+32,6 %
h+24	+74,2 %
Agregado 24 h	+27,7 %

Tabla 4.18: Degradación del modelo de precio al pasar de evaluación en lazo abierto a lazo cerrado con realimentación de la propia predicción. En el agregado, el MAE pasa de 21,65 a 27,64 €/MWh.

El deterioro es severo y crece con el horizonte, como corresponde a la acumulación de error autorregresivo: nulo en la primera hora, del 13,6 % a las seis y del 74,2 % a las veinticuatro. En términos de skill frente a la persistencia, la red pasa de un −7,1 % en lazo abierto a un −39,8 % en lazo cerrado: el modelo tal como estaba desplegado era casi un 40 % peor que repetir el precio de ayer.

Esta medición es lo que justifica la corrección aplicada a `lstm_precios.m`, descrita en la sección siguiente: realimentar el buffer con el precio observado en lugar de con la predicción. La corrección es además la opción realista, porque un operador conoce el precio spot de las horas ya transcurridas (la casación del mercado diario se publica el día anterior), de modo que el lazo cerrado no representaba una limitación operativa sino un defecto de implementación.

4.3.7 Clamp de predicciones negativas

El mercado spot español opera dentro de los límites armonizados del acoplamiento diario europeo (SDAC), que desde el 10 de mayo de 2022 son [−500, 4000] €/MWh; los precios negativos son posi-

bles pero infrecuentes ($\leq 1\%$ de las horas). Para evitar que el modelo genere predicciones aberrantes muy negativas en períodos con alta incertidumbre, se aplica un *clamp* mínimo de -20 €/MWh en la inferencia: $Y_{24} = \max(-20, Y_{24})$. Este umbral es conservador: admite precios negativos plausibles (excedentes renovables) pero descarta outliers extremos que podrían desestabilizar la lógica de control del EMS.

4.3.8 Integración en Simulink: S-Function `lstm_precios.m`

El modelo entrenado se guarda en `codigo/modelos/lstm_precio_luz.mat`. La S-Function `lstm_precios.m` recibe cuatro puertos de entrada: el vector de 3 features meteorológicas externas (ALLSKY, T2M, WS50M en valores crudos sin normalizar), el tiempo de simulación, el día del año (1–365) y el día de la semana (1=domingo, 7=sábado).

Internamente, la S-Function mantiene dos buffers circulares de 168 horas: uno para las features meteorológicas (`pr_buffer_weather`) y otro para la serie de precio (`pr_buffer_precio`). Este segundo buffer se inicializa con los precios reales de las 168 horas previas al día simulado. En la implementación heredada se realimentaba después con la propia predicción a un paso del modelo, en lugar de con el precio observado; el apartado 4.3.6 cuantifica el coste de esa elección (un 27,7 % de MAE adicional, hasta un 74,2 % en $h+24$) y motiva la corrección aplicada: el buffer se actualiza ahora con el precio real de la hora transcurrida, tomado de la misma serie `precio_real_hour` que alimenta al modelo de Simulink, y sólo recurre a la predicción si esa muestra no está disponible. La operación sigue siendo estrictamente causal, porque el precio que se inserta corresponde a una hora ya pasada. En cada nueva hora, reconstruye la matriz de 14 features $\times$ 168 pasos temporales aplicando las codificaciones cíclicas y los lags de precio, llama a `predict()` y actualiza la predicción de las próximas 24 horas. Las features meteorológicas de la historia se leen de `features_precio`, pre-cargado en el workspace base por `init_OASIS.m`.

Igual que en el modelo solar, lo que sale del bloque no es la predicción cruda sino la señal combinada: sobre el vector de 24 horas se aplica la mezcla convexa con la persistencia de 24 h descrita en el apartado anterior. La línea base sale gratis, porque el precio de referencia p_{t-24+h} se lee de la serie `precio_real_hour` —no del *buffer* autorregresivo—, y corresponde en todos los casos a horas ya transcurridas. Los pesos se cargan de `w_combi_precio`, añadido al `.mat` del modelo por el script de entrenamiento, y en su ausencia la S-Function emite la salida cruda.

4.4 Comparación de los dos modelos

Característica	LSTM Solar	LSTM Precio
Variable objetivo	ALLSKY (Wh/m ²)	Precio spot (€/MWh)
Features de entrada	8	14
Ventana de historia	48 h	168 h (7 días)
Horizonte de predicción	24 h	24 h
Capas LSTM (unidades)	128 + 64	128 + 64
Dropout	20%	30%
Normalización objetivo	Min-Max	Z-score
Datos de entrenamiento	NASA POWER (2007–2025)	ENTSO-E + NASA (2021–2025)
Split train/val/test	80%/10%/10% cronológico	2021-23 / 2024 / 2025
Época máxima	300	200
Regularización	Dropout	Dropout + L2 (1e-4)
Archivo guardado	lstm_solar_sevilla.mat	lstm_precio_luz.mat
S-Function	lstm_sol.m	lstm_precios.m
Línea base de referencia	Persistencia de cielo claro	Persistencia lag-24
Skill de la red sola (24 h)	−8,8 %	−7,1 %
Skill de la señal combinada	+5,8 %	+6,6 %
Peso de la LSTM en $h+1 \rightarrow h+24$	0,92 $\rightarrow$ 0,48	0,74 $\rightarrow$ 0,52

Tabla 4.19: Comparación de características y resultados de los dos modelos LSTM desarrollados.

La elección de una ventana de historia de 168 h para el modelo de precio (frente a 48 h para el solar) responde a la naturaleza del fenómeno: la irradiancia solar en Sevilla tiene patrones diarios muy regulares que se capturan bien con 2 días de historia, mientras que el precio de la electricidad requiere ver al menos 7 días para capturar el ciclo semanal completo (diferencia entre laborables y festivos).

Las cuatro últimas filas de la Tabla 4.19 dan el mismo resultado en los dos modelos pese a tratarse de fenómenos y líneas base completamente distintos: ninguna de las dos redes bate por sí sola a su línea base trivial en el agregado de 24 horas, y ambas lo hacen (con márgenes muy parecidos, +5,8 % y +6,6 %) una vez combinadas con ella. La diferencia está en el perfil de los pesos. En el modelo solar caen a cero en el tramo central del horizonte, porque la geometría solar es determinista y la red no tiene nada que añadir sobre la envolvente de cielo claro más allá de las primeras horas. En el modelo de precio se mantienen en torno a 0,5 en todo el horizonte, porque los dos predictores capturan partes distintas de la señal —el perfil calendario-solar la red, el nivel del día la persistencia— y ninguno domina.

Al leer las dos filas de *skill* de la Tabla 4.19 debe tenerse presente que las dos líneas base no son igual de exigentes, de modo que el −8,8 % y el −7,1 % no son cifras directamente comparables. La persistencia de cielo claro separa las dos componentes de la irradiancia (la determinista, contenida en CLRSKY y conocida con exactitud para cualquier instante futuro, y la estocástica, resumida en el índice k_t) y persiste únicamente la segunda. La persistencia lag-24, en cambio, arrastra a la vez la geometría solar de ayer y la nubosidad de ayer adherida a las horas de reloj de ayer, con lo que hereda

dos fuentes de error en lugar de una. El precio spot no admite una construcción equivalente, porque no existe una envolvente física del precio calculable de antemano; en su caso la persistencia de 24 horas es la referencia más fuerte disponible.

La consecuencia es que, medido contra la persistencia lag-24 (que es el análogo exacto de la línea base del modelo de precio), el modelo solar sí mejora a la referencia, y en un 10,1 %: 30,19 frente a 33,59 Wh/m² (Tabla 4.5). El déficit del 8,8 % se produce frente a la línea base más dura de las dos, que es la que la literatura de predicción de irradiancia considera correcta y la que se adopta aquí por ese motivo. La elección no es inocua: reportar únicamente la lag-24 habría permitido presentar el modelo solar con un *skill* positivo del 10 % sin haber cambiado nada del modelo, y habría hecho al mismo tiempo irrelevante el +5,8 % de la señal combinada, porque batir una referencia débil no demuestra gran cosa.

De aquí se sigue una conclusión metodológica que se traslada al diseño de la Versión B: el valor de la predicción no está en sustituir a la línea base, sino en complementarla.

Conviene por ello fijar la terminología que se emplea en el resto del trabajo, porque la distinción es la que sostiene todo el capítulo. Se llama **red sola** a la salida directa de la LSTM, y **señal combinada** a la mezcla convexa de esa salida con la línea base correspondiente, horizonte a horizonte y con los pesos ajustados sobre validación. La red sola es un objeto intermedio del análisis: aparece en la evaluación porque es lo que permite medir cuánto aporta la red por encima de una regla trivial, pero no es lo que se despliega. Lo que las dos S-Functions entregan al EMS, y por tanto lo único que la Versión B llega a consumir, es la señal combinada.

4.5 Limitaciones de los modelos

Los dos modelos presentan limitaciones que deben tenerse en cuenta al interpretar los resultados de la simulación:

En primer lugar, ninguno de los modelos incorpora información de predicción meteorológica NWP (*Numerical Weather Prediction*), sino que usa datos históricos observados. En un sistema real, la predicción solar se obtendría de una fuente NWP (ECMWF, AEMET) en lugar de datos pasados. Ambos modelos operan, no obstante, de forma estrictamente causal durante la simulación: las S-Functions mantienen una ventana móvil de observaciones pasadas (48 h en el modelo solar, 168 h en el de precio) e insertan en cada paso únicamente la muestra del instante actual, sin acceso a valores futuros. El hecho de que las variables meteorológicas provengan del año de test no supone por tanto disponer de una predicción meteorológica, sino evaluar sobre datos no vistos en el entrenamiento.

Sí existe, en cambio, una limitación de disponibilidad del dato: la irradiancia ALLSKY procede del reanálisis satelital CERES distribuido por NASA POWER, que se publica con varios días de retraso. Un sistema real no dispondría del valor de la última hora observada y tendría que sustituirlo por una medida local (piranómetro) o por una previsión NWP, cada una con su propia distribución de error. La transferencia del modelo a una instalación real exigiría por tanto reentrenarlo con la fuente de datos disponible en tiempo real.

En segundo lugar, y de forma más sutil, la evaluación de los modelos y su despliegue no ocurren en el mismo régimen. Ambas redes se entrenan con la entrada real en la ventana de historia (*teacher forcing*), pero la S-Function del precio operaba realimentando su propia predicción, lo que produce el fenómeno conocido como *exposure bias*: el error se acumula a lo largo del día y el rendimiento medido en lazo abierto sobrestima el que el EMS experimenta realmente. El apartado 4.3.6 cuantifica esa brecha y describe la corrección adoptada. Queda como limitación residual que la corrección depende de disponer del precio observado de la hora anterior, algo que en la simulación se garantiza por

construcción y que en una instalación real exige una conexión fiable a la publicación de la casación diaria.

En tercer lugar, el modelo de precio tiene dificultades en episodios extremos: precios muy negativos (curtailment masivo), picos superiores a 200 €/MWh (tensiones de gas) o cambios regulatorios bruscos. Estos eventos son inherentemente difíciles de predecir con modelos estadísticos y suelen requerir la incorporación de variables fundamentales de mercado no disponibles en los datasets públicos utilizados.

En cuarto lugar, ambos modelos se entrenan con datos de España y Sevilla, respectivamente. Una implantación de la estación OASIS en otra ubicación requeriría re-entrenar con datos de esa región.

5 Metodología

5.1 Enfoque general

Este capítulo describe cómo se combinan los elementos presentados hasta ahora (el dimensionamiento y los perfiles de demanda del Capítulo 3 y los modelos de predicción del Capítulo 4) en el sistema de gestión de energía de la estación. El capítulo está organizado alrededor de una única versión final del EMS, la Versión C, y del camino que llevó hasta ella. Se parte del EMS heurístico de referencia heredado de [7] (Versión A), se resume lo que enseñó el intento de mejorarlo con predicción, y se describe en detalle el diseño final, que separa dos decisiones que la heurística tomaba juntas: de dónde sale la energía que consume el electrolizador y cuándo conviene fabricar el hidrógeno.

El principio metodológico es el de un diseño comparativo controlado. Todas las variantes del EMS se ejecutan sobre exactamente el mismo modelo físico de Simulink, con los mismos perfiles de entrada (fotovoltaica, demanda eléctrica, demanda de hidrógeno y precio), y solo se sustituye el *script* del bloque de decisión. Las versiones se construyen además de forma incremental: cada una difiere de la anterior en un único punto, con un interruptor por mecanismo. La diferencia observada entre dos tandas se puede atribuir así a un cambio concreto y no a un rediseño global. La Versión C se evalúa por ablación: la misma lógica con y sin cada uno de sus componentes.

5.2 Entorno de simulación: la microrred OASIS

El modelo utilizado es la microrred OASIS, implementada en Simulink dentro de SimugridElectrolinera/ (init_OASIS.m, OASIS.slx). Esta microrred incluye generación fotovoltaica, un electrolizador PEM, un tanque pulmón de baja presión (LOH), un compresor, un tanque surtidor de alta presión (LOH_High), una pila de combustible, carga de vehículos eléctricos y demanda de hidrógeno, con las S-Functions lstm_sol.m y lstm_precios.m ya integradas en el bucle de simulación (Capítulo 4). La Figura 5.1 muestra la disposición física que se modela (marquesinas fotovoltaicas sobre los puntos de suministro y recinto técnico con los equipos electroquímicos y los tanques) y la Figura 5.2, los bloques del modelo y las señales que intercambian con el EMS.

La Tabla 5.1 reúne los parámetros de la instalación simulada, que hasta aquí se han ido justificando por separado en el Capítulo 2 y el Capítulo 3.

Subsistema	Parámetro	Valor
Generación fotovoltaica	Configuración del array	24 módulos en serie $\times$ 35 ramas en paralelo, ≈ 508 kWp (Capítulo 2)
Batería (BESS)	Capacidad / potencia	1 MWh; ≈ 494 kW (0,5C), 380 V y 1 300 A; estado de carga inicial del 70 %
Electrolizador PEM	Potencia / consumo específico	200 kW; ≈ 50 kWh/kg; entrega a 40 bar
Compresor	Potencia / consumo específico	15 kW; 3,6 kWh/kg; etapa de baja a alta presión
Pila de combustible (PEMFC)	Potencia	130 kW de diseño (P_{maxFC}); el bloque electroquímico está parametrizado con 120 celdas de 600 cm ² y 600 A, y entrega menos
Tanque de baja (LOH)	Volumen / presión	3,1 m ³ ; 40 bar máximos, 26 bar iniciales; 10,1 kg lleno
Tanque de alta (LOH_High)	Volumen / presión	0,41 m ³ ; 600 bar máximos, 480 bar iniciales (80 % de nivel al arrancar); 20,0 kg lleno con la ecuación de gas ideal del bloque, 14,2 kg con gas real (Capítulo 2)
Cargadores de vehículo eléctrico	Número / potencia	2 $\times$ 50 kW en corriente continua (Capítulo 3.4.1)
Surtidor de hidrógeno	Número / caudal	1 módulo a 1,2 kg/min; 700 bar es la presión nominal del depósito del vehículo (SAE J2601), no la del almacenamiento (Capítulo 2)
Conexión a red	Tipo / valoración	Bidireccional, sin límite de potencia contratada en el modelo; energía valorada al precio horario del mercado diario, sin peajes ni cargos (Capítulo 5.7)

Tabla 5.1: Configuración de la estación OASIS tal y como está parametrizada en OASIS.slx. Las cifras de hidrógeno almacenado siguen la ecuación de estado del propio bloque, que sobrestima la masa a alta presión; el efecto sobre la lectura de los resultados se discute en el Capítulo 2.




Figura 5.1: Vistas isométricas de la estación OASIS desde los cuatro cuadrantes (noroeste, noreste, suroeste y sureste). Las dos marquesinas fotovoltaicas cubren los dos cargadores de vehículo eléctrico de 50 kW y el surtidor de hidrógeno; el recinto vallado agrupa los contenedores de batería, electroliizador, compresor y pila de combustible, el tanque tampón de baja presión y el bastidor de botellas de alta presión.




Figura 5.2: Arquitectura por módulos del modelo OASIS.slx. Los bloques se agrupan por la red que intercambian: consignas del EMS hacia los equipos (trazo discontinuo naranja), medidas de los equipos hacia el EMS (discontinuo gris), potencia eléctrica en el bus de alterna (azul) y flujo de hidrógeno (verde), con los nombres de las señales tal y como aparecen en Simulink. El EMS es un único bloque MATLAB Function con once entradas y seis salidas; las dos S-Functions de previsión le entregan PVPred y PrecioPred.

El grupo de investigación dispone además de un segundo modelo, `AIHRE_Puerto_Negocio1v1.slx`, con una arquitectura de componentes muy similar a la del Caso 2 de Molero Almazán [7] (electrolizador PEM, compresor, doble tanque de H₂, pila de combustible, batería y demanda de H₂ externa). Ese modelo no se emplea en este trabajo, que se realiza íntegramente sobre OASIS, y se conserva fuera del árbol de trabajo del repositorio.

5.3 El EMS de referencia — Versión A

El EMS heurístico previo de OASIS gestionaba únicamente el electrolizador mediante una máquina de estados de tres etapas (Paro → Standby → Run, señalizada mediante los vectores `EstEl/DiscEl`), dejaba la pila de combustible permanentemente en standby y no llegaba a asignar consigna alguna a la batería. Como punto de partida se ha portado a esta misma interfaz el EMS heurístico más completo descrito en [7] (Caso 2, versión 4.2), que sí implementa:

- Reparto dinámico de potencia entre batería y electrolizador según tramos de estado de carga (SOC): 80/20 con SOC bajo, 60/40 con SOC intermedio y 30/70 con SOC alto. El reparto favorece la producción de H₂ cuando la batería está casi llena.
- Uso efectivo de la pila de combustible para cubrir déficit, tras la batería, en vez de mantenerla siempre parada.
- Tiempo mínimo de funcionamiento (TMF) de 2 horas para electrolizador y pila, con histéresis y anti-rebote temporal, para evitar conmutaciones rápidas de estos equipos.
- Decisión económica de producción propia de H₂ frente a compra externa, comparando el coste de producir un kilogramo localmente (a partir del precio eléctrico instantáneo) con el precio de un suministro externo.

El bloque MATLAB Function de `OASIS.slx` tiene 11 entradas y 6 salidas. Entre las entradas está `PrecioPred`, que no alimentaba ninguna decisión, y entre las salidas no hay ninguna de compra externa de H₂. Todas las versiones del EMS de este trabajo mantienen esa firma, de modo que sustituyen al *script* del bloque sin tocar el cableado de Simulink. La adaptación respecto al código de [7] ha requerido los siguientes cambios, comentados en `codigo/EMS/ems_A.m`:

1. **Conservar la máquina de estados existente.** El EMS de referencia calcula consignas de potencia de forma puramente algebraica, sin máquina de estados; para no modificar los bloques de Simulink ya construidos, la lógica de decisión se ha conservado y se traduce, en un último paso, a los pulsos `DiscEl/DiscFc` que gobiernan las transiciones Paro/Standby/Run, usando el TMF como condición de arranque/parada.
2. **Reescalar los umbrales de presión a nivel porcentual.** El EMS original trabaja con presiones absolutas en bar (tanque de alta hasta 900 bar de techo de seguridad). OASIS expresa el nivel de ambos tanques en porcentaje (`LOH`, `LOH_High`), sobre los límites de diseño propios de la instalación. El bloque de tanque de alta empleado en las simulaciones está parametrizado a 600 bar de presión máxima (Capítulo 2), frente a los 900 bar de techo de seguridad del tanque de [7]. Las dos escalas son relativas, así que la Tabla 5.2 no cambia: los porcentajes de la tabla se obtienen como la fracción que cada umbral de Molero Almazán representa sobre su propio rango de diseño (`bar/900`), y esa fracción se traslada a la escala 0–100% de OASIS.

Ambas magnitudes miden lo mismo: los bloques de tanque de OASIS calculan la presión a partir del hidrógeno almacenado y entregan el nivel como $LOH = P/P_{\max} \times 100$, es decir, como fracción de presión sobre la presión máxima del tanque, que es la magnitud en la que están expresados los umbrales de [7].

Sí tiene una consecuencia que hay que explicitar: un mismo porcentaje no representa la misma presión absoluta en los dos trabajos. El umbral de banda baja del 76%, por ejemplo, equivale a 680

bar sobre el rango de 900 bar de [7] y a 456 bar sobre los 600 bar con los que está parametrizado el tanque de OASIS. El reescalado conserva la posición relativa del umbral dentro del rango útil del tanque, y con ella la lógica de decisión del EMS, pero no el punto de operación termodinámico. Dado que todas las versiones comparadas emplean los mismos umbrales, la comparación entre ellas no se ve afectada; sí condiciona la comparación cuantitativa directa con los resultados de [7], que se hace por tanto en términos relativos.

3. **Sin puerto de compra externa de H2: decisión económica implementada como constante interna.** Al no existir salida H2Ext ni entrada de precio externo en el bloque real, la comparación de coste «producir localmente vs. comprar fuera» que describe [7] se ha implementado con un precio de referencia externo fijo (H2_PRECIO_EXT_KG). Se toma como base el índice ibérico oficial de precio mayorista del H2 verde (Mibgas IBHYX [52]), 6,12 €/kg en su revisión del 15/07/2025, que sustituye al hipotético «5-6 €/kg» que citaba Molero Almazán; pero ese índice es el precio del hidrógeno en la puerta del electrolizador de referencia, no en la hidrogenera. El hidrógeno que la estación tendría que comprar llega en cisterna y hay que comprimirlo, y con esos dos conceptos añadidos el coste de reposición efectivo se estima en 8 €/kg. La campaña que se reporta en el Capítulo 6 usa en la regla ese coste de reposición, H2_PRECIO_EXT_KG = 8, con el que producir sale más barato que comprar siempre que el precio spot esté por debajo de unos 149 €/MWh (con los consumos específicos adoptados, 50 kWh/kg del electrolizador y 3,6 kWh/kg del compresor); la misma campaña con el índice sin corregir, 6,12 €/kg (umbral de 114 €/MWh), se ha ejecutado como análisis de sensibilidad (Capítulo 5.8). La constante decide si se fuerza el electrolizador y el compresor, pero no hay ninguna salida que module un suministro externo real: si producir localmente no compensa, ese déficit de hidrógeno no se cubre por esta vía en el modelo actual, y en la métrica de coste se valora como coste de oportunidad al precio de reposición de 8 €/kg (Capítulo 5.7). Añadir un mecanismo físico de compra externa queda como ampliación pendiente; la forma natural de implementarlo es un puerto H2Ext alimentado por un suministro discreto en cisterna (*tube trailer*), y como una cisterna entrega centenares de kilogramos de una vez (muy por encima de la capacidad conjunta de los dos tanques de OASIS), la decisión pasaría a ser un problema de reposición con coste fijo de pedido, es decir, una decisión con horizonte.

Umbral	Molero Almazán (bar)	OASIS (%)
Tanque de baja — mínimo para comprimir	22 / 40	55
Tanque de baja — techo electrolizador	38 / 40	95
Tanque de baja — reserva compresor	27 / 40	68
Tanque de alta — techo de seguridad	900 / 900	97
Tanque de alta — banda baja (activa H2)	680 / 900	76
Tanque de alta — banda baja (desactiva)	710 / 900	79
Tanque de alta — nivel crítico	650 / 900	72

Tabla 5.2: Reescalado de los umbrales de nivel de tanque de [7] (bar, sobre su rango de diseño) a los límites propios de OASIS (%). Cada porcentaje es la fracción que el umbral representa sobre el rango de diseño de **su propio** tanque, y LOH es en ambos casos una fracción de presión, por lo que el traslado es dimensionalmente consistente. Lo que se conserva es la posición relativa del umbral dentro del rango útil, no la presión absoluta: el 76 % equivale a 680 bar sobre los 900 bar de [7] y a 456 bar sobre los 600 bar con los que está parametrizado el tanque de OASIS.

La potencia máxima de la batería (P_{maxBat}) usaba provisionalmente 100 kW (coincidiendo con el pico de dos cargadores EV de 50 kW) a falta de una cifra real. Con los parámetros reales del bloque de batería de OASIS (Capítulo 2: 380 V de tensión de circuito abierto, 1 300 A de corriente máxima

de carga/descarga, es decir 0,5C), $P_{\max Bat}$ se fija en $\approx 0,5$ MW ($380 \text{ V} \times 1300 \text{ A} \approx 494 \text{ kW}$) en el código de todas las versiones.

Los umbrales de tanque de la Tabla 5.2 son los que se trasladan de [7]; el resto de constantes que gobiernan la decisión de la Versión A se recogen en la Tabla 5.3. Todas ellas se mantienen sin cambios en la Versión B y en la Versión C, de modo que la Tabla 5.5 solo añade lo propio de esta última.

Parámetro	Valor	Qué gobierna
Reparto excedente batería / electrolizador	80/20 · 60/40 · 30/70	Fracción del excedente que va a cada uno según el estado de carga, con saltos discretos en el 40 % y el 80 % (defecto 3 de la Capítulo 5.5).
$P_{\max Bat}$	$\approx 494 \text{ kW}$	Potencia máxima de carga y descarga de la batería, derivada del bloque ($380 \text{ V} \times 1300 \text{ A}$).
Banda de estado de carga	20 – 90 %	Suelo y techo de la batería. Ninguno de los dos llega a tocarse en la campaña semanal.
$P_{\max El}$ / $P_{\max FC}$	200 / 130 kW	Potencia máxima del electrolizador y consigna máxima de la pila.
TMF	2 h	Tiempo mínimo de funcionamiento del electrolizador y de la pila, con anti-rebote en las transiciones Paro/Standby/Run.
Histéresis del electrolizador	5 %	Margen único de arranque y mantenimiento sobre el umbral de tanque (defecto 1 de la Capítulo 5.5).
Consumos específicos	50 / 3,6 kWh/kg	Electrolizador y compresor; fijan el coste local del kilogramo con el que se evalúa la decisión económica.
H2_PRECIO_EXT_KG	8 €/kg	Precio externo de referencia: producir sale a cuenta por debajo de 149 €/MWh. La campaña de sensibilización lo repite con 6,12 €/kg (114 €/MWh).

Tabla 5.3: Parámetros de decisión de la Versión A, comunes a las tres versiones comparadas. Los umbrales de nivel de los dos tanques están en la Tabla 5.2 y la configuración física de la instalación, en la Tabla 5.1.

La Figura 5.3 resume esa lógica y señala los dos puntos que la Versión C modifica (Capítulo 5.6).




Figura 5.3: Lógica de decisión del EMS. En gris, la lógica común heredada de la Versión A: balance, reparto por estado de carga en la rama de excedente, cobertura del déficit por orden de mérito, decisión económica de producir hidrógeno y máquina de estados. En azul, los dos únicos cambios de la Versión C: la carga del electrolizador y del compresor se ofrece a la batería antes que a la red, y la decisión de producir pasa a ser un planificador de orden de mérito a 24 h que consume el precio publicado del mercado diario, la previsión de precio en las horas no publicadas y la previsión solar. La variante predictiva inyectaba las previsiones en los bloques 2 y 3 de A y no se representa.

5.4 Del EMS heurístico al EMS de programación: lo que enseñó la iteración

La pregunta original del trabajo era si la previsión LSTM mejora al EMS heurístico. La forma más directa de responderla es la que se probó primero: una variante de la Versión A, la Versión B (codigo/EMS/ems_B.m), que consume las dos previsiones en el mismo punto en que la heurística toma sus decisiones. La previsión solar desplaza el reparto batería/electrolizador cuando anticipa una caída del excedente en las dos horas siguientes. La previsión de precio gobierna un arbitraje de batería dimensionado: se localiza la punta de precio prevista en las doce horas siguientes, se exige que el beneficio neto de comprar ahora y descargar en la punta supere un margen mayor que el error de previsión tras las pérdidas del ciclo, y la potencia de carga se calcula a partir de la energía que falta para llegar cargado a esa punta. Es el mismo diseño que la versión V4 de [7]. No es la salida cruda de las redes: las S-Functions entregan la señal combinada con su línea base (persistencia de cielo claro y persistencia de 24 h), con los pesos ajustados en validación (Capítulo 4), porque ninguna de las dos redes bate por sí sola a esa línea base en el agregado de 24 horas.

El dimensionado condiciona el resultado, y de ahí sale la propiedad que se le exige a cualquier regla que consuma una previsión. Una regla que traduzca «el precio va a subir» en una acción de magnitud fija, sin comprobar que haya excedente ni que el diferencial cubra las pérdidas, empeora el coste, y lo empeora más cuanto mejor es la previsión. La acción disparada por una previsión tiene por tanto que estar condicionada a esas dos comprobaciones y su magnitud tiene que salir del margen económico disponible, no de una constante: el valor de una previsión lo determina la regla que la consume, no la previsión por sí sola.

La variante predictiva quedó indistinguible de la Versión A en coste, con la previsión real y también con la perfecta —el propio precio y la propia irradiancia futuros, entregados a las S-Functions en modo oráculo—, y la superó de forma sistemática en las métricas de servicio de hidrógeno, con una mejora que escala con la calidad de la previsión (Capítulo 6). El oráculo es la cota superior: si con error nulo no gana, ninguna mejora de la previsión puede hacer que gane (Capítulo 5.8). Dos medidas adicionales cerraron la línea del arbitraje de precio. La primera es que la previsión de precio, aun teniendo un error medio competitivo, comprime la amplitud del precio a entre el 36 % y el 55 % de la real en los días con recorrido: es la consecuencia esperable de una combinación convexa que minimiza el error medio, y arruina cualquier decisión que dependa de la magnitud de la punta. La segunda es estructural: la estación exporta 10,6 veces la energía que importa, e importa a 121–136 €/MWh mientras exporta a unos 40. El hueco que vale dinero en esta instalación está entre importar y exportar, no entre horas caras y baratas de importación.

Esa segunda medida indicaba dónde mirar, y la descomposición de la importación por destinos lo confirmó: entre el 74 % y el 78 % de la energía que la Versión A compra a la red va al electrolizador, y en los instantes en que la compra la batería está al 85 % de media y nunca por debajo del 69 %. La batería se llena con excedente que después se exporta a 40 €/MWh, mientras el electrolizador consume red a 120. A esto se añade que en el escenario nublado el electrolizador compra a 149,5 €/MWh (8,0 €/kg de hidrógeno, por encima del precio externo de referencia) porque el test económico heredado evalúa el coste de comprimir, no el de electrolizar, cuando el tanque de baja está por encima de su reserva. Son los defectos 6 y 7 de la Capítulo 5.5, y ninguna previsión los veía: la información necesaria (estado de carga, nivel de tanque y precio instantáneo) estaba ya en las entradas de la Versión A.

Una última observación reordena el papel de la previsión de precio. En el mercado diario de OMIE [53] la sesión se celebra a las 12:00 CET y los precios horarios del día siguiente se publican hacia las 13:00. Un operador conoce por tanto con certeza los precios del resto del día en curso y, desde las 13:00, también los del día siguiente: entre 11 y 35 horas del horizonte no hay que predecirlas. Queda

por prever la parte final del horizonte, la madrugada del día siguiente durante la mañana, y solo ese tramo. El diseño final incorpora esa información publicada como dato, y reserva la red neuronal para el tramo no publicado.

5.5 Qué se corrige del EMS heredado y qué queda anotado

Al revisar en detalle el código del EMS de [7] heredado en la Versión A (codigo/EMS/ems_A.m) se identificaron siete puntos en los que el código no se corresponde del todo con su propia descripción textual, o en los que una decisión de diseño resulta cuestionable con independencia de si hay predicción o no. Los cinco primeros se detectaron por inspección del código y quedan recogidos en la Tabla 5.4; los dos últimos, al medir a dónde iba cada kilovatio-hora importado, son los que tienen peso económico y se detallan a continuación.

6. **La batería no alimenta al electrolizador.** En la rama de déficit la batería cubre la carga de los vehículos y, después, la decisión económica añade hasta 200 kW de electrolizador y el compresor. Esa carga nueva no se le ofrece a la batería: la absorbe la red, aunque la batería esté llena. Es el defecto con más peso económico de los siete, y el que corrige la Versión C.
7. **Test económico del compresor aplicado al electrolizador.** Cuando el tanque de baja está por encima de su reserva, el coste local del kilogramo se calcula solo con el consumo del compresor (3,6 kWh/kg), de modo que el test pasa hasta precios superiores a 2 000 €/MWh; pero si pasa, fuerza también el electrolizador a plena potencia. El umbral económico de la regla (149 €/MWh con 8 €/kg; 114 con 6,12) solo actúa con el tanque de baja por debajo del 68 %.

Nº	Defecto	Qué hace el código heredado
1	Histéresis del electrolizador	El texto de [7] describe dos umbrales, uno de arranque y otro de mantenimiento; su código emplea un único umbral del 5 % para ambos casos.
2	Tiempo mínimo de funcionamiento incondicional	El TMF fuerza la potencia mínima con independencia del precio de red, de modo que el electrolizador puede quedar consumiendo red cara hasta agotarlo.
3	Conmutación discreta del reparto	El reparto de potencia batería/electrolizador según el estado de carga salta de forma discreta en SOC = 40 % y SOC = 80 %, en lugar de interpolar entre esos puntos característicos.
4	Compresor sin protección temporal	Se activa y desactiva de forma puramente algebraica según el nivel de los tanques, sin el tiempo mínimo, la histéresis y el anti-rebote que sí tienen el electrolizador y la pila.
5	Decisión económica de H2 todo-o-nada	Cuando producir localmente resulta más barato que el precio externo de referencia, la potencia forzada salta directamente al 100 % del máximo disponible, en vez de escalar con el margen de ahorro.

Tabla 5.4: Defectos del EMS heredado que se dejan anotados, sin corregir ni evaluar en este trabajo, detectados por inspección del código de ems_A.m. La numeración es la que emplea el texto al referirse a ellos.

Los defectos 1 a 5 de la Tabla 5.4 se dejan anotados y no se corrigen ni se evalúan: hacerlo abriría la pregunta «¿ayuda corregir el EMS heredado?», distinta de la que el trabajo se plantea, y exigiría campañas adicionales. El 6 se corrige en la Versión C. El 7 se corrige en la decisión programada de C, pero no en su regla de emergencia, que hereda la de la Versión A (Capítulo 5.6). Anotarlos tiene una consecuencia sobre la interpretación de los resultados: la comparación enfrenta variantes

de una misma lógica de partida imperfecta, no una implementación óptima con otra, y una parte de la diferencia observada podría venir de que un cambio esquivase incidentalmente alguno de los defectos no corregidos. Eso se tiene en cuenta al discutir, en el Capítulo 6, cómo el uso de la batería para el electrolizador interactúa con el defecto 3.

5.6 El EMS final — Versión C

La Versión C (codigo/EMS/ems_C.m; en las etiquetas de los ficheros de resultados esta versión conserva el nombre E con el que se desarrolló, igual que la Versión B conserva B_prima2, por trazabilidad con los registros de la campaña) parte de la Versión A y le hace dos cambios, cada uno con su interruptor. Todo lo demás —parámetros, umbrales, rama de excedente, TMF, histéresis y máquina de estados— es idéntico, para que cada diferencia observada sea atribuible a un cambio concreto. La idea que los une es separar dos decisiones que la heurística tomaba a la vez y con la misma regla: de dónde sale la energía que consume el electrolizador, y cuándo conviene fabricar el hidrógeno.

5.6.1 La batería alimenta al electrolizador

En la rama de déficit, la carga discrecional que crea la decisión de producir hidrógeno (electrolizador más compresor) se ofrece a la batería antes que a la red, mientras el estado de carga esté por encima de una reserva fija:

```
P_disc = abs(min(RefEl, 0)) + max(0, Compresor);      % carga que ha creado la
decision de H2
if (P_disc > 0) && (SOC > SOC_RESERVA)                % SOC_RESERVA = 60 %
    aporte = min(P_disc, PmaxBat - abs(RefBat));
    RefBat = RefBat + aporte;                          % RefBat > 0 = descarga
end
```

El bloque tiene diez líneas y no consume ninguna previsión. Corrige el defecto 6: la energía que antes se exportaba a 40 €/MWh pasa a desplazar una compra a 120. La reserva del 60 % protege la cobertura de la carga de los vehículos; con un piso fijo de ese nivel queda disponible el 79 % de la energía que el electrolizador compraba a la red en la Versión A. Una reserva que variase con la previsión solar aportaría por tanto poco sobre la fija, y por eso la Versión C la deja constante.

5.6.2 Programación: el electrolizador produce en las horas más baratas que hacen falta

La decisión de producir hidrógeno deja de ser la puerta instantánea de la Versión A («producir si el precio está por debajo del umbral económico y el tanque de alta por debajo del 79 %») y pasa a ser una regla de orden de mérito sobre un horizonte de 24 horas, evaluada en cada paso:

1. Se estima la demanda de hidrógeno prevista como media móvil exponencial del caudal medido, con una constante de tiempo de 24 h. No existe puerto de previsión de demanda; es la hipótesis mínima y se declara como limitación.
2. Se estima cuánto excedente fotovoltaico gratis podrá absorber el electrolizador en el horizonte, a partir de la previsión solar PVPred convertida a potencia por forma (escalando la irradiancia prevista con los picos observados) y de la carga actual persistida.
3. Se calcula el hidrógeno que falta: reponer el tanque de alta hasta su objetivo (79 %) más la demanda prevista en el horizonte, menos el inventario del tanque de baja por encima de la reserva del compresor. Restado el excedente previsto, queda la energía que habrá que comprar a la red, y de ahí el número n de horas de electrolizador a plena potencia, redondeado a bloques del TMF (2 h) para no arrancarlo y dejarlo a medias.
4. Se produce en la hora actual si está entre las n más baratas del horizonte, es decir, si el número de horas futuras con precio previsto estrictamente menor que el actual es inferior a n .

5. Se conservan las dos puertas de la Versión A: nunca se produce por encima del precio del hidrógeno externo (el umbral económico, ahora evaluado con el coste completo de electrolizar y comprimir), y en nivel crítico del tanque de alta se produce igual que en A.

La propiedad que hace defendible esta regla, después de lo aprendido en la Capítulo 5.4, es que solo usa el orden de los precios. Contar cuántas horas futuras son más baratas que la actual es invariante a cualquier transformación monótona de la previsión: multiplicar el precio previsto por 0,36 no cambia ni una decisión. Por tanto la sub-dispersión que invalidó el arbitraje no invalida la programación. La regla se autolimita en energía y no en potencia: compra exactamente las horas que faltan, y con el tanque lleno no produce aunque el precio sea nulo.

5.6.3 Qué hace cada previsión, y por qué

Las dos redes del Capítulo 4 entran en la Versión C con funciones distintas, y se declaran por separado.

- **La previsión de precio alarga la información disponible.** El precio del mercado diario publicado a las 13:00 fija con certeza entre 11 y 35 horas del horizonte. La S-Function `lstm_precios.m` incorpora un modo mercado diario que, en cada hora simulada, sustituye por el precio real los horizontes ya publicados —el resto del día en curso y, a partir de las 13:00, todo el día siguiente— y deja la previsión combinada de la red para el tramo no publicado, que son las primeras horas de la madrugada siguiente cuando se evalúa por la mañana. Es estrictamente causal: solo se usan precios ya publicados en ese instante. El modo tiene una segunda variante que rellena el tramo no publicado con la persistencia de 24 horas en vez de con la red, y que sirve de línea base para medir la aportación de la LSTM de precio. Esto es distinto del modo oráculo, que entrega el precio real de las 24 horas siguientes a cualquier hora y no es desplegable.
- **La previsión solar valora el excedente que viene.** Estima, a partir de la forma y los picos de la irradiancia prevista, cuánta energía fotovoltaica sobrante podrá absorber el electrolizador en las próximas 24 horas, y esa cantidad se descuenta de la que hay que comprar. Decide sobre todo en el día nublado, donde la red debe anunciar que no habrá excedente; y es también donde el modelo solar tiene su mayor error (Capítulo 4), de modo que un fallo de la previsión se traduciría en comprar de menos y dejar el tanque corto.

Ninguna de las dos previsiones fija una potencia. Las dos entran como dato de un planificador cuya ejecución sigue en manos de los bloques heredados, y ahí está la diferencia con la primera variante predictiva: la previsión informa una decisión con margen económico, en lugar de disparar una acción de magnitud fija.

5.6.4 Parámetros y lo que no lleva

Parámetro	Valor	Justificación
SOC_RESERVA	60 %	Nivel de batería por debajo del cual no se alimenta al electrolizador. Medido sobre A: con ese nivel el 79 % de lo que el electrolizador compraba a la red podía salir de la batería; el suelo del 20 % para la carga de vehículos no se toca.
N_PLAN_H	24 h	Horizonte del planificador, el de las S-Functions.
N_TMF_H	2 h	Las horas se compran en bloques del tiempo mínimo de funcionamiento.
LOH_OBJ	79 %	Objetivo de inventario del tanque de alta, el mismo umbral de desactivación de A.
LOH_OBJ_MAX	90 %	Por encima de este nivel no se compra red para hidrógeno.
CAP_HIGH_KG, CAP_LOW_KG	20,0 / 10,1 kg	Capacidades de los dos tanques con la ecuación de gas ideal del bloque, a 600 y 40 bar. El planificador las usa para convertir niveles de tanque en kilogramos.
H2_PRECIO_EXT_KG	8 €/kg	Idéntico a A: techo de 149 €/MWh (114 en la campaña de sensibilidad a 6,12 €/kg).

Tabla 5.5: Parámetros propios de la Versión C. Todos los demás son los de la Versión A.

Tres cosas que la Versión C no incluye, y que se declaran como líneas futuras en el Capítulo 7: la reserva de batería es fija y no depende de la previsión solar; el objetivo de inventario del tanque es fijo, cuando la previsión de un día nublado permitiría subirlo la víspera; y la regla de emergencia en nivel crítico hereda el test económico de la Versión A, con el defecto 7 incluido, de modo que en el escenario nublado la estación sigue comprando hidrógeno caro cuando el tanque está en crítico.

5.6.5 Diseño de la ablación

La Versión C se evalúa como un único modelo con sus componentes activados por etapas, todas sobre el mismo horizonte y los mismos pares escenario-semilla:

Tanda	Batería → electrolizador	Programación	Qué aísla
C0	sí	no (regla de A)	El techo sin previsión: cuánto vale que la batería alimente al electrolizador.
C_p	sí	precio publicado + persistencia	Cuánto vale programar con información trivial.
C	sí	precio publicado + LSTM	Cuánto añade la red neuronal de precio sobre la persistencia.

Tabla 5.6: Ablación de la Versión C. Las tres tandas usan el mismo fichero `ems_C.m`; C0 desactiva el planificador con un interruptor, y las dos últimas difieren únicamente en el modo de la S-Function de precio (C_p, planificador con persistencia en el tramo no publicado; C, con la LSTM). En las etiquetas de los ficheros de resultados son E0, E_sinLSTM y E. La previsión solar está presente en las tres y no se aísla.

Cada tanda tiene un criterio de aceptación comprobable antes de mirar ningún coste: la descarga de batería debe ser mucho mayor que en A (la batería se descarga a propósito para el electrolizador) y el error de previsión de precio a una hora debe ser exactamente cero en las dos últimas, porque la primera hora del horizonte siempre está publicada. Las predicciones sobre el resultado de cada contraste se dejaron escritas antes de simular, y en el Capítulo 6 se contrastan una a una.

5.7 Métricas de comparación

Para comparar cuantitativamente las versiones se emplean las siguientes métricas, calculadas sobre el mismo horizonte de simulación:

- **Coste neto de la energía (€):** energía importada de la red valorada al precio horario, menos la exportada al mismo precio. Es la función objetivo del Caso 1 de [7], sin peajes ni cargos, y como allí debe leerse como indicador comparativo y no de facturación.
- **Coste corregido por el valor terminal (€):** el anterior, descontando el valor de la energía que queda almacenada al final del horizonte respecto al inicio (batería y tanques), para no penalizar a la estrategia que termina con más reservas. La batería se valora al precio medio de exportación (unos 40 €/MWh) porque en una instalación que exporta 10,6 veces lo que importa el kilovatio-hora sobrante acaba exportándose, no desplazando una compra; el hidrógeno, a su precio de reposición, 8 €/kg.
- **Coste total con hidrógeno (€):** el coste corregido más el hidrógeno servido con el tanque vacío valorado a 8 €/kg, el coste de reposición con transporte y compresión, que es el coste de oportunidad de no tenerlo y el mismo precio con el que la regla decide si produce (Capítulo 5.3). Solo el control de horizonte semanal de la variante predictiva conserva en la regla el índice mayorista de 6,12 €/kg; la campaña de sensibilización (Capítulo 5.8) muestra que esa constante cambia el coste semanal en menos de medio euro. Es la métrica principal del trabajo, y las tres se reportan siempre juntas.
- **Autoconsumo renovable (%) y autosuficiencia energética (%):** fracción de la generación PV consumida localmente, y fracción de lo consumido que se cubre con generación propia. Se reportan juntas porque una estrategia puede mejorar una y empeorar la otra.
- **Servicio de hidrógeno:** nivel medio y mínimo del tanque de alta, porcentaje de tiempo por debajo del nivel crítico e hidrógeno no servido (kg). Como se justifica en Capítulo 3, la franja útil del tanque es menor que un repostaje completo, por lo que el tiempo en nivel crítico mide sobre todo la velocidad de recuperación y la capacidad de anticiparse, no la ausencia de incidencias.
- **Número de conmutaciones** del electrolizador y de la pila, y **energía ciclada** por la batería (kWh cargados más descargados), como indicadores de desgaste. No se convierten a coste porque no se dispone de curvas de degradación de los equipos de OASIS; se usan para comprobar que la versión económicamente mejor no lo es a costa de un régimen sensiblemente más agresivo.

Contraste estadístico. Todas las comparaciones son pareadas por escenario y semilla (Capítulo 6), y la diferencia se reporta con su media, su mediana, el número de pares en que la versión gana y el *p*-valor del test de rangos con signo de Wilcoxon. Se abandonó el *t*-test pareado al comprobar que en varias tandas tres semillas del escenario nublado dominaban la media, con medias cinco y veinte veces mayores que la mediana, y el contraste sobre la media no describía por tanto a la población de semillas. Además, se fija un umbral de relevancia económica: la dispersión del coste semanal de la propia Versión A entre dos grupos de semillas, 9,33 € por semana. Una diferencia estadísticamente significativa por debajo de ese umbral se declara como tal, significativa y operativamente nula.

La decisión económica de la Capítulo 5.3 fuerza el electrolizador siempre que el precio esté por debajo del umbral económico —114 €/MWh con el índice mayorista, 149 con el coste de reposición— y el tanque de alta por debajo del 79 %, y si el tanque de baja está por encima de su reserva el

umbral equivalente sube por encima de 2 000 €/MWh. De esa lectura del código se sigue un criterio de falsación, fijado antes de simular: el electrolizador tiene que aparecer forzado la mayor parte del tiempo, las métricas de hidrógeno tienen que resultar poco discriminantes y la previsión solar tiene que tener poco margen para modificar nada; si la campaña mostrase lo contrario, la interpretación de la regla heredada sería incorrecta. Los tres puntos se confirman, y llevar el tercero hasta el final es lo que obliga a medir a dónde iba la importación y conduce a los defectos 6 y 7.

5.8 Escenarios de simulación

Siguiendo el mismo criterio de horizonte adoptado en [7], las simulaciones se plantean sobre días representativos en lugar de periodos mensuales o anuales, y se priorizan el ajuste y la comparación de la lógica del EMS frente a un análisis estadístico de largo plazo. Los escenarios no se eligen al azar sino para cruzar las dos variables que gobiernan la decisión del EMS (el recurso solar y el régimen de precio) y cubrir además los dos perfiles de demanda:

Escenario	Fecha	Perfil	Qué somete a prueba
E1 · laborable soleado	02-07-2025	laborable	Excedente fotovoltaico máximo con precio plano (71–130 €/MWh): reparto entre batería y electrolizador sin señal económica que lo distorsione.
E2 · laborable nublado	11-02-2025	laborable	Estrés de recurso ($k_t = 0.36$) con punta de precio de 194 €/MWh a las 20 h: el caso en que la estación no tiene excedente y el hidrógeno hay que comprarlo caro o no servirlo.
E3 · fin de semana soleado	13-07-2025	fin de semana	Irradiancia máxima del año en fin de semana, con precio de 0–4 €/MWh a mediodía: excedente y energía casi gratis a la vez, y perfil de demanda distinto.
E4 · volatilidad	17-09-2025	laborable	Mayor diferencial de precio de 2025 (24 → 252 €/MWh): el escenario con más recorrido para decidir cuándo producir.

Tabla 5.7: Escenarios de la campaña de simulación. Cada uno se ejecuta con varias semillas del generador de demanda y para cada versión del EMS, con las mismas semillas en todas ellas.




Figura 5.4: Los cuatro escenarios en su fecha: precio horario del mercado diario (arriba) e irradiancia horizontal real frente a la de cielo claro (abajo), con el índice de claridad k_t del día. Las cuatro columnas comparten escala, de modo que la comparación entre ellas es directa.

Las semillas responden a que el perfil de demanda es estocástico: el número de vehículos, sus horas de llegada y la energía o el hidrógeno de cada sesión se muestrean de las distribuciones del Capítulo 3. Comparar dos versiones sobre una única realización confundiría la diferencia entre estrategias con el ruido de una tirada concreta; si se repiten las mismas semillas en todas las versiones, cada par de resultados es directamente comparable.

La campaña se organiza en dos horizontes. La comparación de la Versión A con la variante predictiva se hizo sobre 24 horas con diez semillas por escenario (40 pares), horizonte adecuado para la dinámica eléctrica. La Versión C se evalúa sobre una semana continua con cinco semillas por escenario (20 pares), y ese horizonte es el principal por dos razones: la cadena de hidrógeno tiene constantes de tiempo de horas y el tanque de alta arranca cada simulación en su condición inicial, y —más importante— sobre un día el uso de la batería se confunde con el transitorio del estado de carga inicial (del 70 % al 83 %), que en la semana se lava. Con cinco semillas el contraste semanal tiene menos potencia que el diario: en la campaña de 24 horas no resolvió diferencias de 1 a 3 €, y las que se esperan de C son de decenas de euros.

A esa matriz se añaden dos experimentos que no forman parte de la comparación pareada y que sirven para interpretarla. El primero es el oráculo: repetir una tanda entregando a las S-Functions el precio y la irradiancia reales de las 24 horas siguientes en lugar de una predicción. Su resultado es la cota superior de lo que el mecanismo puede extraer de la información; si con error nulo no mejora, ninguna mejora de la previsión puede hacer que mejore. El segundo es la sensibilidad al precio del hidrógeno. La ablación se ha ejecutado con la constante de la regla al coste de reposición con transporte, 8 €/kg (umbral de producción de 149 €/MWh), que es la campaña que se reporta, y se ha repetido completa con el índice mayorista sin corregir, 6,12 €/kg (umbral de 114 €/MWh). Entre una y otra cambia cuántas horas filtra la regla, cuánto electrolizador hay que alimentar y cuántas horas tiene el planificador para elegir, así que la comparación de ambas dice cuánto dependen las conclusiones de ese parámetro, que gobierna tres cuartas partes de la importación. Además, la energía terminal y el hidrógeno no servido se recalculan en posproceso a distintos precios de valoración para comprobar que el signo de las conclusiones no depende de ese supuesto. Los dos se plantean sobre el horizonte semanal, por la razón ya expuesta.

La ejecución de estas simulaciones y la comparación cuantitativa de resultados se presentan en el Capítulo 6.

6 Resultados

Este capítulo presenta la ejecución de la campaña descrita en el Capítulo 5 y la comparación cuantitativa. Se documenta primero cómo se produjeron los resultados (la cadena de *scripts*, el diseño de repeticiones y las comprobaciones de validez) y después las cifras, en el mismo orden del capítulo anterior: el resultado de la variante predictiva, el diagnóstico que reorientó el trabajo y la Versión C con su ablación.

6.1 Cadena de ejecución

Cada simulación es el resultado de encadenar seis piezas, todas ellas en el repositorio del trabajo:

#	Script	Función
1	preparar_workspace_simulink.m	Construye datos_OASIS.mat a partir de los CSV crudos de NASA POWER y ENTSO-E: normaliza las <i>features</i> de las dos redes con los mismos parámetros con que se entrenaron, genera la irradiancia a 1 s con ruido de nubes de semilla fija (42) y guarda las series horarias de precio y de cielo claro. Se ejecuta una sola vez.
2	Demanda_Coches_Aleatoria.m	Genera el perfil estocástico de demanda de vehículos de una semilla dada, perfil_EV_s<n>.mat. Se invoca automáticamente si el perfil de la semilla no existe; para horizontes de varios días, construir_demanda_multidia.m encadena perfiles según el día de la semana real.
3	init_OASIS.m	Recorta todas las series al periodo simulado más 168 h de precalentamiento (el <i>lookback</i> de la red de precio) y las publica en el <i>workspace</i> base, de donde las leen los bloques <i>From Workspace</i> del modelo.
4	OASIS.slx	El modelo. El EMS vive en un bloque MATLAB Function y las dos previsiones en sendas S-Functions, lstm_sol.m y lstm_precios.m.
5	guardar_resultados_ems.m	Calcula los KPIs de una simulación a partir de las señales registradas y guarda un .mat con las series completas y el bloque de indicadores.
6	campana_simulacion.m	Recorre la matriz escenarios $\times$ semillas, orquestando los pasos 2 a 5.

Tabla 6.1: Cadena de *scripts* que produce cada simulación de la campaña.

La agregación posterior corre a cargo de `resumen_campana.m`, que recopila todos los `.mat` de resultados y construye una fila por simulación y otra por versión $\times$ escenario, y de `analisis_ablacion.m`, que compara cada versión contra una referencia emparejando por escenario y semilla y descarta automáticamente las tandas de otro horizonte. `descomponer_importacion.m` reparte la energía importada entre sus cuatro destinos (vehículos, electrolizador, compresor y batería) en proporción al consumo instantáneo de cada uno, y calcula el precio ponderado al que compra cada destino. `medir_reserva_ociosa.m` construye el contrafactual: cuánta de la importación destinada al electrolizador podría haber salido de la batería sin bajar de un nivel de estado de carga dado.

Cada variante del EMS es un archivo separado que difiere del anterior en los puntos estrictamente necesarios, y cada tanda tiene un criterio de aceptación que detecta un bloque mal pegado antes de mirar ningún coste: una descarga de batería nula delata un error de signo.

6.2 Diseño de repeticiones y comparación pareada

El perfil de demanda es estocástico: una única realización no permite distinguir el efecto de la estrategia de control del ruido de la tirada. La campaña se organiza como una matriz de cuatro escenarios (Tabla 5.7) por varias semillas, con una propiedad que gobierna todo el análisis posterior: la semilla n genera exactamente el mismo perfil de demanda en todas las versiones del EMS, el mismo número de vehículos, las mismas horas de llegada y las mismas energías por sesión.

Esto permite comparar de forma pareada: en lugar de contrastar la media de una versión contra la media de otra, se calcula la diferencia semilla a semilla. El ruido de demanda, común a los dos miembros de cada par, se cancela en la diferencia, y el contraste gana potencia de forma considerable. Todas las diferencias de este capítulo son pareadas y se expresan en el sentido versión menos referencia; se reportan con su media, su mediana, el recuento de pares en que la versión gana y el p -valor del test de rangos con signo de Wilcoxon, por las razones expuestas en Capítulo 5.7.

Cada simulación de 24 h cubre 86 401 muestras por señal con paso de integración de 1 s, y las de una semana, siete veces más; el EMS se evalúa a ese paso y las dos S-Functions de previsión emiten una nueva predicción de 24 valores una vez por hora simulada.

6.3 Alcance de lo ejecutado

La Tabla 6.2 resume las tandas que sostienen los resultados de este capítulo. Todas las comparaciones se hacen dentro de un mismo horizonte.

Tanda	Horizonte	Pares	Qué es
A	24 h	40	EMS heurístico de referencia (Capítulo 5.3).
B	24 h	40	Variante predictiva: previsiones inyectadas en las reglas de A, con arbitraje dimensionado (Capítulo 5.4).
B con oráculo	24 h	40	La misma variante con previsión perfecta.
A, B	7 días	20	Control de horizonte de la comparación anterior (regla a 6,12 €/kg).
A, C0, C_p, C	7 días	20	Ablación de la Versión C (Tabla 5.6), contra A a 7 días, con la constante de la regla a 8 €/kg.
A, C0, C_p, C a 6,12 €/kg	7 días	20	Sensibilidad a la constante económica de la regla (Capítulo 6.7.3).

Tabla 6.2: Tandas ejecutadas. Los pares son combinaciones escenario $\times$ semilla; las semillas son las mismas en todas las tandas de un mismo horizonte. Todas las tandas llevan en la regla el coste de reposición de 8 €/kg salvo el control de horizonte de B, que conserva el índice de 6,12; la Capítulo 6.7.3 muestra que esa constante cambia el coste semanal en menos de medio euro.

6.4 Verificación previa de los resultados

La Figura 6.1 muestra una semana completa de simulación con la Versión C: es la referencia visual sobre la que se leen tanto las comprobaciones de esta sección como el mecanismo que describen las siguientes.




Figura 6.1: Una semana completa del escenario laborable soleado con la Versión C, semilla 1. De arriba abajo: potencias en el bus de alterna (fotovoltaica, electrolizador, carga de vehículos, importación y exportación de red), precio horario del mercado diario, estado de carga de la batería con su reserva del 60 % y nivel de los dos tanques de hidrógeno con la zona crítica sombreada.

El residuo máximo del balance de potencia del nudo de alterna, que `guardar_resultados_ems.m` reconstruye en cada instante y normaliza por la escala de potencia de la instalación, es del orden de 10^{-15} %. El error de la previsión de precio a una hora es exactamente cero en las tandas con oráculo y en las dos tandas de C con el modo mercado diario, lo que funciona como control del diseño pareado.

Los integradores de los dos tanques de `OASIS.slx` tienen desactivada la saturación de salida, de modo que el inventario puede bajar de cero si una realización de la demanda agota el tanque antes de que el electrolizador reponga, y el nivel del tanque de alta se hace negativo en algunas simulaciones del escenario nublado. En esas tiradas el modelo sirve un hidrógeno que físicamente no tiene. El efecto se cuantifica con el indicador de hidrógeno no servido, es decir, los kilogramos dispensados con el inventario en negativo, y se valora al precio externo dentro de la métrica principal, de modo que una versión que deja el tanque vacío paga por ello. Activar la saturación queda como corrección pendiente del modelo.

6.5 El resultado de la variante predictiva

La Tabla 6.3 recoge la comparación de la variante predictiva contra A, sobre 24 horas y 40 pares, con la previsión real y con la perfecta. La lectura está en la Capítulo 5.4; aquí se dejan las cifras.

Versión – A, 24 h	Coste total con H ₂ (€/día)	mediana	gana	p rangos
B (variante predictiva)	-0,13	+0,11	15/40	0,17
B con oráculo	-0,67	+0,08	18/40	0,85

Tabla 6.3: Variante predictiva frente a la Versión A (24 h, 40 pares), sobre la métrica principal. Ninguna de las dos diferencias es significativa y ambas quedan muy por debajo del umbral de relevancia. Sobre el coste neto, sin hidrógeno, la diferencia es de +0,06 € (mediana +0,22, 9/40) para B y de +2,42 € (mediana +0,23, 13/40) con oráculo; esa media procede del escenario nublado, donde el arbitraje con previsión perfecta compra más red (+25 kWh/día) y a cambio deja menos hidrógeno sin servir, y la mediana es la cifra que describe a la población.

Dos cifras completan el cuadro. La primera es la sub-dispersión de la previsión de precio: en el escenario nublado el recorrido previsto es el 36 % del real (31,9 frente a 88,5 €/MWh), y el 55 % en promedio, de modo que el test económico del arbitraje, que exige un beneficio neto mínimo tras pérdidas, casi nunca se activa con la previsión real, y cuando se activa con la perfecta no compensa. La segunda es que sobre la semana (control de horizonte, con la regla a 6,12 €/kg) la variante predictiva pierde 1,02 € en 19 de 20 pares frente a un recibo de 391: ampliar el horizonte no mejora el resultado del arbitraje.

Donde la previsión sí mejora de forma sistemática es en el servicio de hidrógeno. Todas las variantes predictivas evaluadas a lo largo del trabajo mantienen el tanque de alta más lleno y pasan menos tiempo en nivel crítico que A, en los dos horizontes y con $p < 0,05$ en casi todas las celdas; para B, +0,07 puntos de nivel medio (39/40) y -0,11 puntos de tiempo crítico (28/40). Y el efecto escala con la calidad de la previsión: con oráculo pasa a +0,92 y -1,08, entre diez y trece veces más, y el hidrógeno no servido baja de tres eventos en A a dos, y a cero en la implementación sin dimensionar del arbitraje, que es la que más energía movía. En el escenario nublado la previsión perfecta llega a reducir el tiempo crítico 18,9 puntos, el mayor efecto de la previsión medido en el trabajo, en el mismo escenario en que el modelo de precio está más sub-disperso.

6.6 El diagnóstico: a dónde va la importación

La descomposición de la importación de A por destinos, sobre la semana, da el resultado que reorienta el trabajo:

Destino de la importación (A, semana)	kWh	%	Precio ponderado (€/MWh)
Vehículos	279	21	—
Electrolizador	1 006	76	121,5
Compresor	29	2	—
Batería	7	< 1	—
Total importado	1 321	100	121,5

Tabla 6.4: Destino de la energía importada por la Versión A sobre una semana, medias de 20 simulaciones. En el mismo periodo la estación exporta 14 012 kWh a 39,3 €/MWh de media: un ratio de 10,6 a 1 en energía y de 3 a 1 en precio.




Figura 6.2: Destino de la energía importada de la red, media semanal, para la Versión A y para las dos etapas de la Versión C. En A tres cuartas partes van al electrolizador; en C ese bloque se reduce a la mitad porque lo alimenta la batería.

En los instantes en que A importa para el electrolizador la batería está al 85,1 % de estado de carga de media y nunca baja del 69,1 %; ni el techo del 90 % ni el suelo del 20 % se tocan en toda la campaña semanal. El contrafactual de `medir_reserva_ociosa.m` indica que, con un piso del 60 %, el 79 % de esa importación podría haberse servido desde la batería y que la exportación posterior repone el 90 % de lo desviado, de modo que el flujo es sostenible y no consume una reserva. Por escenario, el electrolizador compra a 114 €/MWh en el laborable soleado, 112 en el fin de semana, 93 en el volátil y 149 en el nublado, donde compra en horas de hasta 194 €/MWh pese al umbral de 149 que la regla dice respetar: corresponde al defecto 7 de la Capítulo 5.5.

6.7 La Versión C

6.7.1 Frente a la heurística de referencia

C – A, semana, 20 pares	media	mediana	gana	<i>p</i> rangos
Coste total con hidrógeno (€)	-52,3 (-13,9 %)	-46,9	20/20	$9,6 \cdot 10^{-5}$
Coste corregido (€)	-56,8	-53,9	20/20	$9,6 \cdot 10^{-5}$
Coste neto (€)	-67,7 (-17,3 %)	-71,3	20/20	$9,6 \cdot 10^{-5}$
Importación (kWh)	-717 (-54 %)	-667	20/20	$9,6 \cdot 10^{-5}$
Autosuficiencia (puntos)	+6,7 (87,7 → 94,3)	+6,3	20/20	$9,6 \cdot 10^{-5}$
Energía descargada por la batería (kWh)	539 → 1 208 (×2,2)			
Tiempo en nivel crítico (puntos)	+4,0	+2,1	0/20	$9,6 \cdot 10^{-5}$
Nivel mínimo del tanque de alta (puntos)	-3,5	-2,4	2/20	$6,7 \cdot 10^{-4}$
Hidrógeno no servido (kg/semana, escenario nublado)	0,82 → 3,07			solo en ese escenario

Tabla 6.5: Versión C frente a la Versión A sobre una semana. Negativo es mejor en las tres filas de coste y en la importación. Las tres métricas de coste coinciden en signo y orden, y la diferencia supera en cinco veces el umbral de relevancia de 9,33 € por semana.




Figura 6.3: Coste total con hidrógeno por escenario y semana, Versión A frente a Versión C. Cada punto es una semilla; las líneas unen los pares con la misma demanda. Un valor negativo es un ingreso neto por la exportación.

La mejora aparece en los cuatro escenarios: $-49,0$ € en el laborable soleado, $-57,0$ en el nublado, $-36,8$ en el fin de semana y $-66,2$ en el volátil, en los cinco pares de cada uno. El orden no lo fija el excedente disponible para reponer, sino el precio al que compraba el electrolizador: el ahorro es mayor donde más caro compraba. El ahorro son los kilovatios-hora que pasan de la red a la batería multiplicados por el margen de precio, y esa cantidad manda sobre el excedente disponible.

Conviene situar la magnitud de esa diferencia, porque un porcentaje de mejora solo significa algo si se sabe contra qué se mide. La referencia no es una regla ingenua construida para perder, sino la heurística más avanzada del trabajo antecedente [7], ya validada sobre su propia microrred: incorpora de partida el reparto dinámico entre batería y electrolizador según el estado de carga, el tiempo mínimo de funcionamiento con histéresis y anti-rebote en los equipos electroquímicos, la gestión de los dos niveles de presión con su compresor y la decisión económica de producir frente a comprar (Capítulo 5.3). Es decir, la Versión A ya trae los mecanismos que distinguen a un EMS de reglas maduro de un simple reparto por prioridades, y las dos versiones comparadas están construidas sobre ese mismo código con un único bloque de diferencia. Que sobre esa base quede un 14 % del recibo sin capturar, y que se recupere con un cambio de diez líneas en el orden en que se usa la batería, es lo que da valor al resultado: el margen no estaba donde lo dejaría una heurística mal hecha, sino en una decisión que la regla de referencia tomaba correctamente por separado y no coordinaba. Los siete puntos de la Capítulo 5.5 matizan esta lectura sin invertirla: la referencia es una implementación buena pero no óptima, y por eso el trabajo declara cuál de sus defectos corrige (el 6, y el 7 solo en la decisión programada) y cuáles deja intactos en ambas versiones.

El precio de la mejora está en las tres últimas filas. La batería cicla 2,2 veces más energía, y la degradación no está modelada; el párrafo siguiente acota lo que eso puede valer. Y el servicio de hidrógeno empeora en el escenario nublado: el tiempo en nivel crítico sube 9,3 puntos y el hidrógeno no servido pasa de 0,82 a 3,07 kg por semana, lo que representa el 1,8 % de la demanda de esa semana frente al 0,5 % de A. Esa penalización está incluida en el coste total, y por eso en ese escenario el coste corregido mejora 75 € y el total solo 57; pero es un dato de operación que la métrica de coste no debe ocultar. El mecanismo no es el uso de la batería en sí: la pila de combustible no arranca en ninguna de las 40 simulaciones. Es su interacción con el defecto 3 de la Capítulo 5.5: al amanecer con

la batería por debajo del 80 %, el reparto por tramos asigna al electrolizador el 40 % del excedente en vez del 70 %, y en el día nublado no hay horas baratas para compensarlo.

El ciclado adicional solo puede acotarse en euros de forma aproximada. La Versión C descarga 669 kWh más por semana que A, dos tercios de un ciclo completo de la batería de 1 MWh. Una cuenta contable ingenua, con una inversión del orden de 300 €/kWh repartida entre los 3 000 a 4 000 ciclos de vida del ion-litio estacionario [23], asigna a cada ciclo completo entre 75 y 100 €, y al ciclado adicional de C entre 50 y 67 € por semana: del orden del ahorro de 52 €. Esa cuenta supone, sin embargo, que la batería muere por ciclos, y a este ritmo no lo hace: A completa unos 28 ciclos al año y C unos 63, de modo que agotar 3 500 ciclos llevaría más de medio siglo, muy por encima de la vida por calendario de 10 a 15 años que fija el final de la batería con las dos estrategias. Cuando domina el calendario, el coste marginal de un ciclo adicional es una fracción pequeña del contable y el ahorro de C se mantiene. Cuál es esa fracción no puede afirmarse sin un modelo de degradación por profundidad de descarga, como el que emplea [24] para dimensionar la batería de una estación de carga rápida; es la sensibilidad más importante que queda por hacer.




Figura 6.4: Un día del escenario nublado, hora a hora, para la misma semilla: precio, estado de carga de la batería, potencia del electrolizador e importación de red. En C la batería baja hasta la reserva del 60 % alimentando al electrolizador y la importación desaparece en esas horas; en A la batería se mantiene llena y el electrolizador consume red.




Figura 6.5: Nivel del tanque de alta a lo largo de la semana nublada, misma semilla, con la zona crítica sombreada. C pasa más tiempo en la zona crítica que A.

6.7.2 Ablación: cuánto vale cada componente

Contraste, coste total con H ₂ (€/semana)	media	mediana	gana	<i>p</i> rangos
C0 (solo batería → electrolizador) – A	−47,1	−45,4	20/20	$9,6 \cdot 10^{-5}$
C_p (+ programación con persistencia) – C0	−5,1	−3,0	19/20	$6,4 \cdot 10^{-4}$
C (+ programación con LSTM) – C_p	0,00	0,00	—	idénticas

Tabla 6.6: Ablación de la Versión C. Las dos últimas tandas son idénticas a precisión de máquina en los 40 indicadores de los 20 pares.

Alimentar el electrolizador desde la batería explica el 90 % de la mejora y supera el criterio de falsación —mejorar en los dos escenarios con excedente suficiente para reponer—, así como las predicciones de magnitud: la importación destinada al electrolizador cae un 48 % (se previó al menos un 40 %) y la energía descargada sube 811 kWh semanales (se previeron unos 1 000).

La programación añade 5,1 € por semana, significativa pero por debajo del umbral de relevancia. El mecanismo no está en el precio al que compra el electrolizador, que se mantiene (123,2 → 122,9 €/MWh), sino en el volumen: compra menos (−45 kWh) y produce algo menos de hidrógeno (−0,5 kg). En el escenario nublado sigue pagando 147 €/MWh porque la regla de emergencia en nivel crítico, que hereda el test económico de A con su defecto 7, actúa el 70 % del tiempo; el planificador solo manda fuera de esa banda, y ahí la batería ya cubre casi todo. El escenario volátil es, de hecho, donde menos aporta (−1,9 €).

La red neuronal de precio no cambia ningún resultado: su efecto es exactamente cero. La explicación está en la Capítulo 5.4: entre las 13:00 y las 24:00 las 24 horas del horizonte están publicadas, y por la mañana lo único no publicado son las primeras horas de la madrugada siguiente, las más baratas del día tanto para la red como para la persistencia, y por eso ninguna de las dos señales cambia nunca el orden de mérito. La previsión solar sí interviene en el planificador y no se ha aislado; su contribución está dentro de los 5,1 € de la programación.

6.7.3 Sensibilidad a los precios del hidrógeno

El primer supuesto variado es la constante de la regla. La ablación se ha ejecutado dos veces, con H2_PRECIO_EXT_KG a 8 €/kg (umbral de 149 €/MWh, la campaña que se reporta) y a 6,12 €/kg (umbral de 114). El cambio mueve el coste semanal de A 0,12 € de media (−0,49 € en el nublado y cero en los otros tres escenarios) y el de C 0,02 €, de modo que las diferencias pareadas de la Tabla 6.5 y la

Tabla 6.6 cambian, como mucho, en la primera decimal. La razón es el defecto 7 de la Capítulo 5.5: con el tanque de baja por encima del 68 % el test heredado evalúa solo el coste de comprimir, y el umbral económico casi nunca es el que decide. El nublado, único escenario con precios entre 114 y 149 €/MWh en horas de déficit, es también donde A ya compraba a 149 por esa misma vía.

El segundo supuesto es el precio de valoración. Las conclusiones de la Tabla 6.5 tampoco dependen de la valoración de la energía terminal ni del hidrógeno: el coste neto, el corregido y el total coinciden en signo y en orden de magnitud, y la diferencia de C es un orden de magnitud mayor que el efecto de valorar la batería al precio de importación en vez de al de exportación. No ocurría lo mismo en la comparación de la variante predictiva, donde el signo del coste corregido sobre la semana cambiaba según el precio de valoración entre 2,8 y 104 €/MWh; esa fragilidad es una de las razones por las que la semana se presenta allí como control de horizonte y no como evidencia principal.

7 Conclusiones

7.1 Respuesta a la pregunta del trabajo

El trabajo partió de una pregunta concreta: si una previsión de irradiancia y de precio basada en redes LSTM mejora un sistema de gestión de energía heurístico para una estación de repostaje multi-energía. La respuesta se descompone en tres resultados, todos ellos medidos.

La previsión, inyectada en las reglas de la heurística, no reduce el coste. La variante predictiva quedó indistinguible de la heurística en coste: la diferencia media es de una décima de euro sobre un recibo diario de unos 45 € en la métrica principal, no significativa y muy por debajo de la dispersión entre semillas. Esto se cumple tanto con la previsión real como con la perfecta. Llegar a ese empate exigió dimensionar la regla: una primera implementación que convertía «el precio va a subir» en una acción de magnitud fija empeoraba el coste, y lo empeoraba más cuanto mejor era la previsión, lo que muestra que el resultado depende de cómo la regla usa la previsión, no solo de su exactitud. Sí superó a la heurística de forma sistemática en la seguridad de suministro de hidrógeno: todas las variantes predictivas evaluadas mantuvieron el tanque de alta más lleno y redujeron el tiempo en nivel crítico, con una mejora que crece más de diez veces al pasar de la previsión real a la perfecta. La aportación medible de la predicción en este montaje está en el servicio de hidrógeno, no en el coste, y sobre todo en el día nublado, que es a la vez donde anticiparse vale más y donde el modelo de precio es peor.

El margen económico estaba en usar la batería para el electrolizador, y no necesitaba previsión. Al medir a dónde iba cada kilovatio-hora importado apareció el punto débil de la heurística heredada: entre el 74 % y el 78 % de la electricidad que compraba a la red era para el electrolizador, y en los instantes de compra la batería estaba al 85 % de media. La lógica servía la carga de los vehículos desde la batería y, en un paso posterior, encendía el electrolizador contra la red. La Versión C cambia ese orden (ofrece esa carga a la batería antes que a la red) y programa la producción de hidrógeno en las horas más baratas del horizonte sobre el precio ya publicado. Sobre siete días y veinte pares escenario-semilla reduce el coste total con hidrógeno en 52,3 € por semana de media (un 13,9 % del recibo, mejor en los veinte pares, $p = 9,6 \cdot 10^{-5}$), importa un 54 % menos energía y eleva la autosuficiencia del 87,7 % al 94,3 %. De esa mejora, 47,1 € proceden de ese cambio de orden y 5,1 de la programación; esta segunda cifra es significativa pero inferior al umbral de relevancia de 9,3 € fijado de antemano.

Añadir la red neuronal de precio a la Versión C no cambió ningún resultado. La tanda que la sustituye por la persistencia de 24 horas produjo exactamente los mismos veinte resultados, KPI por KPI. La razón es que la información que la decisión necesita ya está disponible: el mercado diario publica a las 13:00 el precio del día siguiente, y las horas que quedan por prever —la madrugada siguiente, cuando se evalúa por la mañana— no alteran nunca el orden de mérito. La previsión de precio es correcta, pero innecesaria en esta decisión. La previsión solar sí interviene en la Versión C, al estimar el excedente que podrá absorber el electrolizador, pero su contribución queda dentro de los 5,1 € de la programación y no se aisló.

La conclusión general no es que la predicción no sirva: su valor depende de en qué decisión se inserte y de qué información no esté ya disponible. En esta instalación el margen estaba en una decisión que la información instantánea ya permitía tomar (alimentar el electrolizador desde la batería), y la previsión aporta donde hay incertidumbre real, que es el suministro de hidrógeno en los días de poco sol.

7.2 Aportaciones

- Un EMS para la estación OASIS que mejora un 14 % del coste semanal, en los veinte casos evaluados, al heurístico de referencia —que no es una regla ingenua, sino la heurística más avanzada del trabajo antecedente, con reparto dinámico batería-electrolizador, tiempo mínimo de funcionamiento con histéresis y decisión económica de producción ya incorporados—, y lo hace con un cambio de diez líneas en el orden en que se usa la batería y un planificador de orden de mérito que solo usa el orden de los precios y es por tanto insensible a la sub-dispersión de la previsión.
- La identificación y medida de dos defectos del EMS heredado que no estaban documentados: la batería que no alimentaba al electrolizador y el test económico del compresor aplicado al electrolizador, que en el escenario nublado llevaba a fabricar hidrógeno por encima de su precio de reposición.
- Una cadena de medida para atribuir el valor de una previsión dentro de un controlador: comparación pareada por semilla con test de rangos, oráculo como cota superior, descomposición de la importación por destinos y ablación por componentes con predicciones declaradas antes de simular. El margen se localizó con esta cadena de medida, no a partir de la pregunta inicial.
- Dos modelos LSTM validados contra líneas base no triviales, con la medida de que un error medio competitivo puede convivir con una señal inservible para decisiones que dependen de la amplitud, y la corrección del despliegue en lazo cerrado de la red de precio.
- La observación, incorporada al diseño, de que en el mercado español el precio del día siguiente es un dato publicado y no algo que predecir, lo que reordena el papel de cualquier modelo de precio en un EMS con horizonte diario.

7.3 Limitaciones

Las principales están declaradas a lo largo del documento y se recogen aquí juntas. El modelo no incluye peajes ni cargos, igual que su antecedente, y las cifras de coste son comparativas, no de facturación. No hay compra externa de hidrógeno modelada; el déficit se valora al precio externo como coste de oportunidad. Los tanques usan la ecuación de los gases ideales, que a los 600 bar del tanque de alta sobrestima en torno a un 45 % la masa almacenada, de modo que la autonomía de hidrógeno observada en simulación es optimista respecto a la de una instalación real. La demanda de hidrógeno se aproxima por analogía con la de vehículos eléctricos, y el planificador la prevé con una media móvil. La irradiancia de la última hora que alimenta la red solar procede de un reanálisis que no está disponible en tiempo real. La degradación de la batería no está modelada: la Versión C cicla 2,2 veces más energía que la heurística y, aunque a 63 ciclos completos al año la vida de la batería la fija el calendario y no el ciclado, el coste marginal de ese ciclado extra queda sin cuantificar (Capítulo 6.7). La pila de combustible no arranca en ninguna simulación, porque la batería cubre siempre el déficit antes que ella; el trabajo no dice nada del escenario en que aportaría, el modo isla con la batería agotada. El servicio de hidrógeno empeora en el escenario nublado (tiempo en nivel crítico +4,0 puntos, hidrógeno no servido del 1,8 % frente al 0,5 % de la demanda de esa semana), penalización incluida en el coste total pero relevante para la operación. Y la campaña semanal tiene cinco semillas por escenario, suficientes para el tamaño de efecto de la Versión C pero no para diferencias del orden del euro.

7.4 Líneas futuras

1. Aislar la previsión solar con una tanda que la sustituya por la persistencia de cielo claro, igual que se hizo con la de precio. Es la única previsión que decide algo en la Versión C y no está aislada.
2. Fijar un objetivo de inventario del tanque con previsión. El oráculo mostró que anticipar el día nublado lleva el hidrógeno no servido a cero; una regla que eleve el objetivo del tanque la víspera de un día de poca irradiancia es el sitio donde la previsión solar tiene más recorrido, y exige una previsión de demanda de hidrógeno.
3. Corregir el test económico en la regla de emergencia y los otros defectos anotados del EMS heredado, evaluando cada corrección por separado.
4. Sustituir la heurística por un controlador predictivo con horizonte deslizante, en la línea de [45] y [34], con un valor terminal para la batería y el hidrógeno que evite la posición abierta al final del horizonte. La medida de este trabajo acota lo que puede esperarse: con el precio publicado, la ganancia adicional vendría de coordinar batería y electrolizador, no de predecir mejor.
5. Añadir la compra externa de hidrógeno por lotes con puerto propio, que convertiría la decisión de producir en un problema de reposición con coste fijo de pedido, y comprobar la Versión C con una cadena de datos operativa (previsión meteorológica numérica y piranómetro) en lugar de reanálisis.
6. Modelar la degradación de la batería y simular un horizonte anual. Un conteo de ciclos por profundidad de descarga convertiría el ciclado en coste y diría qué parte del 14 % sobrevive; y una simulación de un año completo capturaría la estacionalidad de la irradiancia y del precio que los cuatro escenarios solo muestrean.
7. Someter a las dos versiones a una prueba de estrés de demanda, repitiendo A y C con la demanda de vehículos e hidrógeno multiplicada sobre el horizonte semanal, para comprobar si la ventaja de C se mantiene con más carga o se agota al agotarse la batería. Es la comprobación natural del mecanismo, porque todo el ahorro de C descansa en que la batería tenga energía por encima de la reserva cuando el electrolizador la pide. El paso siguiente es una estación futura: duplicar el tráfico, duplicar con él el número de surtidores para que la espera en cola no sea el cuello de botella, y repetir con el campo fotovoltaico actual y ampliado, que separaría si las reglas siguen siendo válidas cuando la estación crece y cuánta generación local hace falta para que crecer no se traduzca en depender más de la red. La herramienta de simulación admite ya ese barrido sin tocar el modelo: los factores de llegada, el número de surtidores y el número de cadenas del campo fotovoltaico son parámetros de la campaña.

8 Anexo: código y datos del trabajo

Todo el material necesario para reproducir este trabajo está publicado en

<https://github.com/USUARIO/REPOSITORIO>

y no se adjunta impreso. El repositorio contiene el modelo de Simulink, los EMS comparados, los dos modelos LSTM ya entrenados, los datos de entrada, los CSV con los indicadores de todas las simulaciones de la campaña y la fuente de esta memoria.

Carpeta	Contenido
SimugridElectrolinera/	El modelo 0ASIS.slx, su script de preparación init_0ASIS.m y las dos S-Functions de previsión, lstm_sol.m y lstm_precios.m.
codigo/EMS/	Las Versiones A, B y C del EMS, más C0. Cada una es el archivo que se pega en el bloque MATLAB Function del modelo. La constante H2_PRECIO_EXT_KG viene a los 8 €/kg de la campaña que se reporta; a 6,12 €/kg se obtiene la de sensibilidad.
codigo/herramientas/	La campaña de simulación, el cálculo de indicadores, el contraste pareado, la descomposición de la importación y la generación de las figuras del Capítulo 6.
codigo/preparar/	Generación del perfil estocástico de demanda y construcción del <i>workspace</i> de Simulink a partir de los datos.
codigo/entrenar/	Entrenamiento de los dos modelos LSTM del Capítulo 4.
codigo/modelos/	Los dos modelos ya entrenados que consumen las S-Functions.
codigo/python/	Descarga y análisis de los datos de NASA POWER, ENTSO-E, DESL-EPFL y Caltech, y las figuras del Capítulo 3.
codigo/data/	Los datos descargados y procesados que alimentan la simulación.
codigo/resultados/	Los CSV con los indicadores de todas las simulaciones y sus agregados, de los que salen las tablas y las figuras del Capítulo 6.
memoria/	La fuente de este documento.

Tabla 8.1: Contenido del repositorio del trabajo.

El fichero README.md de la raíz detalla la secuencia completa de reproducción: qué scripts regeneran los datos y los modelos, qué EMS corresponde a cada tanda de la campaña con qué semillas y qué horizonte, y qué funciones producen las tablas y las figuras. No se versionan los .mat de resultados ni los perfiles de demanda, porque son regenerables: el generador de tráfico es determinista dada su semilla, y los CSV incluidos llevan todos los indicadores que se citan en la memoria.

Índice de Figuras

2.1.	Cadena de producción, almacenamiento y dispensación de hidrógeno de OASIS. El electrolizador entrega a la presión máxima del tanque tampón, de modo que la compresión solo interviene en la etapa siguiente. Los umbrales que acompañan a cada tanque son los que gobiernan la decisión del EMS y se justifican en el Capítulo 5; LOH y LOH_High son fracciones de la presión máxima de su propio tanque, no de la masa almacenada.	10
3.1.	Distribución de llegadas de EV por hora del día. Dataset DESL-EPFL.	19
3.2.	Distribución de energía cargada por sesión. Media: 32.2 kWh, mediana: 29.4 kWh.	19
3.3.	Distribución del estado de carga (SOC) de llegada y salida.	20
3.4.	Distribución de potencia media por sesión: Level 2 vs Level 3.	22
3.5.	Relación energía vs duración: Level 2 (izq) vs Level 3 (der).	22
3.6.	Distribución de duración de sesiones en DESL-EPFL. Media: 33 min, mediana: 30 min.	24
3.7.	Espera media en cola W_q (Erlang C) frente al número de cargadores, para $\lambda = 0.71$ EV/h y $\mu = 1.55$ servicios/h. El salto entre $c = 1$ y $c = 2$ (de ≈ 33 min a ≈ 2 min) sustenta la elección de 2 cargadores; a partir de $c = 3$ la mejora es marginal.	25
3.8.	Sesiones por día de la semana. Laborables en azul, fines de semana en rojo.	28
3.9.	Perfil de potencia demandada por los cargadores EV (modo laborable). Cada pulso corresponde a una sesión de carga con curva CC-CV.	29
4.1.	Curva de entrenamiento del modelo LSTM solar: evolución del error cuadrático medio en entrenamiento y validación a lo largo de las épocas.	35
4.2.	Predicción LSTM solar ($h+1$) vs. irradiancia real ALLSKY durante una semana del conjunto de test (Sevilla, NASA POWER).	36
4.3.	Predicción LSTM solar completa a 24 horas para un día de test. Cada punto corresponde a un horizonte $h+1$, $h+2$, ..., $h+24$.	36

4.4.	Predicción de irradiancia frente al valor real de NASA POWER en los cuatro días de la campaña de simulación.	40
4.5.	Curva de entrenamiento del modelo LSTM de precio: evolución del error en entrenamiento y validación. La parada temprana (<i>early stopping</i>) se activa cuando la pérdida de validación no mejora durante 15 épocas consecutivas.	46
4.6.	Predicción LSTM de precio (línea roja) vs. precio real ENTSO-E (línea azul) para tres días del conjunto de test de 2025. La línea punteada representa el <i>baseline</i> de persistencia lag-24 (precio de ayer a la misma hora).	47
4.7.	Error MAE del modelo LSTM de precio por horizonte temporal (h+1 a h+24), comparado con las líneas base de persistencia lag-24 y lag-168.	48
4.8.	Predicción del modelo de precio frente al precio real ENTSO-E en los cuatro días seleccionados para la campaña de simulación.	50
5.1.	Vistas isométricas de la estación OASIS desde los cuatro cuadrantes (noroeste, noreste, suroeste y sureste). Las dos marquesinas fotovoltaicas cubren los dos cargadores de vehículo eléctrico de 50 kW y el surtidor de hidrógeno; el recinto vallado agrupa los contenedores de batería, electrolizador, compresor y pila de combustible, el tanque tampón de baja presión y el bastidor de botellas de alta presión.	58
5.2.	Arquitectura por módulos del modelo OASIS.slx. Los bloques se agrupan por la red que intercambian: consignas del EMS hacia los equipos (trazo discontinuo naranja), medidas de los equipos hacia el EMS (discontinuo gris), potencia eléctrica en el bus de alterna (azul) y flujo de hidrógeno (verde), con los nombres de las señales tal y como aparecen en Simulink. El EMS es un único bloque MATLAB Function con once entradas y seis salidas; las dos S-Functions de previsión le entregan PVPred y PrecioPred.	59
5.3.	Lógica de decisión del EMS. En gris, la lógica común heredada de la Versión A: balance, reparto por estado de carga en la rama de excedente, cobertura del déficit por orden de mérito, decisión económica de producir hidrógeno y máquina de estados. En azul, los dos únicos cambios de la Versión C: la carga del electrolizador y del compresor se ofrece a la batería antes que a la red, y la decisión de producir pasa a ser un planificador de orden de mérito a 24 h que consume el precio publicado del mercado diario, la previsión de precio en las horas no publicadas y la previsión solar. La variante predictiva inyectaba las previsiones en los bloques 2 y 3 de A y no se representa.	63
5.4.	Los cuatro escenarios en su fecha: precio horario del mercado diario (arriba) e irradiancia horizontal real frente a la de cielo claro (abajo), con el índice de claridad k_t del día. Las cuatro columnas comparten escala, de modo que la comparación entre ellas es directa.	71

- 6.1. Una semana completa del escenario laborable soleado con la Versión C, semilla 1. De arriba abajo: potencias en el bus de alterna (fotovoltaica, electrolizador, carga de vehículos, importación y exportación de red), precio horario del mercado diario, estado de carga de la batería con su reserva del 60 % y nivel de los dos tanques de hidrógeno con la zona crítica sombreada. 77
- 6.2. Destino de la energía importada de la red, media semanal, para la Versión A y para las dos etapas de la Versión C. En A tres cuartas partes van al electrolizador; en C ese bloque se reduce a la mitad porque lo alimenta la batería. 79
- 6.3. Coste total con hidrógeno por escenario y semana, Versión A frente a Versión C. Cada punto es una semilla; las líneas unen los pares con la misma demanda. Un valor negativo es un ingreso neto por la exportación. 80
- 6.4. Un día del escenario nublado, hora a hora, para la misma semilla: precio, estado de carga de la batería, potencia del electrolizador e importación de red. En C la batería baja hasta la reserva del 60 % alimentando al electrolizador y la importación desaparece en esas horas; en A la batería se mantiene llena y el electrolizador consume red. 81
- 6.5. Nivel del tanque de alta a lo largo de la semana nublada, misma semilla, con la zona crítica sombreada. C pasa más tiempo en la zona crítica que A. 82

Índice de Tablas

2.1.	Principales estándares de carga rápida DC para vehículos eléctricos.	13
3.1.	Características principales del dataset DESL-EPFL	18
3.2.	Clasificación de cargadores de EV por nivel de potencia (convención SAE J1772).	20
3.3.	Comparación entre cargadores Level 2 y Level 3.	21
3.4.	Comparación de métricas reales entre Level 2 y Level 3, medidas sobre los datasets Caltech (Level 2) y DESL-EPFL (Level 3).	21
3.5.	Comparación de opciones de potencia para el cargador DC. Tiempo calculado con $t = \frac{E}{P}$ y la energía media del dataset (32.2 kWh) para las cuatro potencias, de forma consistente con el cálculo de la sección anterior. Capacidad teórica máxima con 2 cargadores operando 14 h (8:00-22:00) sin tiempos muertos entre sesiones — un límite superior, no la demanda esperada.	24
3.6.	Espera media en cola en la hora punta (18:00) según el número de cargadores, modelo M/M/c con $\lambda = 0.71$ EV/h y $\mu = 1.55$ servicios/h.	25
3.7.	Dimensionamiento de cargadores EV, basado en el análisis de colas de la Tabla 3.6.	26
4.1.	Features de entrada al modelo LSTM solar (8 variables).	33
4.2.	Arquitectura de la red LSTM solar.	34
4.3.	Hiperparámetros de entrenamiento del modelo LSTM solar.	34
4.4.	Métricas de validación del modelo LSTM solar por horizonte, sobre el conjunto de test (05-feb-2024 a 30-dic-2025, 16 647 secuencias).	36
4.5.	Comparación del modelo LSTM solar con las líneas base, sobre el mismo conjunto de test. La última fila corresponde a una curva de cielo claro escalada por una constante, un modelo que no incorpora ninguna información meteorológica.	37
4.6.	MAE (Wh/m ²) del modelo LSTM solar frente a la persistencia de cielo claro por horizonte, y mejora relativa. El modelo aporta información hasta h+4 y a partir de h+5 es superado por la línea base.	38

4.7.	MAE (Wh/m ²) del modelo LSTM solar y de la persistencia de cielo claro en los cuatro días de la campaña de simulación.	38
4.8.	Efecto de proyectar la predicción sobre la envolvente de cielo claro, sobre el mismo conjunto de test. MAE en Wh/m ² .	41
4.9.	MAE (Wh/m ²) por horizonte antes y después de proyectar sobre la envolvente. El desglose se calculó con $k_{\max} = 1,10$, el techo con el que se hizo el diagnóstico; el techo que finalmente se despliega es 1,00 (Tabla 4.8). La mejora se concentra en las primeras horas y se anula en el tramo central.	41
4.10.	Comparación de las cuatro señales sobre el conjunto de test. La combinada es la única que bate a la línea base en el agregado de 24 h. MAE en Wh/m ² .	42
4.11.	Features de entrada al modelo LSTM de precio (14 variables).	44
4.12.	Arquitectura de la red LSTM de precio.	45
4.13.	Hiperparámetros de entrenamiento del modelo LSTM de precio.	45
4.14.	Métricas del modelo LSTM de precio frente a las líneas base de persistencia, sobre el conjunto de test de 2025. MAE y RMSE en €/MWh.	47
4.15.	Importancia de las <i>features</i> del modelo de precio por permutación, medida como incremento del MAE (€/MWh) al aleatorizar cada variable sobre el conjunto de test.	48
4.16.	Error del modelo de precio en los cuatro escenarios de la campaña de simulación (Tabla 5.7), frente a la persistencia de 24 horas. MAE en €/MWh.	49
4.17.	Efecto de la combinación convexa en el modelo de precio, sobre el conjunto de test. MAE en €/MWh.	51
4.18.	Degradación del modelo de precio al pasar de evaluación en lazo abierto a lazo cerrado con realimentación de la propia predicción. En el agregado, el MAE pasa de 21,65 a 27,64 €/MWh.	51
4.19.	Comparación de características y resultados de los dos modelos LSTM desarrollados.	53
5.1.	Configuración de la estación OASIS tal y como está parametrizada en OASIS.slx. Las cifras de hidrógeno almacenado siguen la ecuación de estado del propio bloque, que sobrestima la masa a alta presión; el efecto sobre la lectura de los resultados se discute en el Capítulo 2.	57

5.2.	Reescalado de los umbrales de nivel de tanque de [7] (bar, sobre su rango de diseño) a los límites propios de OASIS (%). Cada porcentaje es la fracción que el umbral representa sobre el rango de diseño de su propio tanque, y LOH es en ambos casos una fracción de presión, por lo que el traslado es dimensionalmente consistente. Lo que se conserva es la posición relativa del umbral dentro del rango útil, no la presión absoluta: el 76 % equivale a 680 bar sobre los 900 bar de [7] y a 456 bar sobre los 600 bar con los que está parametrizado el tanque de OASIS.	61
5.3.	Parámetros de decisión de la Versión A, comunes a las tres versiones comparadas. Los umbrales de nivel de los dos tanques están en la Tabla 5.2 y la configuración física de la instalación, en la Tabla 5.1.	62
5.4.	Defectos del EMS heredado que se dejan anotados, sin corregir ni evaluar en este trabajo, detectados por inspección del código de <code>ems_A.m</code> . La numeración es la que emplea el texto al referirse a ellos.	65
5.5.	Parámetros propios de la Versión C. Todos los demás son los de la Versión A.	68
5.6.	Ablación de la Versión C. Las tres tandas usan el mismo fichero <code>ems_C.m</code> ; C0 desactiva el planificador con un interruptor, y las dos últimas difieren únicamente en el modo de la S-Function de precio (C_p, planificador con persistencia en el tramo no publicado; C, con la LSTM). En las etiquetas de los ficheros de resultados son E0, E_sinLSTM y E. La previsión solar está presente en las tres y no se aísla.	68
5.7.	Escenarios de la campaña de simulación. Cada uno se ejecuta con varias semillas del generador de demanda y para cada versión del EMS, con las mismas semillas en todas ellas.	70
6.1.	Cadena de <i>scripts</i> que produce cada simulación de la campaña.	74
6.2.	Tandas ejecutadas. Los pares son combinaciones escenario × semilla; las semillas son las mismas en todas las tandas de un mismo horizonte. Todas las tandas llevan en la regla el coste de reposición de 8 €/kg salvo el control de horizonte de B, que conserva el índice de 6,12; la Capítulos 6.7.3 muestra que esa constante cambia el coste semanal en menos de medio euro.	76
6.3.	Variante predictiva frente a la Versión A (24 h, 40 pares), sobre la métrica principal. Ninguna de las dos diferencias es significativa y ambas quedan muy por debajo del umbral de relevancia. Sobre el coste neto, sin hidrógeno, la diferencia es de +0,06 € (mediana +0,22, 9/40) para B y de +2,42 € (mediana +0,23, 13/40) con oráculo; esa media procede del escenario nublado, donde el arbitraje con previsión perfecta compra más red (+25 kWh/día) y a cambio deja menos hidrógeno sin servir, y la mediana es la cifra que describe a la población.	78

6.4.	Destino de la energía importada por la Versión A sobre una semana, medias de 20 simulaciones. En el mismo periodo la estación exporta 14 012 kWh a 39,3 €/MWh de media: un ratio de 10,6 a 1 en energía y de 3 a 1 en precio.	78
6.5.	Versión C frente a la Versión A sobre una semana. Negativo es mejor en las tres filas de coste y en la importación. Las tres métricas de coste coinciden en signo y orden, y la diferencia supera en cinco veces el umbral de relevancia de 9,33 € por semana.	79
6.6.	Ablación de la Versión C. Las dos últimas tandas son idénticas a precisión de máquina en los 40 indicadores de los 20 pares.	82
8.1.	Contenido del repositorio del trabajo.	88

Bibliografía

- [1] European Commission, «The European Green Deal». 2019.
- [2] European Environment Agency, «Transport and environment report 2021: Decarbonising road transport — the role of vehicles, fuels and transport demand», Copenhagen, technical report EEA Report 02/2022, 2022.
- [3] P. Speers, «Hydrogen Mobility Europe (H2ME): Vehicle and Hydrogen Refuelling Station Deployment Results», *World Electric Vehicle Journal*, vol. 9, n.º 1, p. 2, 2018, doi: 10.3390/wevj9010002.
- [4] Fuel Cells and Hydrogen 2 Joint Undertaking, «Hydrogen Roadmap Europe: A sustainable pathway for the European energy transition», Luxembourg, technical report, 2019. doi: 10.2843/341510.
- [5] M. Tahir, S. Hu, T. Khan, y H. Zhu, «Sustainable hybrid station design framework for electric vehicle charging and hydrogen vehicle refueling based on multiple attributes», *Energy Conversion and Management*, vol. 300, p. 117922, 2024, doi: 10.1016/j.enconman.2023.117922.
- [6] MITECO, «Hoja de Ruta del Hidrógeno: una apuesta por el hidrógeno renovable», Madrid, España, technical report, 2020.
- [7] F. Molero Almazán, «Desarrollo y simulación de un EMS tipo heurístico para una microrred híbrida con almacenamiento de hidrógeno», Trabajo Fin de Máster, Máster en Ingeniería Industrial, Sevilla, España, 2025.
- [8] International Energy Agency, «Global Hydrogen Review 2023», Paris, technical report, 2023.
- [9] Ministerio para la Transición Ecológica y el Reto Demográfico, «Plan Nacional Integrado de Energía y Clima 2023–2030», Madrid, technical report, 2024.
- [10] Parlamento Europeo y Consejo de la Unión Europea, «Reglamento (UE) 2023/1804 relativo a la implantación de una infraestructura para los combustibles alternativos». 2023.
- [11] Interempresas / Redacción, «Repsol inaugura la primera estación de servicio multienergía de las Islas Canarias». [En línea]. Disponible en: <https://www.interempresas.net/Estaciones-servicio/586244-Repsol-inaugura-su-nueva-estacion-de-servicio-multienergia-en-las-Islas-Canarias.html>
- [12] M. F. Roslan *et al.*, «Techno-economic impact analysis for renewable energy-based hydrogen storage integrated grid electric vehicle charging stations in different potential locations of Malaysia», *Energy Strategy Reviews*, vol. 54, p. 101478, 2024, doi: 10.1016/j.esr.2024.101478.

- [13] Z. Zhu, X. Liu, X. Kong, L. Ma, K. Y. Lee, y Y. Xu, «PV/Hydrogen DC microgrid control using distributed economic model predictive control», *Renewable Energy*, vol. 222, p. 119871, 2024, doi: 10.1016/j.renene.2023.119871.
- [14] Solargis, «Solar resource map: Global Horizontal Irradiation (GHI) Spain». [En línea]. Disponible en: <https://solargis.com/maps-and-gis-data/download/spain>
- [15] R. Perez, P. Ineichen, R. Seals, J. Michalsky, y R. Stewart, «Modeling daylight availability and irradiance components from direct and global irradiance», *Solar Energy*, vol. 44, n.º 5, pp. 271-289, 1990, doi: 10.1016/0038-092X(90)90055-H.
- [16] S. A. Grigoriev, V. N. Fateev, D. G. Bessarabov, y P. Millet, «Current status, research trends, and challenges in water electrolysis science and technology», *International Journal of Hydrogen Energy*, vol. 45, n.º 49, pp. 26036-26058, 2020, doi: 10.1016/j.ijhydene.2020.03.109.
- [17] IRENA, «Green Hydrogen Cost Reduction: Scaling up Electrolysers to Meet the 1.5 C Climate Goal», Abu Dhabi, technical report, 2020.
- [18] A. Buttler y H. Spliethoff, «Current status of water electrolysis for energy storage, grid balancing and sector coupling via power-to-gas and power-to-liquids: A review», *Renewable and Sustainable Energy Reviews*, vol. 82, n.º 3, pp. 2440-2454, 2018, doi: 10.1016/j.rser.2017.09.003.
- [19] S. Shiva Kumar y V. Himabindu, «Hydrogen production by PEM water electrolysis — A review», *Materials Science for Energy Technologies*, vol. 2, n.º 3, pp. 442-454, 2019, doi: 10.1016/j.mset.2019.03.002.
- [20] A. Ursúa, L. M. Gandía, y P. Sanchis, «Hydrogen production from water electrolysis: current status and future trends», *Proceedings of the IEEE*, vol. 100, n.º 2, pp. 410-426, 2012, doi: 10.1109/JPROC.2011.2156750.
- [21] G. Sdanghi, G. Maranzana, A. Celzard, y V. Fierro, «Review of the current technologies and performances of hydrogen compression for stationary and automotive applications», *Renewable and Sustainable Energy Reviews*, vol. 102, pp. 150-170, 2019, doi: 10.1016/j.rser.2018.11.028.
- [22] J. Larminie y A. Dicks, *Fuel Cell Systems Explained*, 2.^a ed. John Wiley & Sons, 2003.
- [23] M. Faisal, M. A. Hannan, P. J. Ker, A. Hussain, M. Mansor, y F. Blaabjerg, «Review of Energy Storage System Technologies in Microgrid Applications: Issues and Challenges», *IEEE Access*, vol. 6, pp. 35143-35164, 2018, doi: 10.1109/ACCESS.2018.2841407.
- [24] W. ur Rehman, R. Bo, H. Mehdipourpicha, y J. W. Kimball, «Sizing battery energy storage and PV system in an extreme fast charging station considering uncertainties and battery degradation», *Applied Energy*, vol. 313, p. 118745, 2022, doi: 10.1016/j.apenergy.2022.118745.
- [25] A. Gulraiz *et al.*, «Energy advancements and integration strategies in hydrogen and battery storage for renewable energy systems», *iScience*, vol. 28, n.º 3, p. 111945, 2025, doi: 10.1016/j.isci.2025.111945.
- [26] CharIN, «White Paper: Megawatt Charging System (MCS), version 2.0». [En línea]. Disponible en: https://www.charin.global/media/pages/technology/knowledge-base/0c2cc2c8da-1747654352/250508_whitepaper_megawatt_charging_system_2.0.pdf
- [27] J. Van Roy, N. Leemput, F. Geth, J. Büscher, R. Salenbien, y J. Driesen, «Electric Vehicle Charging in an Office Building Microgrid With Distributed Energy Resources», *IEEE Transactions on Sustainable Energy*, vol. 5, n.º 4, pp. 1389-1396, 2014, doi: 10.1109/TSTE.2014.2314754.

- [28] IEEE, «IEEE Guide for Design, Operation, and Integration of Distributed Resource Island Systems with Electric Power Systems». 2011.
- [29] D. T. Ton y M. A. Smith, «The U.S. Department of Energy's Microgrid Initiative», *Electricity Journal*, vol. 25, n.º 8, pp. 84-94, 2012, doi: 10.1016/j.tej.2012.09.013.
- [30] D. E. Olivares *et al.*, «Trends in Microgrid Control», *IEEE Transactions on Smart Grid*, vol. 5, n.º 4, pp. 1905-1919, 2014, doi: 10.1109/TSG.2013.2295514.
- [31] J. Pascual, J. Barricarte, P. Sanchis, y L. Marroyo, «Energy management strategy for a renewable-based residential microgrid with generation and demand forecasting», *Applied Energy*, vol. 158, pp. 12-25, 2015, doi: 10.1016/j.apenergy.2015.08.040.
- [32] C. E. Garcia, D. M. Prett, y M. Morari, «Model predictive control: theory and practice—a survey», *Automatica*, vol. 25, n.º 3, pp. 335-348, 1989, doi: 10.1016/0005-1098(89)90002-2.
- [33] A. T. D. Perera y P. Kamalaruban, «Applications of reinforcement learning in energy systems», *Renewable and Sustainable Energy Reviews*, vol. 137, p. 110618, 2021, doi: 10.1016/j.rser.2020.110618.
- [34] F. García-Torres y C. Bordons, «Optimal Economical Schedule of Hydrogen-Based Microgrids With Hybrid Storage Using Model Predictive Control», *IEEE Transactions on Industrial Electronics*, vol. 62, n.º 8, pp. 5195-5207, 2015, doi: 10.1109/TIE.2015.2412524.
- [35] D. Apostolou y G. Xydis, «A literature review on hydrogen refuelling stations and infrastructure. Current status and future prospects», *Renewable and Sustainable Energy Reviews*, vol. 113, p. 109292, 2019, doi: 10.1016/j.rser.2019.109292.
- [36] H. Wang, Z. Lei, X. Zhang, B. Zhou, y J. Peng, «A review of deep learning for renewable energy forecasting», *Energy Conversion and Management*, vol. 198, p. 111799, 2019, doi: 10.1016/j.enconman.2019.111799.
- [37] S. Aslam, H. Herodotou, S. M. Mohsin, N. Javaid, N. Ashraf, y S. Aslam, «A survey on deep learning methods for power load and renewable energy forecasting in smart microgrids», *Renewable and Sustainable Energy Reviews*, vol. 144, p. 110992, 2021, doi: 10.1016/j.rser.2021.110992.
- [38] A. D. Quansah *et al.*, «Assessment of solar radiation resource from the NASA-POWER reanalysis products for tropical climates in Ghana towards clean energy application», *Scientific Reports*, vol. 12, p. 10684, 2022, doi: 10.1038/s41598-022-14126-9.
- [39] R. Weron, «Electricity price forecasting: A review of the state-of-the-art with a look into the future», *International Journal of Forecasting*, vol. 30, n.º 4, pp. 1030-1081, 2014, doi: 10.1016/j.ijforecast.2014.08.008.
- [40] J. Lago, G. Marcjasz, B. De Schutter, y R. Weron, «Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark», *Applied Energy*, vol. 293, p. 116983, 2021, doi: 10.1016/j.apenergy.2021.116983.
- [41] F. Ziel y R. Steinert, «Probabilistic mid- and long-term electricity price forecasting», *Renewable and Sustainable Energy Reviews*, vol. 94, pp. 251-266, 2018, doi: 10.1016/j.rser.2018.05.038.
- [42] T. Janke y F. Steinke, «Forecasting the Price Distribution of Continuous Intraday Electricity Trading», *Energies*, vol. 12, n.º 22, p. 4262, 2019, doi: 10.3390/en12224262.

-
- [43] HOMER Energy, «HOMER Pro Microgrid Software». [En línea]. Disponible en: <https://www.homerenergy.com/>
- [44] MathWorks, «Simscape Electrical: Model and simulate electrical power systems». [En línea]. Disponible en: <https://www.mathworks.com/products/simscape-electrical.html>
- [45] C. Bordons, F. García-Torres, y M. A. Ridao, *Model Predictive Control of Microgrids*. en *Advances in Industrial Control*. Springer Nature Switzerland, 2020. doi: 10.1007/978-3-030-24570-2.
- [46] DESL-EPFL, «Level 3 EV Charging Dataset». [En línea]. Disponible en: <https://github.com/DESL-EPFL/Level-3-EV-charging-dataset>
- [47] Caltech y JPL, «ACN-Data: Adaptive Charging Network Data». [En línea]. Disponible en: <https://ev.caltech.edu/>
- [48] A. Shukla, K. Verma, y R. Kumar, «Voltage-dependent modelling of fast charging electric vehicle load considering battery characteristics», *IET Electrical Systems in Transportation*, vol. 8, n.º 4, pp. 221-230, 2018, doi: 10.1049/iet-est.2017.0096.
- [49] S. Hochreiter y J. Schmidhuber, «Long Short-Term Memory», *Neural Computation*, vol. 9, n.º 8, pp. 1735-1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [50] NASA Langley Research Center, «NASA POWER — Prediction Of Worldwide Energy Resources». [En línea]. Disponible en: <https://power.larc.nasa.gov/>
- [51] J. M. Bates y C. W. J. Granger, «The Combination of Forecasts», *Journal of the Operational Research Society*, vol. 20, n.º 4, pp. 451-468, 1969, doi: 10.1057/jors.1969.103.
- [52] Mibgas, «Índice ibérico de precios del hidrógeno verde (Mibgas IBHYX)». [En línea]. Disponible en: <https://greenenergy.mibgas.es/>
- [53] OMIE, «Mercado diario de electricidad: funcionamiento y horario de la sesión». [En línea]. Disponible en: <https://www.omie.es/es/mercado-de-electricidad>